UNIVERSIDAD TECNOLÓGICA METROPOLITANA

Facultad de Ingeniería · Escuela de Informática y Computación
Cátedra Gestión de Proyectos Informáticos (GPI) 2026-II · Sección 411

Informe de Evaluación Técnica y Económica (Informe ERV) – Caso de Estudio PIA

Integración del prototipo Vox-Causal AI (Inferencia Causal Multimodal) en la plataforma corporativa de Alloxentric SpA

Tabla 1. *Datos del informe*

Campo	Detalle
Cliente corporativo	Alloxentric SpA – casa matriz en Londres, Reino Unido
Sección / grupo	411 – Grupo 2
Docente	Dr. Oscar Magna Veloso
Desafío técnico del caso	Latencia de inferencia < 250 ms, 1.500 llamadas concurrentes, error ATE ≤ 0,05 e integración con Azure (API Management, Service Bus, Blob Storage con SAS URLs, Azure OpenAI)
Entrega	28 de octubre de 2026 · repositorio del proyecto, carpeta /docs/erv

Integrantes

Giovanni Gabrielli · Martín Vera · Aylin Strajilevich · Cristóbal Muñoz

Índice

Resumen ejecutivo 3
1. Contexto y problema 3
1.1 Por qué IA causal y no correlacional 3
1.2 Estado del arte y soluciones comparables 4
1.3 Objetivos 4
2. Gestión y control del proyecto (EVM) 5
3. Arquitectura C4 6
3.1 Nivel 1 – Contexto 7
3.2 Nivel 2 – Contenedores 8
3.3 Nivel 3 – Componentes del Servicio de Inferencia 10
4. Pipeline MLOps, inferencia y resolución del incidente 10
4.1 Resolución del incidente de latencia y seguridad 11
5. Evidencia del repositorio 12
6. Métricas objetivas de software e IA 13
7. Evaluación financiera ERV 13
7.1 CAPEX y OPEX 13
7.2 Beneficios y flujo de caja 14
7.3 Indicadores por escenario 14
8. Impacto, recomendación ejecutiva y hoja de ruta 16
8.1 Ahorro para el cliente y recargo 16
8.2 Diferenciación 16
8.3 Riesgos 16
8.4 Dictamen ejecutivo 17
Referencias 18
Anexo A. Supuestos y fuentes 20
Anexo B. Equivalencia de servicios Azure ↔ AWS usada para costear 21
Anexo C. Especificación de servicios, protocolos y mapeo del pipeline 22
C.1 Especificación de los servicios de inferencia 22
C.2 Protocolos de comunicación y mapeo del pipeline 23

Nota: si el índice aparece vacío, en Word haga clic derecho sobre él y elija «Actualizar campos».

Resumen ejecutivo

Alloxentric SpA solicitó evaluar si conviene financiar e integrar en su plataforma SaaS el prototipo **Vox-Causal AI**, que identifica durante la llamada la **causa raíz** de la insatisfacción del cliente y su riesgo de fuga, combinando análisis prosódico de la voz con Modelos Causales Estructurales (SCM/DAG). La evaluación se apoya en (1) una revisión del estado del arte y de soluciones comparables, (2) el diseño de la arquitectura de integración en Azure con un presupuesto de latencia, y (3) un modelo financiero a 5 años con precios públicos de AWS como referencia y supuestos de mercado citados.

Nota metodológica. Por instrucción de la cátedra, los costos de infraestructura se estimaron con **precios públicos de AWS en Londres (eu-west-2)** para el servicio equivalente a cada componente Azure del caso (Anexo B). Montos en dólares (US$).

Tabla 2. *Indicadores clave de la evaluación*

Indicador	Meta / resultado	Lectura
Latencia de inferencia	< 250 ms [CASO] · diseño p95 175 ms	Cumple con 75 ms de holgura (capítulo 4)
Concurrencia	1.500 llamadas [CASO]	36 GPU y 12 nodos CPU en el pico, autoescalado
Precisión causal	Error ATE ≤ 0,05 [CASO]	Puerta de calidad en el pipeline antes de publicar
CAPEX / OPEX anual pleno	US$ 69.835 / US$ 281.383	800 HH del caso; cloud + 1 FTE MLOps
VAN después de impuestos (12,34%)	US$ 366.751	Crea valor en el escenario base
TIR / Payback / B/C	91,9% / 1,82 años / 1,54	Recupera la inversión en el año 2
Valor para el cliente	US$ 13,2 de ahorro por cada US$ 1 de recargo	Justifica el recargo de 20%

Dictamen: GO CONDICIONADO

El proyecto es técnica y económicamente viable en los escenarios base y optimista. El escenario pesimista (VAN −US$ 215.937) muestra que el valor depende del **precio aceptado por el mercado y de la adopción**. Se recomienda avanzar por fases con tres condiciones: prueba de carga que cumpla < 250 ms con 1.500 llamadas, piloto que valide un recargo ≥ 15% (quiebre: 13,1%) y LLM de bajo costo fuera del camino crítico (capítulo 8).

1. Contexto y problema

Alloxentric SpA, con casa matriz en Londres, procesa diariamente millones de interacciones de texto, audio y video en Microsoft Azure. Sus modelos de IA actuales son **correlacionales**: detectan sentimiento o tono, pero no explican **por qué** el cliente está insatisfecho ni qué acción reduciría su riesgo de fuga. Vox-Causal AI aborda ese vacío con un DAG sobre las causas operativas de una llamada (transferencias, esperas, errores de cobro), ajustado por confusores como el historial de contacto del cliente, y con los rasgos prosódicos de la voz medidos en vivo.

1.1 Por qué IA causal y no correlacional

Un ejemplo numérico, verificable a mano, muestra el problema. Los clientes que **ya habían llamado antes** son transferidos más a menudo y, además, se fugan más por sí solos: el contacto previo es un **confusor**. Dentro de cada segmento, ser transferido varias veces aumenta la fuga en exactamente **8 puntos porcentuales** (el efecto real):

Tabla 3. *Ejemplo ilustrativo de sesgo por confusión (probabilidad de fuga a 90 días)*

Segmento	Peso	% transferido	Fuga si transferido	Fuga si no	Efecto real
Con llamada previa	40%	60%	35%	27%	+8 pp
Primer contacto	60%	25%	15%	7%	+8 pp

Fuente: ejemplo construido por el equipo con asistencia de IA (Claude Opus, Anthropic).

Si se comparan directamente todos los clientes transferidos con los no transferidos, la fuga es **27,3% frente a 12,2%**: la lectura correlacional atribuye a las transferencias **15,1 pp**, casi el doble del efecto real, con un **error de ATE de 0,071 > 0,05**. Ajustando por el confusor (criterio backdoor: promediar el efecto dentro de cada segmento) se recupera el efecto real de 8 pp. Por eso el caso usa el error de ATE como métrica de precisión: solo un método causal la cumple, y un operador guiado por correlaciones puede atacar la causa equivocada.

1.2 Estado del arte y soluciones comparables

Tabla 4. *Soluciones comparables en producción*

Solución / caso	Qué hace	Resultado reportado	Brecha frente a Vox-Causal
Cogito en MetLife (EE. UU.)	Analiza tono, ritmo y frecuencia de palabras en vivo y sugiere ajustes al agente	+13% satisfacción y +3,5% resolución al primer contacto en 10 centros	Detecta cómo suena la llamada, no por qué el cliente está molesto
Microsoft Copilot for Service	Asistente de agentes con IA generativa	−12% de AHT (programa de acceso anticipado, 2023)	Recomienda contenido; no atribuye causa
Google Agent Assist en TTEC y YouTube	Sugerencias de conocimiento y resúmenes en vivo	TTEC: −11% de AHT; YouTube: −23% de AHT con agentes conversacionales	Correlacional; no estima efectos
Five9 Agent Assist en TruConnect	Transcripción y notas automáticas	−30 s de AHT en tres meses	Automatiza documentación; no diagnostica
Uber CausalML · Microsoft EconML	Librerías de ML causal (efectos heterogéneos, CATE)	Uso en producción para focalizar campañas y personalizar ofertas	Procesamiento por lotes en marketing, no streaming de voz

Fuente: Best Practice AI (MetLife); CX Today (2023); Google Cloud (2024); Business Wire (2021); repositorio uber/causalml. Ver Referencias.

Lecciones. (1) Las reducciones de tiempo de manejo reportadas (**11% a 23%**) hacen **plausible** el 15% de reducción de TTR del caso, que se ubica dentro del rango; el capítulo 8 también evalúa el valor con 11%. (2) Ninguna solución revisada estima **efectos causales en vivo**: todas detectan emoción, sentimiento o contenido. Esa es la diferenciación que sostiene el recargo de 20%. (3) Desde el **2 de febrero de 2025** el **EU AI Act (art. 5.1.f)** prohíbe los sistemas de reconocimiento de emociones a partir de datos biométricos en el lugar de trabajo, con ejemplos explícitos de monitoreo de agentes de call center. Por eso el diseño analiza **solo la voz del cliente** y nunca la del operador.

1.3 Objetivos

- Evaluar la compatibilidad técnica del prototipo con la arquitectura Azure de Alloxentric y la factibilidad de los KPI del caso, resolviendo el incidente de latencia y seguridad.
- Estimar CAPEX y OPEX con fuentes verificables y calcular VAN, TIR, Payback y B/C.
- Emitir un dictamen GO / NO-GO con sus condiciones, riesgos y hoja de ruta.

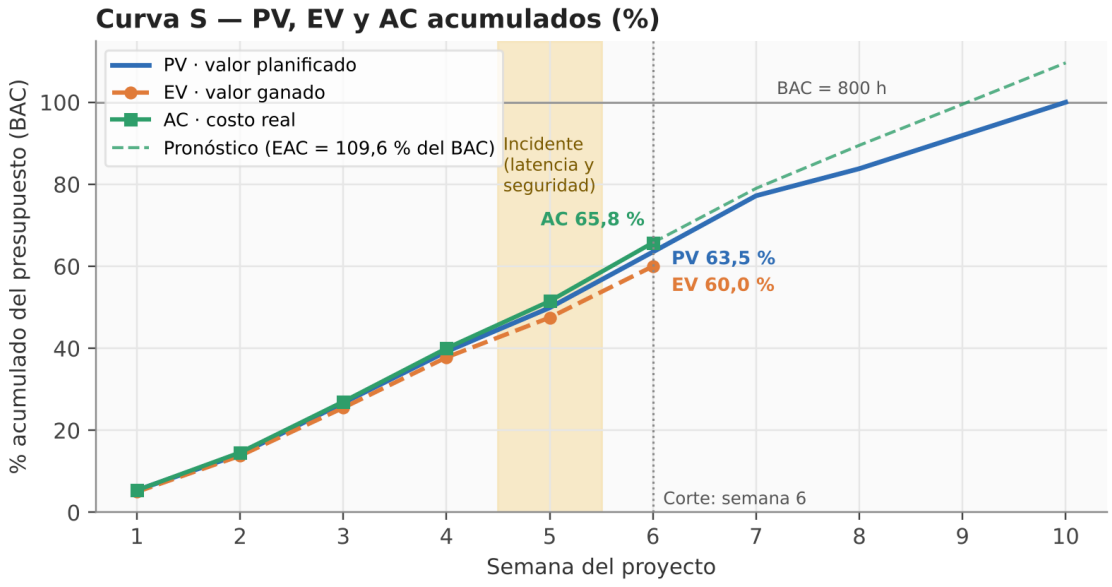
2. Gestión y control del proyecto (EVM)

La línea base del proyecto de integración corresponde a las **800 horas-hombre** del caso (BAC = US$ 54.982 a US$ 68,73/h), distribuidas en **siete paquetes de trabajo durante 10 semanas**. La fecha de corte es el cierre de la semana 6. **Origen de los datos:** PV desde la línea base; EV y AC como **escenario de control simulado** para el ejercicio académico (el proyecto aún no se ejecuta), incluido el retrabajo de integración y seguridad provocado por el incidente de latencia y seguridad (capítulo 4).

Tabla 5. *Estructura de desglose del trabajo (EDT) y valor ganado al corte de la semana 6 (horas)*

#	Paquete de trabajo	Semanas	BAC	PV	EV	AC	SPI	CPI
1	Gestión, gobernanza y evaluación de impacto (DPIA)	S1–S10	60	36	36	40	1,00	0,90
2	Refactorización y contenerización del prototipo	S1–S4	150	150	150	158	1,00	0,95
3	Integración Azure (APIM, Service Bus, Blob SAS, Web PubSub)	S3–S7	150	120	96	118	0,80	0,81
4	Pipeline MLOps y motor causal (Azure ML)	S2–S7	160	133	140	142	1,05	0,99
5	Seguridad y cumplimiento (SAS, TLS, aislamiento, UK GDPR)	S5–S8	90	45	40	48	0,89	0,83
6	Pruebas SQA y desempeño (latencia, concurrencia, ATE)	S6–S10	120	24	18	20	0,75	0,90
7	Despliegue canario y transferencia	S9–S10	70	0	0	0	—	—
	Total proyecto	S1–S10	800	508	480	526	0,945	0,913

Fuente: línea base del equipo sobre las 800 HH [CASO]; EV y AC simulados; Elaborado por el Grupo 2 con asistencia de IA (Claude Opus, Anthropic); revisado por el equipo.



Fuente: línea base de 7 paquetes sobre las 800 HH del caso; EV y AC = escenario de control simulado (no medición real).
Elaborado por el Grupo 2 (Sección 411) con asistencia de IA: Claude Opus (Anthropic).

Figura 1. *Curva S: PV, EV y AC acumulados en % del BAC, con pronóstico al término. Elaborado por el Grupo 2 con asistencia de IA (Claude Opus, Anthropic); revisado por el equipo.*

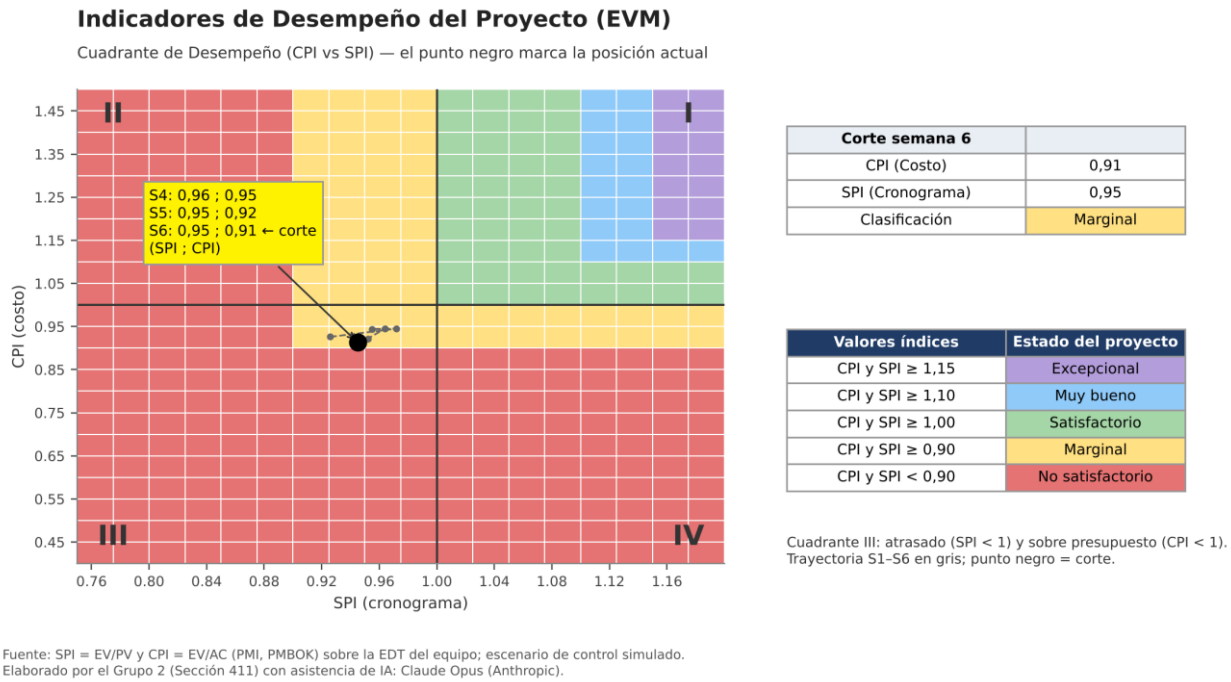


Figura 2. *Cuadrante de desempeño (CPI vs. SPI) con la escala de clasificación; trayectoria semanal hasta el corte. Elaborado por el Grupo 2 con asistencia de IA (Claude Opus, Anthropic); revisado por el equipo.*

Tabla 6. *Indicadores EVM al corte*

Indicador	Valor	Interpretación
SV = EV − PV	−28 h	Atraso concentrado en la integración Azure (paquete 3)
CV = EV − AC	−46 h	Sobrecosto por retrabajo de integración y seguridad (paquetes 3 y 5)
SPI / CPI	94,5% / 91,3%	Cuadrante III (atrasado y sobre presupuesto) · clasificación Marginal (CPI y SPI ≥ 0,90)
EAC = BAC / CPI	877 h (US$ 60.256)	Desvío final estimado de 77 h (9,6%)
Reserva de contingencia (15%)	120 h	Cubre el desvío: se consumiría el 64%
TCPI = (BAC − EV) / (BAC − AC)	1,168	Eficiencia exigente para cerrar en el BAC; se gestiona con la reserva

Fuente: fórmulas PMI (PMBOK, 7.ª ed.) aplicadas a la EDT anterior.

Acciones correctivas: (1) congelar el alcance de los paquetes 3 y 5 en los controles ya definidos; (2) reutilizar plantillas de infraestructura como código para los recursos de Azure; (3) aprobar formalmente el uso de la reserva para el retrabajo del incidente, con seguimiento semanal del CPI.

3. Arquitectura C4

Para evaluar la viabilidad técnica, el equipo abstrajo la solución con el **Modelo C4** (Simon Brown) sobre la arquitectura Azure existente de Alloxentric. El prototipo (Python 3.12, FastAPI, DoWhy/EconML) es compatible con la plataforma; los ajustes requeridos se resumen a continuación.

Tabla 7. *Compatibilidad del prototipo con los servicios Azure de Alloxentric*

Componente existente	Uso en Vox-Causal AI	Compatibilidad	Ajuste requerido
Azure API Management	Publicar APIs de consulta de insights	Alta	Definir políticas JWT y cuotas para el nuevo producto
Azure Service Bus	Explicaciones asíncronas y auditoría	Alta	Crear colas explain-requests y audit-events con DLQ

Componente existente	Uso en Vox-Causal AI	Compatibilidad	Ajuste requerido
Azure Blob Storage + SAS URLs	Almacenar audio de llamadas	Alta	Migrar a SAS de delegación de usuario de 15 min (buena práctica UK GDPR)
Azure OpenAI	Explicación en lenguaje natural	Media	Sacar del camino crítico; filtrar PII antes del prompt
Python 3.12 + FastAPI	Servicios del prototipo	Alta	Contenerizar y agregar endpoints gRPC
DoWhy / EconML	Motor causal	Media	Precalcular efectos offline; en línea solo evaluar

La arquitectura sigue tres principios: **(1) separación del camino crítico**, todo lo que debe responder en menos de 250 ms corre en un servicio síncrono y liviano, y lo lento (Azure OpenAI, auditoría) va por Azure Service Bus; **(2) aislamiento entre batch y tiempo real**, el entrenamiento ocurre en Azure ML y en línea solo se ejecutan modelos aprobados; **(3) seguridad y observabilidad por diseño**, con TLS, SAS de delegación de usuario y telemetría de extremo a extremo.

Tabla 8. *Stack tecnológico por capa*

Capa	Tecnología	Justificación
Presentación	React + TypeScript (escritorio del agente)	Estándar de la plataforma; recibe insights por WebSocket
Entrada / API	Azure API Management	Gateway existente: autenticación JWT (Entra ID), cuotas, versionado
Servicios	Python 3.12 + FastAPI en contenedores Docker sobre AKS	Mismo stack del prototipo; FastAPI es asíncrono y soporta gRPC/WebSocket
Inferencia	ONNX Runtime (GPU), openSMILE eGeMAPS, DoWhy / EconML	ONNX reduce latencia del codificador; DoWhy/EconML son las librerías del prototipo
Mensajería	Azure Service Bus (colas y tópicos AMQP con DLQ)	Arquitectura asíncrona existente; reintentos y dead-letter nativos
Tiempo real	Azure Web PubSub	Entrega por WebSocket a miles de escritorios sin mantener conexiones en los pods
Datos	Blob Storage (audio), Cosmos DB (sesión), PostgreSQL Flexible (insights y auditoría)	Cada almacén según patrón de acceso: objetos, baja latencia, relacional
IA generativa	Azure OpenAI (asíncrono)	Explicaciones en lenguaje natural fuera del camino crítico
MLOps	Azure ML Pipelines + Model Registry, GitHub Actions, Azure Container Registry	Linaje y versionado de modelos; CI/CD reproducible
Observabilidad / seguridad	Azure Monitor, App Insights, Key Vault, Managed Identity, Private Endpoints	Métricas p95, secretos sin credenciales en código, tráfico privado

Fuente: elaboración propia del Grupo 2 a partir del caso PIA; Elaborado por el Grupo 2 con asistencia de IA (Claude Opus, Anthropic); revisado por el equipo.

3.1 Nivel 1 – Contexto

Actores: **operador** (recibe causa raíz y riesgo de fuga), **supervisor/analista CX** y **equipo MLOps**. Sistemas externos: telefonía/CCaaS del cliente, CRM, **Azure OpenAI** (solo redacta explicaciones, no decide la causa) y **Microsoft Entra ID**.

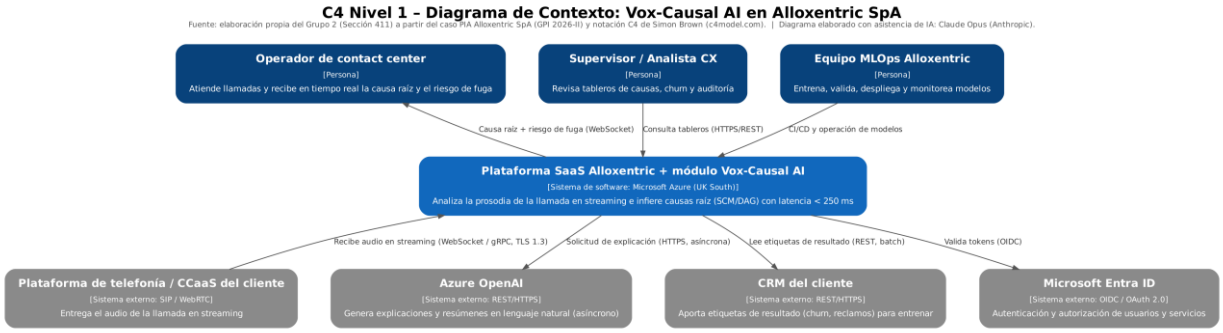


Figura 3. *C4 Nivel 1 – Diagrama de Contexto. Elaborado por el Grupo 2 con asistencia de IA (Claude Opus, Anthropic); revisado por el equipo.*

3.2 Nivel 2 – Contenedores

El flujo crítico es **CCaaS → Media Ingest Gateway → Servicio de Inferencia → Web PubSub → Escritorio del agente**. Las explicaciones siguen la ruta **Servicio de Inferencia → Service Bus → Worker → Azure OpenAI**, que nunca bloquea al operador.

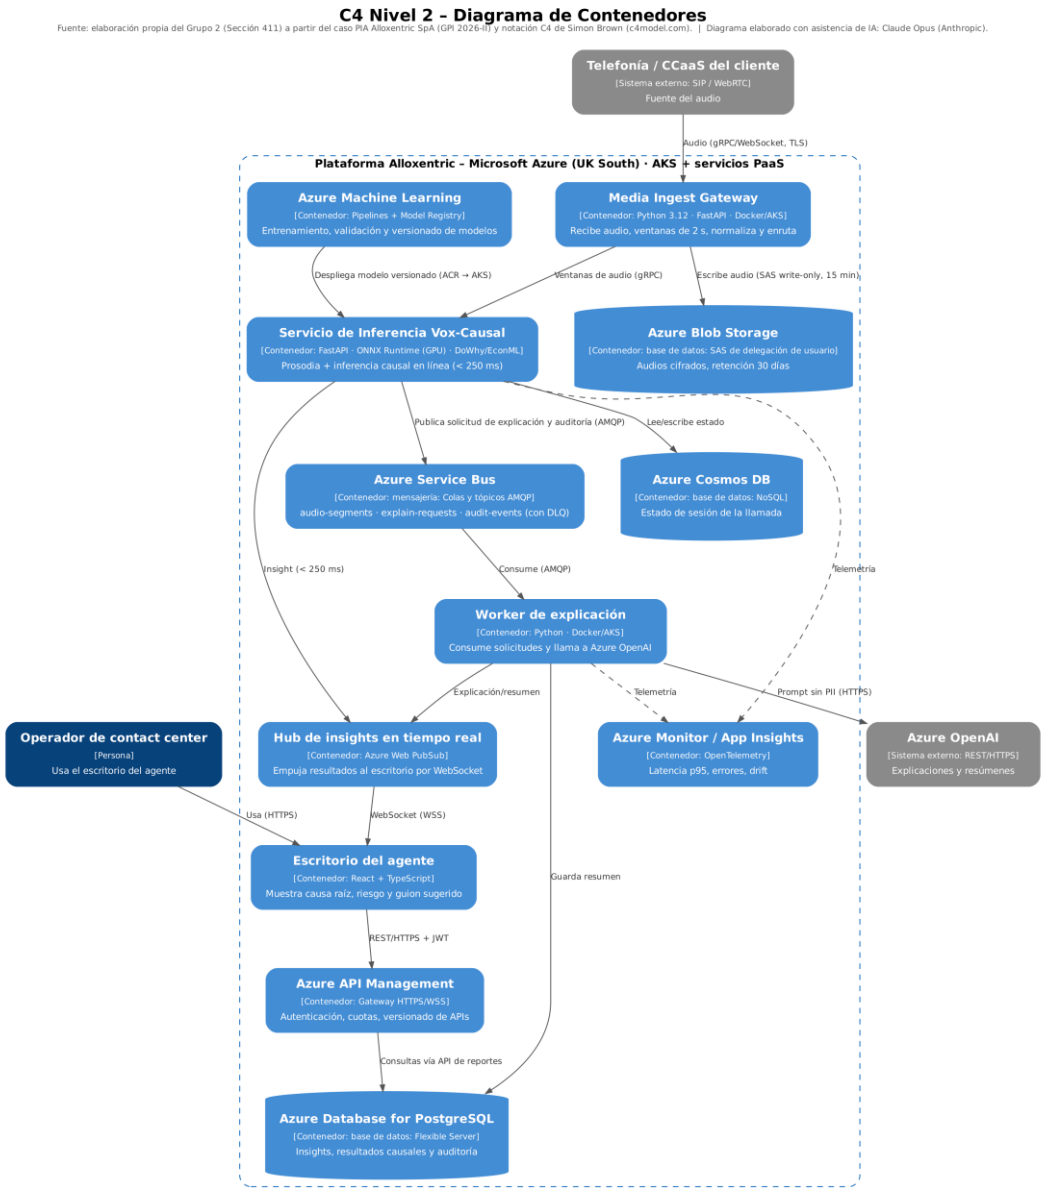


Figura 4. *C4 Nivel 2 – Diagrama de Contenedores. Elaborado por el Grupo 2 con asistencia de IA (Claude Opus, Anthropic); revisado por el equipo.*

Tabla 9. *Responsabilidad de cada contenedor*

Contenedor	Tecnología	Responsabilidad
Escritorio del agente	React + TypeScript	Mostrar causa raíz, riesgo de fuga y guion sugerido
Azure API Management	Gateway gestionado	Autenticación, cuotas y versionado de APIs REST
Media Ingest Gateway	FastAPI · AKS	Recibir audio, crear ventanas de 2 s, copiar a Blob y enrutar
Servicio de Inferencia Vox-Causal	FastAPI · ONNX GPU · DoWhy/EconML	Prosodia + inferencia causal en línea, p95 < 250 ms
Azure Web PubSub	PaaS WebSocket	Empujar insights a los escritorios
Azure Service Bus	Colas/tópicos AMQP	Desacoplar explicaciones y auditoría; DLQ
Worker de explicación	Python · AKS	Llamar a Azure OpenAI con prompts sin PII
Blob Storage / Cosmos DB / PostgreSQL	PaaS de datos	Audio cifrado 30 días / estado de sesión / insights y auditoría
Azure Machine Learning	Pipelines + Registry	Entrenar, validar y versionar modelos

Contenedor	Tecnología	Responsabilidad
Azure Monitor / App Insights	OpenTelemetry	Métricas p95, errores, drift y alertas

3.3 Nivel 3 – Componentes del Servicio de Inferencia

El **Stream Receiver** agrupa frames de 20 ms en ventanas de 2 s; el **Extractor prosódico** calcula el conjunto eGeMAPS; el **Codificador acústico** (ONNX en GPU) produce un embedding; el **Estimador de efecto causal** evalúa modelos EconML **precalculados** sobre el DAG del registro; el **Ranking** entrega las tres causas más probables y la probabilidad de fuga; el **Latency Guard** protege el presupuesto de tiempo con un fallback, y el **Telemetry & Audit Logger** registra cada decisión.

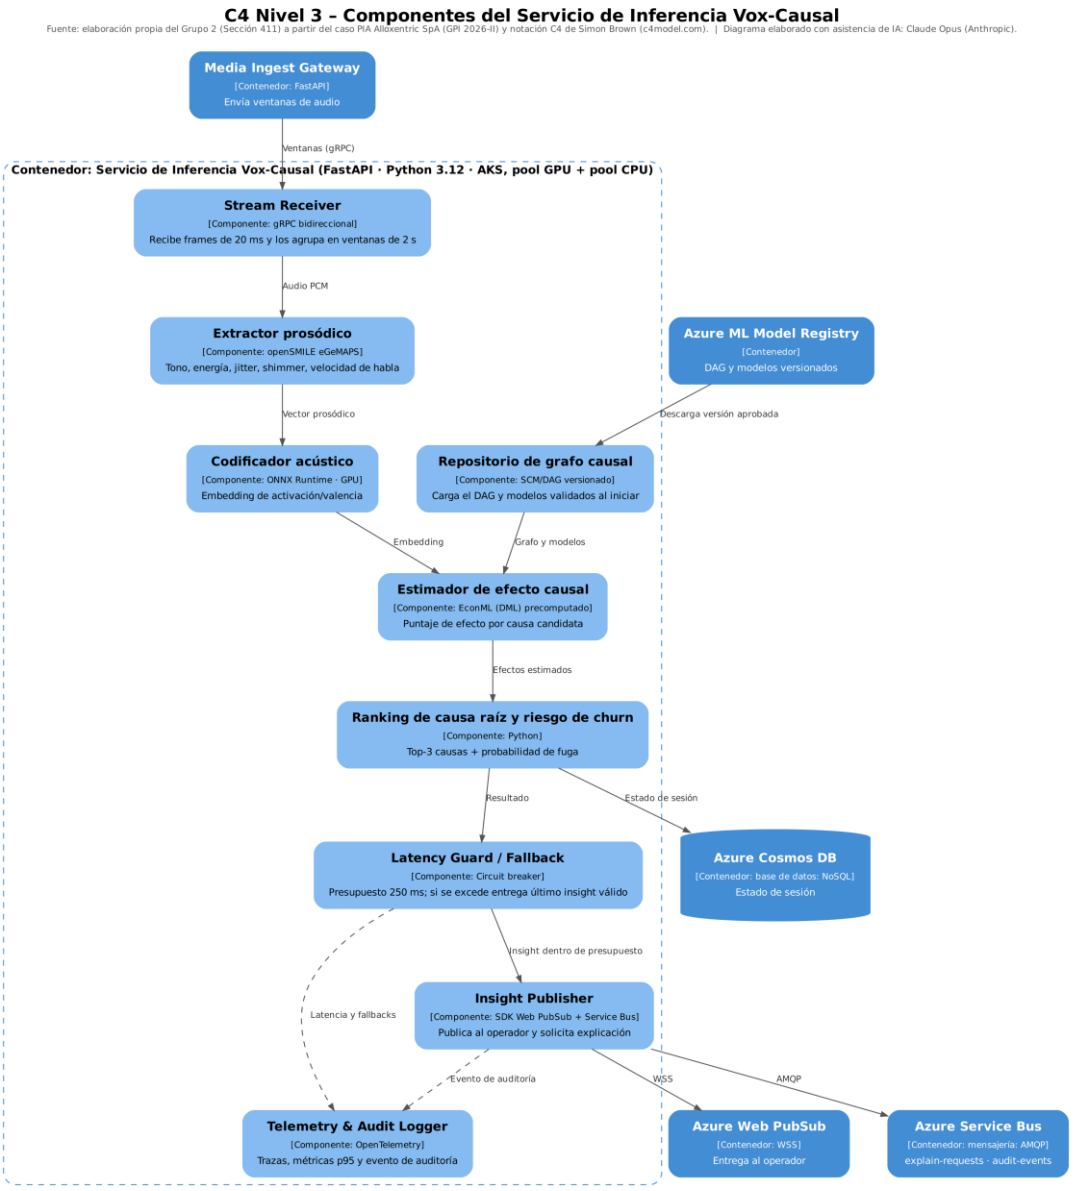


Figura 5. *C4 Nivel 3 – Componentes del Servicio de Inferencia Vox-Causal. Elaborado por el Grupo 2 con asistencia de IA (Claude Opus, Anthropic); revisado por el equipo.*

4. Pipeline MLOps, inferencia y resolución del incidente

El pipeline tiene tres carriles: **A. entrenamiento offline** en Azure ML con una puerta de calidad (error ATE ≤ 0,05 y refutadores DoWhy), **B. inferencia en línea** por llamada y **C. ruta asíncrona** con reintentos, cola de

mensajes fallidos (DLQ), fallback, telemetría, auditoría y detección de drift que gatilla un nuevo entrenamiento. Los carriles A y B solo se conectan a través del modelo aprobado en el registro. El mapeo etapa por etapa y los contratos de los servicios están en el Anexo C.

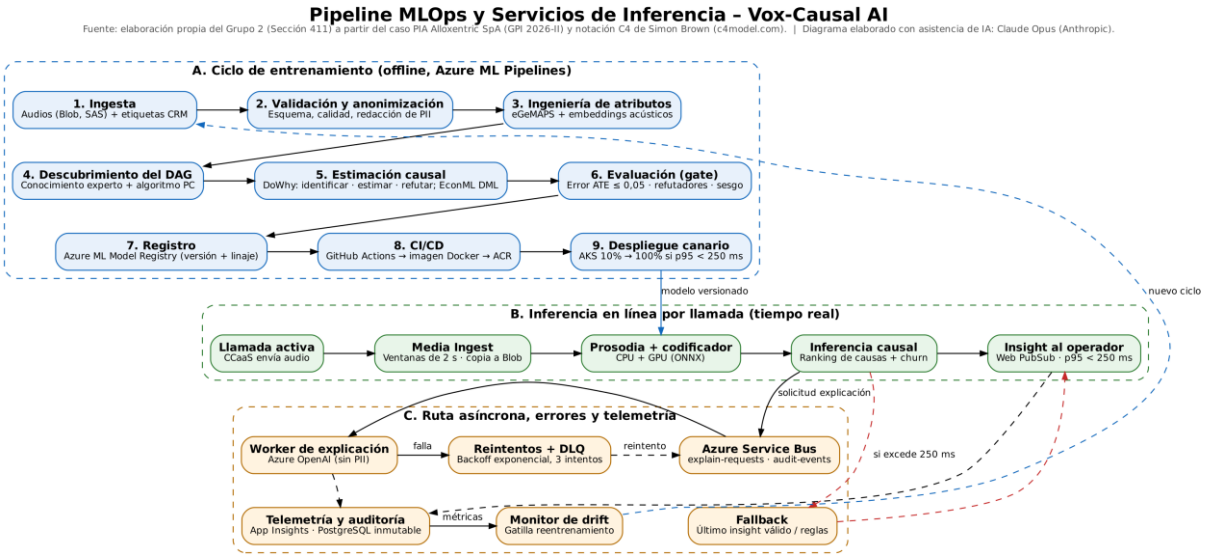


Figura 6. *Pipeline MLOps y servicios de inferencia: ingesta, preprocesamiento, invocación del modelo, errores/fallbacks y telemetría. Elaborado por el Grupo 2 con asistencia de IA (Claude Opus, Anthropic); revisado por el equipo.*

4.1 Resolución del incidente de latencia y seguridad

Incidente. El caso exige que la inferencia sobre el flujo prosódico responda en **menos de 250 ms**, que el prototipo se integre con la arquitectura existente —donde los audios se leen desde Blob Storage mediante **SAS URLs**— y que los datos de voz de clientes del Reino Unido cumplan **UK GDPR**. Conectado tal como funcionaba en el sandbox, el prototipo no cumplía ni la meta de latencia ni los requisitos de seguridad.

Causa raíz. El prototipo encadenaba en una sola solicitud componentes incompatibles con la meta: la respuesta de **Azure OpenAI** crece con el número de tokens generados; la estimación causal con **DoWhy/EconML** reajusta modelos sobre todo el conjunto de datos (una operación por lotes), y el acceso a audios usaba **SAS firmadas con la clave de la cuenta** y de larga duración. Una SAS no cifra: es un token de autorización; el cifrado en tránsito lo aporta **TLS**.

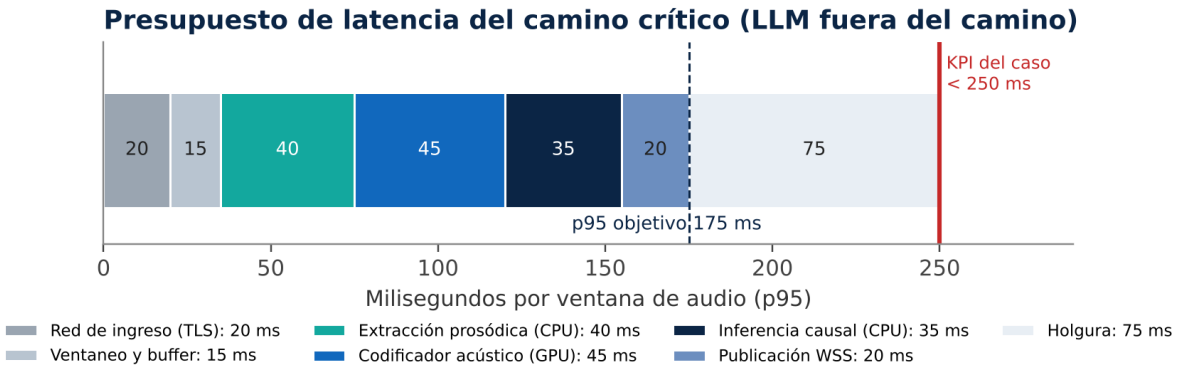
Tabla 10. *Decisiones arquitectónicas frente al incidente*

#	Decisión	Por qué	Alternativa descartada	Respaldo
D1	Separar camino crítico (síncrono) y ruta asíncrona por Service Bus	Nada lento en la ruta en vivo	Una sola API que infiere y explica	La latencia de Azure OpenAI depende de los tokens generados (Microsoft Learn)
D2	Efectos causales precalculados offline; en línea solo se evalúan	Reestimar en la llamada no cabe en 250 ms	DoWhy/EconML completo en línea	Evaluar el modelo ≈ 35 ms vs. reentrenar (minutos)
D3	Codificador ONNX en GPU y transporte gRPC/WebSocket	Menor tiempo de cómputo y serialización	PyTorch en CPU con REST/JSON	Presupuesto de 45 ms por ventana (ver presupuesto de latencia)
D4	SAS de delegación de usuario (Entra ID), solo HTTPS, 15 min, mínimo privilegio; TLS 1.3; región UK South	Seguridad de los audios y UK GDPR	SAS con clave de cuenta y larga duración	Microsoft recomienda la SAS de delegación, HTTPS siempre y expiración corta

#	Decisión	Por qué	Alternativa descartada	Respaldo
D5	Aislamiento batch / tiempo real: node pools, subredes, almacenamiento e identidades separados; solo comparten el registro (lectura)	El entrenamiento no compite con la API ni expone datos	Mismo clúster y colas compartidas	Prueba de aislamiento: reentrenar durante la carga sin variar el p95 > 5%
D6	Analizar solo el canal del cliente, seudonimizar y no enviar PII al LLM	UK GDPR y EU AI Act art. 5.1.f	Analizar ambas voces	Prohibición de reconocimiento de emociones de trabajadores desde 02-02-2025

Fuente: elaboración propia del Grupo 2; Microsoft Learn (SAS, latencia de Azure OpenAI); EU AI Act. Elaborado por el Grupo 2 con asistencia de IA (Claude Opus, Anthropic); revisado por el equipo.

Presupuesto de latencia. La referencia es la conversación humana: la Recomendación **ITU-T G.114** indica que con un retardo en un sentido menor a 150 ms la mayoría de las aplicaciones de voz es transparente para el usuario. El camino crítico suma **175 ms en p95**, con 75 ms de holgura bajo los 250 ms del caso.



Fuente: asignación de presupuesto del equipo por componente; a validar con prueba de carga de 1.500 llamadas concurrentes.
Elaborado por el Grupo 2 (Sección 411) con asistencia de IA: Claude Opus (Anthropic).

Figura 7. *Presupuesto de latencia del camino crítico por ventana de audio. Elaborado por el Grupo 2 con asistencia de IA (Claude Opus, Anthropic); revisado por el equipo.*

Verificación. (1) Prueba de carga de una semana con 1.500 llamadas concurrentes (incluida en el CAPEX); (2) pruebas de seguridad: rechazo de HTTP y de TLS < 1.2, SAS que expira a los 15 minutos, escaneo de PII en los prompts; (3) prueba de aislamiento descrita en D5. **Riesgo residual:** si para cumplir la latencia cada GPU procesa menos streams que los 50 supuestos, el costo sube; el proyecto sigue siendo rentable mientras se procesen al menos **19 streams por GPU** (capítulo 7).

5. Evidencia del repositorio

El repositorio oficial del proyecto está en **GitHub: https://github.com/GiovanniGabrielli33/gpi-411-grupo2-voxcausal**. Según la pauta, el Informe ERV y la presentación se alojan en la carpeta **/docs/erv**, junto con los diagramas y los gráficos de control que respaldan la evaluación.

Tabla 11. *Estructura del repositorio*

Carpeta	Contenido
/README.md	Descripción del caso, integrantes, dictamen y enlace a la carpeta Drive /GPI-Taller Arquitectura/
/docs/erv	Informe ERV (Word y PDF) y presentación del caso; subcarpeta /figuras con los gráficos de costos, flujo de caja, sensibilidad, latencia y ahorro
/docs/arquitectura	Diagramas C4 niveles 1, 2 y 3 y pipeline MLOps en alta resolución
/docs/gestion	Curva S y cuadrante de desempeño EVM

Carpeta	Contenido
/src · /tests	Reservadas para el código y las pruebas de la solución; se completan en la fase de integración si el dictamen es GO

Flujo de ramas: la rama **main** contiene la versión entregada; el trabajo del informe se desarrolla en la rama **feature/erv** y se integra a main mediante un **pull request** revisado por otro integrante, de modo que el historial de commits deja trazabilidad de cada cambio.

6. Métricas objetivas de software e IA

Cada métrica tiene una meta, un método de medición y un criterio de aceptación que se exige antes de la puesta en producción. Son **criterios de aceptación**; los valores medidos se obtendrán en la prueba de carga y en el pipeline de CI.

Tabla 12. *Métricas, metas y criterios de aceptación*

Dimensión	Meta	Cómo se mide	Criterio de aceptación
Precisión causal	Error ATE ≤ 0,05 [CASO]	Datos de prueba con efecto conocido (como el ejemplo del capítulo 1) + refutadores DoWhy (placebo, causa común aleatoria, subconjunto)	Error ≤ 0,05 y las tres refutaciones aprobadas
Latencia	< 250 ms [CASO]; diseño p95 175 ms	Telemetría p50/p95/p99 por componente en App Insights	p95 < 250 ms con 1.500 llamadas
Concurrencia	1.500 llamadas sin degradación [CASO]	Prueba de carga de una semana a escala pico	Tasa de fallback < 2% y error < 1%
Cobertura SQA	≥ 80% de líneas en /src	Pruebas unitarias e integración en GitHub Actions	PR bloqueado bajo el umbral
Deuda técnica	≤ 4 h (método SQALE)	SonarQube / SonarCloud en cada PR	Calificación A; el CI bloquea si empeora

7. Evaluación financiera ERV

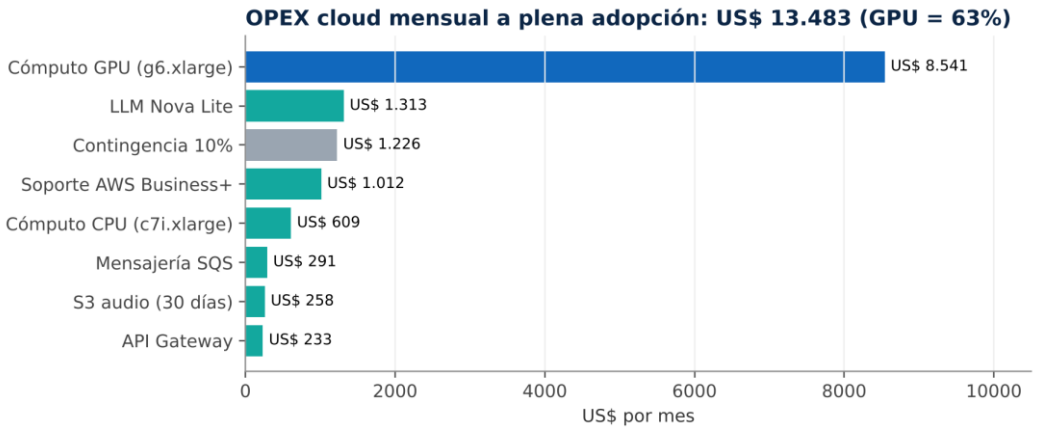
Modelo anual a **5 años** sin valor terminal, en dólares, **después de impuestos** (impuesto corporativo UK de 25%, Finance Act 2025; CAPEX amortizado en 5 años). **Tasa de descuento: 12,34%** = costo de capital del sector Software (System & Application) de Damodaran (ene-2026, 9,34%) + 3 pp de premio por riesgo de innovación. La justificación de cada dato está en el Anexo A.

7.1 CAPEX y OPEX

Tabla 13. *CAPEX*

Concepto	Cálculo	US$
Desarrollo e integración	800 HH [CASO] × US$ 68,73 (salario ML Engineer UK £68.444 + 30% de carga, 1.740 h/año, 1,344 US$/£)	54.982
Contingencia	15% del desarrollo	8.247
Prueba de carga a escala pico	168 h × (36 GPU + 12 CPU) on-demand [AWS]	6.606
Total CAPEX		69.835

El OPEX cloud se dimensionó con un perfil semanal de demanda de contact center UK (factor de carga 31,8%, **3,38 millones de llamadas al mes** a plena adopción, AHT 6 min 10 s). El cómputo GPU es **63% del OPEX cloud**; el personal MLOps (1 FTE) representa el 42% del OPEX total.



Fuente: precios públicos AWS eu-west-2 (Londres) como referencia equivalente a Azure; volumen y capacidad según supuestos del Anexo A. Elaborado por el Grupo 2 (Sección 411) con asistencia de IA: Claude Opus (Anthropic).

Figura 8. *Desglose del OPEX cloud mensual a plena adopción. Elaborado por el Grupo 2 con asistencia de IA (Claude Opus, Anthropic); revisado por el equipo.*

7.2 Beneficios y flujo de caja

Ingreso para Alloxentric: recargo de 20% [CASO] sobre una suscripción base de **US$ 65 por seat al mes** (precios publicados de plataformas comparables: Google US$ 50–60, Sentient US$ 65, Observe.AI US$ 89) para **3.590 seats**, derivados de la carga de llamadas con shrinkage de 30% y ocupación de 85% (Call Centre Helper). A plena adopción: **US$ 560.027 al año**. El ahorro de TTR del cliente **no se suma** como ingreso de Alloxentric para no contarlo dos veces: es el valor que justifica el recargo (capítulo 8).

Tabla 14. *Flujo de caja del proyecto (US$)*

Concepto	Año 0	Año 1	Año 2	Año 3	Año 4	Año 5
Adopción	—	30%	60%	85%	100%	100%
Ingreso (recargo 20%)	—	168.008	336.016	476.023	560.027	560.027
OPEX (cloud + MLOps)	—	−176.568	−222.693	−259.649	−281.383	−281.383
Impuesto (25%)	—	5.632	−24.839	−50.602	−66.169	−66.169
CAPEX	−69.835	—	—	—	—	—
Flujo de caja libre	−69.835	−2.928	88.484	165.772	212.475	212.475

Fuente: elaboración propia; impuesto = 25% × (EBITDA − amortización US$ 13.967); Elaborado por el Grupo 2 con asistencia de IA (Claude Opus, Anthropic); revisado por el equipo.

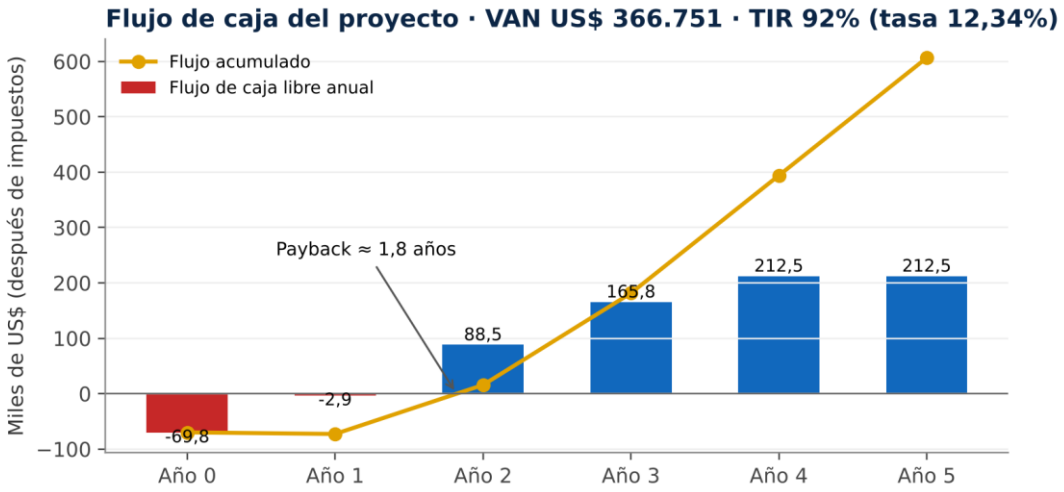
7.3 Indicadores por escenario

Tabla 15. *Indicadores financieros por escenario (después de impuestos)*

Indicador	Pesimista	Base	Optimista
Supuestos clave	ARPU US$ 50 · adopción 15→80% · 25 streams/GPU	ARPU US$ 65 · adopción 30→100% · 50 streams/GPU · 1 FTE	ARPU US$ 89 · 100 streams/GPU · 0,5 FTE MLOps
VAN (12,34%)	−US$ 215.937	US$ 366.751	US$ 1.037.247
TIR	No se alcanza	91,9%	238,0%
Payback	> 5 años	1,82 años	0,65 años

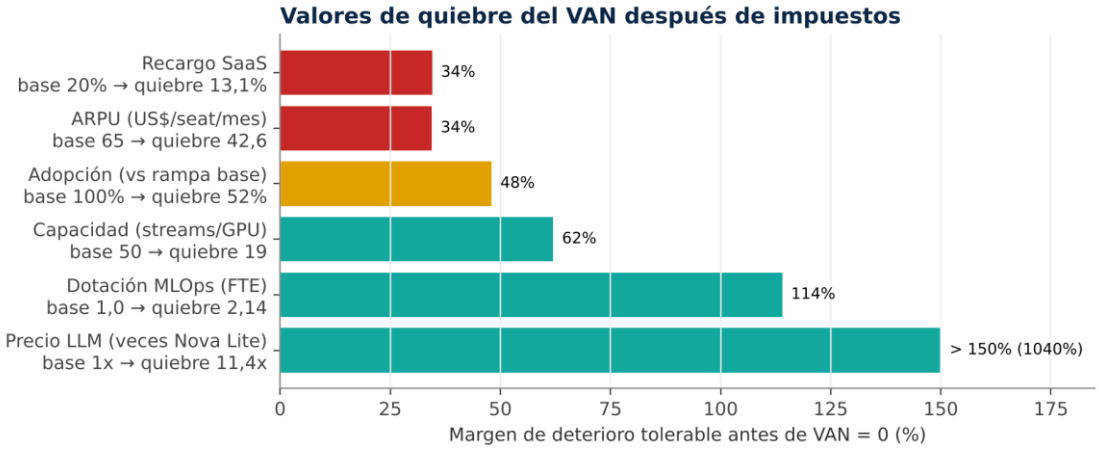
Indicador	Pesimista	Base	Optimista
Relación B/C	0,71	1,54	3,53

Fuente: modelo ERV del equipo; B/C = VP(ingresos) / VP(CAPEX + OPEX); Elaborado por el Grupo 2 con asistencia de IA (Claude Opus, Anthropic); revisado por el equipo.



Fuente: evaluación privada de Alloxentric; supuestos y fuentes en Anexo A (AWS, Damodaran 2026, Finance Act UK 2025, caso PIA).
Elaborado por el Grupo 2 (Sección 411) con asistencia de IA: Claude Opus (Anthropic).

Figura 9. *Flujo de caja anual y acumulado del escenario base. Elaborado por el Grupo 2 con asistencia de IA (Claude Opus, Anthropic); revisado por el equipo.*



Fuente: análisis de sensibilidad univariado del equipo sobre el modelo ERV; rojo = margen < 40% (riesgo crítico).
Elaborado por el Grupo 2 (Sección 411) con asistencia de IA: Claude Opus (Anthropic).

Figura 10. *Valores de quiebre: deterioro tolerable de cada variable antes de que el VAN sea cero. Elaborado por el Grupo 2 con asistencia de IA (Claude Opus, Anthropic); revisado por el equipo.*

Lectura. La inversión es pequeña frente al ingreso recurrente; por eso la TIR resulta alta y la decisión se apoya en el VAN, la relación B/C y la sensibilidad. Las variables críticas son el **recargo** (quiebre en 13,1%) y el **ARPU** (quiebre en US$ 42,6, equivalente a unos **2.350 seats** al precio base), seguidas de la **adopción** (52% de la rampa) y la **capacidad por GPU** (19 streams). La tasa de descuento casi no mueve el resultado: entre 9,34% y 15% el VAN va de US$ 412.935 a US$ 330.644. Usar un LLM premium (Nova Pro) vuelve negativo el VAN (−US$ 68.299).

8. Impacto, recomendación ejecutiva y hoja de ruta

8.1 Ahorro para el cliente y recargo

Las 4,17 millones de horas de llamada anuales, reducidas en 15% [CASO], liberan 625 mil horas de agente. Valoradas al costo de un agente UK (£23.500 anuales, Pertemps, + 30% de carga: US$ 23,60/h) y suponiendo que solo **50%** se convierte en ahorro de dotación, el ahorro del cliente es de **US$ 7,37 millones al año**, frente a US$ 0,56 millones de recargo: **13,2 veces**. Con la reducción de 11% reportada por TTEC con Google Agent Assist, la relación sigue siendo de **9,7 veces**.

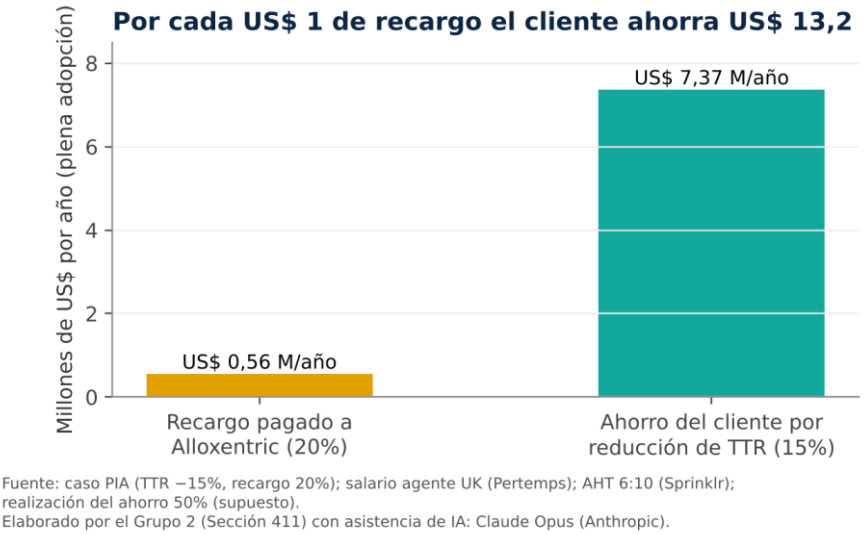


Figura 11. *Ahorro del cliente frente al recargo pagado a Alloxentric. Elaborado por el Grupo 2 con asistencia de IA (Claude Opus, Anthropic); revisado por el equipo.*

8.2 Diferenciación

- **Causal frente a correlacional:** las soluciones revisadas (Cogito, Copilot, Google, Five9) detectan emoción, sentimiento o contenido; Vox-Causal estima la causa y su efecto, con error de ATE ≤ 0,05 como criterio de publicación.
- **Explicable y auditable:** cada insight registra la versión del modelo y del DAG, las causas entregadas y su efecto estimado.
- **Cumplimiento por diseño:** región UK South, seudonimización, retención de 30 días y análisis exclusivo de la voz del cliente, condición para vender en la Unión Europea (EU AI Act art. 5.1.f).

8.3 Riesgos

Tabla 16. *Matriz de riesgos*

Riesgo	Prob.	Impacto	Mitigación
El mercado no acepta el recargo de 20%	Media	Alto	Piloto pagado con 2–3 clientes; argumento de ahorro 13:1
Latencia > 250 ms en pico	Media	Alto	Prueba de carga, Latency Guard, ONNX/GPU, holgura 20%
Capacidad por GPU menor a la supuesta	Media	Medio	Medir en prueba de carga; quiebre en 19 streams
Error ATE > 0,05 con datos reales	Media	Alto	Puerta de calidad; revisión experta del DAG; reentrenamiento

Riesgo	Prob.	Impacto	Mitigación
Incumplimiento UK GDPR / EU AI Act	Baja	Muy alto	D4 y D6: SAS de delegación, TLS, solo voz del cliente, sin PII al LLM
Drift del modelo	Alta	Medio	Monitoreo de drift y reentrenamiento automático

8.4 Dictamen ejecutivo

GO CONDICIONADO, con avance por fases

1. **Aceptación técnica:** prueba de carga en UK South con latencia < 250 ms para 1.500 llamadas concurrentes, ≥ 25 streams por GPU y error ATE ≤ 0,05.
2. **Puerta comercial:** al cierre del piloto, 2–3 clientes UK aceptan un recargo ≥ 15% (quiebre: 13,1%). Bajo ese umbral el dictamen pasa a **NO-GO** de escalamiento.
3. **Costo:** LLM de bajo costo fuera del camino crítico y cierre de los paquetes pendientes dentro de la reserva de contingencia (EAC 877 h).

Tabla 17. *Hoja de ruta post-entrega*

Fase	Plazo	Entregables	Criterio de salida
0 · Integración	Semanas 1–10	Servicios en AKS, Service Bus, SAS de delegación, CI/CD	Cobertura ≥ 80%, deuda ≤ 4 h
1 · Aceptación técnica	Semana 10	Prueba de carga y seguridad en UK South	< 250 ms con 1.500 concurrentes
2 · Piloto controlado	Meses 3–5	2–3 clientes UK; DPIA; corpus etiquetado	Recargo ≥ 15%; error ATE ≤ 0,05
3 · Escalamiento	Meses 6–12	Lanzamiento UK/UE; monitoreo de drift	Adopción 30% el año 1

Referencias

Amazon Web Services. (2026). Amazon API Gateway pricing. https://aws.amazon.com/api-gateway/pricing/

Amazon Web Services. (2026). AWS Support plan pricing. https://aws.amazon.com/premiumsupport/pricing

Amazon Web Services. (2025). Effective cost optimization strategies for Amazon Bedrock (precios Amazon Nova). https://aws.amazon.com/blogs/machine-learning/effective-cost-optimization-strategies-for-amazon-bedrock

Amazon Web Services. (2026). Amazon Nova Lite – Regional availability. https://docs.aws.eu/bedrock/latest/userguide/model-card-amazon-nova-lite.html

Brown, S. (2026). The C4 model for visualising software architecture. https://c4model.com

Call Centre Helper, citado en Lorikeet. (2026). WFM metrics: adherence, shrinkage and occupancy. https://www.lorikeetcx.ai/articles/wfm-metrics-adherence-shrinkage-occupancy-2026

Damodaran, A. (2026, enero). Cost of Capital by Sector (US). NYU Stern. https://pages.stern.nyu.edu/~adamodar/New_Home_Page/datafile/wacc.html

DoiT. (2026). AWS EC2 g6.xlarge y c7i.xlarge – precios on-demand eu-west-2. https://www.doit.com/compute/spot/eu-west-2/g6.xlarge

Enterprise Storage Forum. (2025). AWS S3 pricing (EU London). https://www.enterprisestorageforum.com/cloud/aws-s3-pricing/

Full Fact. (2026). Corporation tax cap at 25%. https://fullfact.org/government-tracker/corporation-tax-cap/

Glassdoor. (2026). Machine Learning Engineer salaries in United Kingdom. https://www.glassdoor.co.uk/Career/machine-learning-engineer-career_KO0,25.htm

Google Cloud. (2026). Conversational Insights pricing. https://cloud.google.com/contact-center/insights/pricing

Hevo Data. (2025). AWS SQS pricing. https://hevodata.com/learn/comprehensive-guide-on-aws-sqs-pricing/

Holori. (2026). c7i.large en eu-west-2 – Compute Savings Plans. https://calculator.holori.com/aws/ec2/c7i.large/eu-west-2

Kayako. (2026). Average handle time industry standards by sector (datos Sprinklr). https://kayako.com/blog/average-handle-time-industry-standard/

Magna, O. (2026). Taller Actividades Prácticas y Caso de Estudio PIA – Arquitectura C4/MLOps e Informe ERV para Alloxentric SpA. GPI 2026-II, UTEM.

MiaRec / Call Centre Helper. (2025). Conversation intelligence & auto QA cost. https://www.callcentrehelper.com/conversation-intelligence-auto-qa-cost-237154.htm

Pertemps. (2026). Contact Centre Agent jobs and salary. https://www.pertemps.co.uk/jobs/contact-centre-agent-jobs/

Pound Sterling Live. (2026). U.S. Dollar–British Pound history 2026. https://www.poundsterlinglive.com/history/USD-GBP-2026

Project Management Institute. (2021). A Guide to the Project Management Body of Knowledge (PMBOK Guide), 7.ª ed. PMI.

Sharma, A. y Kiciman, E. (2020). DoWhy: An end-to-end library for causal inference. arXiv:2011.04216.

Best Practice AI. (s. f.). MetLife: Cogito real-time voice AI in call centres. https://bestpractice.ai/ai-use-cases/case-studies/financial-services/metlife

Business Wire. (2021). TruConnect leverages AI to drive call handling improvements with Five9 Agent Assist. https://www.businesswire.com/news/home/20210428005385/en

CX Today. (2023). Copilot cuts average handling time by 12 percent, claims Microsoft. https://www.cxtoday.com/wfo/copilot-cuts-average-handling-time-by-12-percent-claims-microsoft/

Google Cloud. (2024). Companies achieve stronger results with Customer Engagement Suite. https://cloud.google.com/blog/products/ai-machine-learning/customer-engagement-suite-stronger-results-and-new-ai-features

ITU-T. (2003). Recommendation G.114: One-way transmission time. https://www.cs.columbia.edu/~andreaf/new/documents/other/T-REC-G.114-200305.pdf

Lewis Silkin. (2025). Understanding the EU AI Act's prohibited practices: workplace and advertising (art. 5.1.f). https://www.lewissilkin.com/insights/2025/02/17/understanding-the-eu-ai-acts-prohibited-practices-key-workplace-and-advertising-102k011

Microsoft Learn. (2026). Grant limited access to Azure Storage resources using shared access signatures (SAS). https://learn.microsoft.com/azure/storage/common/storage-sas-overview

Microsoft Learn. (2026). Azure OpenAI: performance and latency. https://learn.microsoft.com/azure/ai-foundry/openai/how-to/latency

Microsoft Research / PyWhy. (2026). EconML: Python package for heterogeneous treatment effects. https://pypi.org/project/econml/

Uber Technologies. (2026). CausalML: uplift modeling and causal inference with machine learning. https://github.com/uber/causalml

Anthropic. (2026). Claude Opus [modelo de lenguaje]. Herramienta de asistencia utilizada en este informe. https://www.anthropic.com

Anexo A. Supuestos y fuentes

Cada dato del modelo se identifica según su origen, con la siguiente convención:

Tabla 18. *Convención de origen de cada dato utilizado*

Etiqueta	Significado	Ejemplo
[CASO]	Dato entregado en el enunciado del caso PIA	800 HH, 1.500 llamadas concurrentes, recargo 20%, TTR −15%
[AWS]	Precio público de Amazon Web Services, región Londres (eu-west-2), usado como referencia por instrucción de la cátedra	GPU g6.xlarge US$1,0216/h
[MERCADO]	Benchmark publicado por una fuente externa citada	WACC software 9,34% (Damodaran, 2026)
[SUP]	Supuesto del equipo, justificado y sometido a sensibilidad	50 streams de audio por GPU

Tabla 19. *Registro completo de supuestos*

Parámetro	Valor	Origen	Justificación / fuente
Concurrencia pico	1.500 llamadas	[CASO]	KPI de throughput del caso
Reducción TTR / recargo	15% / 20%	[CASO]	Beneficios comerciales del caso
Horas de desarrollo	800 HH	[CASO]	CAPEX del caso
Salario ML Engineer UK	£68.444/año	[MERCADO]	Glassdoor, junio 2026
Carga del empleador	30%	[SUP]	National Insurance (15%), pensión y equipamiento
Horas productivas al año	1.740	[SUP]	37,5 h × 52 semanas menos vacaciones y feriados
Tipo de cambio	1,344 US$/£	[MERCADO]	Promedio 2026 (USD/GBP 0,7441), Pound Sterling Live
Perfil de demanda	65% / 10% / 30% / 5% del pico	[SUP]	Horario típico de contact center UK; factor de carga resultante 31,8%
AHT	6 min 10 s	[MERCADO]	Promedio intersectorial 2026, Sprinklr vía Kayako
Streams por GPU / CPU	50 / 150	[SUP]	A validar en prueba de carga; quiebre 19 streams/GPU
Holgura y mínimo de nodos	20% / 2 por tipo	[SUP]	Proteger latencia y alta disponibilidad en 2 zonas
GPU g6.xlarge	US$ 1,0216/h (comprometida 0,8313)	[AWS]	DoiT, eu-west-2
CPU c7i.xlarge	US$ 0,2121/h (Savings Plan 0,1605)	[AWS]	DoiT / Holori, eu-west-2
LLM Amazon Nova Lite	US$ 0,06 / 0,24 por millón de tokens, +20% regional	[AWS] + [SUP]	Precio publicado US; recargo regional supuesto (Nova Lite opera in-region en Londres)
Tokens por llamada	2 invocaciones × (1.500 entrada + 300 salida)	[SUP]	Una explicación y un resumen por llamada
Audio	64 kbps, retención 30 días	[SUP]	Calidad telefónica; minimización UK GDPR
S3 / SQS / API Gateway	US$ 0,024/GB · US$ 0,40/M · US$ 3,50/M	[AWS]	Precios Londres publicados

Parámetro	Valor	Origen	Justificación / fuente
Requests por llamada	216 SQS · 20 API	[SUP]	Segmentos de 10 s, 2 colas, 3 operaciones por mensaje
Soporte AWS	Business Support+ 9/7/5/3%	[AWS]	Tabla oficial de AWS Support
Contingencia OPEX / CAPEX	10% / 15%	[SUP]	Servicios no modelados / error de estimación
MLOps	1 FTE	[SUP]	Monitoreo, reentrenamiento y guardia; quiebre 2,14 FTE
Shrinkage / ocupación	30% / 85%	[MERCADO]	Call Centre Helper (rangos 30–35% y 80–85%)
ARPU base	US$ 65/seat/mes	[MERCADO]	Google US$ 50–60, Sentient US$ 65, Observe.AI US$ 89
Salario agente UK	£23.500/año	[MERCADO]	Pertemps 2026
Realización del ahorro TTR	50%	[SUP]	No todas las horas liberadas reducen dotación
Adopción	30/60/85/100/100%	[SUP]	Rampa comercial de 4 años
Tasa de descuento	12,34%	[MERCADO] + [SUP]	Damodaran 9,34% + premio de innovación 3 pp
Impuesto	25%	[MERCADO]	UK corporation tax, Finance Act 2025

Fuente: registro del equipo; Elaborado por el Grupo 2 con asistencia de IA (Claude Opus, Anthropic); revisado por el equipo.

Anexo B. Equivalencia de servicios Azure ↔ AWS usada para costear

Tabla 20. *Servicio del caso (Azure) y equivalente de referencia (AWS)*

Componente del caso (Azure)	Equivalente AWS usado para el precio	Unidad de cobro
Instancias GPU/CPU en AKS	EC2 g6.xlarge (GPU NVIDIA L4) y c7i.xlarge	Hora de instancia
Azure OpenAI	Amazon Bedrock – Nova Lite	Millón de tokens
Azure Blob Storage + SAS URLs	Amazon S3 Standard + URLs prefirmadas	GB-mes y solicitudes
Azure Service Bus	Amazon SQS	Millón de solicitudes
Azure API Management	Amazon API Gateway (REST)	Millón de llamadas
Soporte Microsoft Unified	AWS Business Support+	% del gasto mensual

Fuente: instrucción de la cátedra de usar precios AWS como referencia; elaboración propia.

La arquitectura se mantiene íntegramente en Azure, como exige el caso. Los precios de AWS se usan solo como referencia de mercado verificable; las tarifas de Azure para servicios equivalentes son del mismo orden de magnitud, y la diferencia queda cubierta por la contingencia y el análisis de sensibilidad.

Anexo C. Especificación de servicios, protocolos y mapeo del pipeline

C.1 Especificación de los servicios de inferencia

Contratos de los servicios de inferencia

Tabla 21. *Interfaces expuestas*

Servicio / endpoint	Protocolo	Entrada	Salida	SLO
InferenceStream.Analyze	gRPC bidireccional	call_id, ventana PCM 16 kHz (2 s)	top-3 causas, efecto estimado, p(churn), versión de modelo	p95 < 250 ms; disponibilidad 99,9%
POST /v1/explanations	AMQP (cola explain-requests)	call_id, causas, rasgos agregados (sin PII)	Texto explicativo y resumen	p95 < 5 s (asíncrono)
GET /v1/calls/{id}/insights	HTTPS/REST vía APIM	call_id + JWT	Historial de insights y explicación	p95 < 300 ms
GET /healthz, /readyz	HTTP	—	Estado del pod y del modelo cargado	Usado por AKS

Manejo de errores y fallbacks

Tabla 22. *Estrategia ante fallas*

Falla	Detección	Respuesta
Inferencia excede el presupuesto de 250 ms	Latency Guard (temporizador por ventana)	Entrega el último insight válido marcado como «provisional»; registra evento
Azure OpenAI no disponible o con throttling (429)	Código HTTP / timeout	Reintento con backoff exponencial (3×); luego DLQ; el operador conserva el insight causal
Mensaje corrupto o no procesable	Excepción de deserialización	Dead-letter queue + alerta; no bloquea la cola
Caída de un pod o nodo GPU	Readiness probe / AKS	Reprogramación automática; mínimo 2 nodos por pool en 2 zonas
Modelo nuevo degrada métricas	Canario: p95 y error vs. versión estable	Rollback automático a la versión anterior del registro
Drift de datos	PSI > 0,2 en rasgos prosódicos	Alerta al equipo MLOps y nuevo ciclo de entrenamiento

Telemetría y auditoría

- **Métricas:** latencia por componente (p50/p95/p99), throughput de llamadas concurrentes, tasa de fallback, tasa de error, uso de GPU, profundidad de colas.
- **Trazas distribuidas** con OpenTelemetry desde el Media Ingest hasta el escritorio, correlacionadas por call_id.
- **Auditoría inmutable:** cada insight registra versión de modelo, versión del DAG, causas entregadas y marca de tiempo (tabla append-only en PostgreSQL), para explicar cualquier decisión ante el cliente o un regulador.

Despliegue y escalamiento

Las imágenes Docker se construyen en GitHub Actions y se publican en Azure Container Registry. El despliegue en AKS es **canario** (10% del tráfico durante 30 minutos y luego 100% si se cumplen los SLO). El escalamiento horizontal usa **KEDA** sobre la profundidad de las colas de Service Bus y el número de streams activos, con un mínimo de 2 nodos por pool para alta disponibilidad.

C.2 Protocolos de comunicación y mapeo del pipeline

Tabla 23. *Protocolos de comunicación*

Origen → Destino	Protocolo	Motivo
CCaaS → Media Ingest Gateway	gRPC bidireccional / WebSocket sobre TLS 1.3	Streaming de audio de baja latencia
Media Ingest → Servicio de Inferencia	gRPC (HTTP/2)	Serialización binaria, menor overhead que REST
Inferencia → Escritorio del agente	WebSocket (WSS) vía Azure Web PubSub	Empuje del insight sin polling
Escritorio → APIM → servicios	HTTPS/REST + JWT (OIDC)	Consultas y tableros
Inferencia → Worker de explicación	AMQP 1.0 (Azure Service Bus)	Desacople asíncrono, reintentos y DLQ
Worker → Azure OpenAI	HTTPS/REST (Private Endpoint)	Generación de explicaciones sin exponer PII
Servicios → Blob Storage	HTTPS con SAS de delegación de usuario	Acceso temporal y de mínimo privilegio a audios

Tabla 24. *Mapeo completo del pipeline: etapa, entradas, salidas y servicio*

#	Etapa	Entrada → Salida	Servicio Azure	Control de calidad
A1	Ingesta	Audios + etiquetas CRM → dataset crudo	Blob Storage (SAS), Data Factory	Conteo y esquema
A2	Validación y anonimización	Dataset crudo → dataset limpio sin PII	Azure ML (job), Presidio	Reglas de calidad; 0 PII
A3	Ingeniería de atributos	Audio → rasgos eGeMAPS + embeddings	Azure ML Compute	Distribuciones vs. línea base
A4	Descubrimiento del DAG	Rasgos + conocimiento experto → DAG	Azure ML (DoWhy, causal-learn)	Revisión experta del grafo
A5	Estimación causal	DAG + datos → efectos (ATE/CATE)	Azure ML (DoWhy, EconML DML)	Refutadores (placebo, causa común aleatoria)
A6	Evaluación (gate)	Modelos → aprobado / rechazado	Azure ML	Error ATE ≤ 0,05 en datos con verdad conocida
A7	Registro	Modelo aprobado → versión registrada	Azure ML Model Registry	Linaje: datos, código, métricas
A8	CI/CD	Código + modelo → imagen Docker	GitHub Actions, ACR	Pruebas unitarias, cobertura ≥ 80%
A9	Despliegue canario	Imagen → AKS 10% → 100%	AKS	p95 < 250 ms y error < 1% en canario
B1–B5	Inferencia en línea	Audio → insight al operador	AKS (GPU/CPU), Web PubSub	Latencia p95 por ventana
C1–C3	Ruta asíncrona y errores	Solicitud → explicación / DLQ	Service Bus, Azure OpenAI	Reintentos 3×, DLQ monitoreada
C4	Fallback	Timeout → último insight válido	Servicio de inferencia	Tasa de fallback < 2%
C5–C6	Telemetría, auditoría y drift	Eventos → métricas, alertas, reentrenamiento	App Insights, PostgreSQL, Azure ML	Alerta si PSI > 0,2

Fuente: elaboración propia del Grupo 2; Elaborado por el Grupo 2 con asistencia de IA (Claude Opus, Anthropic); revisado por el equipo.