UNIVERSIDAD TECNOLÓGICA METROPOLITANA
Facultad de Ingeniería · Escuela de Informática y Computación
Gestión de Proyectos Informáticos (GPI) 2026-II · Sección 411

CASO DE ESTUDIO PIA · TALLER CORREGIDO

Vox-Causal AI en Alloxentric SpA

Arquitectura C4, pipeline MLOps e Informe de Evaluación Técnica y Económica (ERV) para la integración de inferencia causal multimodal en la plataforma omnicanal

GO	US$ 366.751	91,9%	175 ms
condicionado	VAN después de impuestos	TIR después de impuestos	latencia p95 (meta < 250 ms)

Tabla 1. *Datos del informe*

Campo	Detalle
Organización evaluada	Alloxentric SpA – operación en Londres, Reino Unido (directorio destinatario)
Integrantes (Grupo 2)	Giovanni Gabrielli · Martín Vera · Aylin Strajilevich · Cristóbal Muñoz
Profesor	Dr. Oscar Magna Veloso
Versión	v2.0 – corregida según retroalimentación del taller (datos fundamentados, siglas definidas, C4 iniciando por el Nivel 2)
Repositorio	github.com/GiovanniGabrielli33/gpi-411-grupo2-voxcausal · carpeta /docs/erv
Fecha	Santiago, noviembre de 2026

Fuente: Grupo 2.

Índice

Glosario de siglas **3**

Resumen ejecutivo **4**

Parte I. Arquitectura C4 y pipeline MLOps **5**

I.1 Diagrama de Arquitectura C4 – Nivel 2 5

I.2 Diagrama de Arquitectura C4 – Nivel 1 6

I.3 Diagrama de Arquitectura C4 – Nivel 3 7

I.4 Pipeline MLOps 8

Parte II. Informe ERV **9**

1. Contexto y alcance 9

2. Evaluación técnica 10

3. Beneficios 11

4. Costos 12

5. Evaluación económica 14

6. Viabilidad y sostenibilidad 15

7. Plan de implementación y riesgos 16

8. Conclusiones y recomendación ejecutiva 18

Referencias **19**

Anexo A. Supuestos y fuentes **21**

Anexo B. Equivalencia Azure ↔ AWS usada para costear **22**

Anexo C. Contratos de servicio, fallos y evidencia del repositorio **23**

Anexo D. Cálculo del ejemplo de confusión **24**

Anexo E. Valor ganado (SPI y CPI) **25**

Glosario de siglas

Cada sigla se define además en su primera aparición en el texto. Las etiquetas de origen de los datos ([CASO], [AWS], [MERCADO], [SUP]) se explican en el Anexo A.

Tabla 2. *Siglas utilizadas en el informe*

Sigla	Significado	Sigla	Significado
AHT	Average Handle Time: tiempo medio de atención de una llamada	FTE	Full-Time Equivalent: jornada completa equivalente
AKS	Azure Kubernetes Service: orquestador de contenedores de Azure	GDPR	General Data Protection Regulation (UK GDPR en Reino Unido)
AMQP	Advanced Message Queuing Protocol: protocolo de mensajería de Service Bus	GPU	Graphics Processing Unit: acelerador de inferencia
AP / AR	Avance físico Programado / Avance físico Real (% acumulado)	gRPC	Llamada a procedimiento remoto sobre HTTP/2 con mensajes binarios
APIM	Azure API Management: puerta de enlace de APIs	HH	Horas-hombre
ATE	Average Treatment Effect: efecto causal promedio	IRF	Índice de Ritmo Físico = ΔAR semanal / ΔAP semanal
B/C	Relación beneficio/costo a valor presente	JWT	JSON Web Token: credencial firmada de acceso
CAPEX	Capital Expenditure: inversión inicial	KPI	Key Performance Indicator: indicador clave
CATE	Conditional ATE: efecto causal por segmento	LLM	Large Language Model: modelo de lenguaje (Azure OpenAI)
CCaaS	Contact Center as a Service: telefonía en la nube del cliente	MLOps	Prácticas para operar modelos de ML en producción
CI/CD	Integración y despliegue continuos	ONNX	Open Neural Network Exchange: formato de modelo optimizado
CPI / SPI	Índices de desempeño de costo y de plazo (valor ganado)	OPEX	Operational Expenditure: gasto operacional recurrente
CRM	Customer Relationship Management	p95	Percentil 95: valor bajo el cual cae el 95% de las mediciones
CSAT	Customer Satisfaction: satisfacción del cliente	PII	Personally Identifiable Information: datos personales
CX	Customer Experience: experiencia de cliente	PSI	Population Stability Index: indicador de drift de datos
DAG	Directed Acyclic Graph: grafo causal dirigido acíclico	SAS	Shared Access Signature: URL de acceso temporal a Blob Storage
DLQ	Dead-Letter Queue: cola de mensajes fallidos	SCM	Structural Causal Model: modelo causal estructural
DML	Double Machine Learning: método de estimación causal de EconML	SLA / SLO	Acuerdo / objetivo de nivel de servicio
DPIA	Data Protection Impact Assessment (evaluación de impacto UK GDPR)	SQALE	Método de SonarQube que mide la deuda técnica en tiempo de corrección
EBITDA	Resultado operacional antes de intereses, impuestos y amortización	TIR	Tasa Interna de Retorno
EDT	Estructura de Desglose del Trabajo	TLS	Transport Layer Security: cifrado en tránsito
eGeMAPS	Conjunto estándar de 88 rasgos acústicos de voz (openSMILE)	TTR	Time to Resolution: tiempo de resolución del caso del cliente
ERV	Evaluación técnica y económica del proyecto (informe del caso)	VAN	Valor Actual Neto
EVM	Earned Value Management: gestión del valor ganado	WACC	Costo promedio ponderado de capital
FCL	Flujo de Caja Libre	WSS	WebSocket seguro sobre TLS
FCR	First Contact Resolution: resolución al primer contacto		

Fuente: elaboración propia del Grupo 2.

Resumen ejecutivo

Alloxentric SpA solicitó evaluar si conviene financiar e integrar en su plataforma omnicanal el prototipo **Vox-Causal AI**, que identifica durante la llamada la **causa raíz** de la insatisfacción del cliente y su riesgo de fuga, combinando el análisis prosódico de la voz con Modelos Causales Estructurales (SCM, por su sigla en inglés). El informe tiene dos partes: la **Parte I** presenta la arquitectura de integración en Azure con el modelo C4 y el pipeline de operación de modelos (MLOps); la **Parte II** es el Informe ERV con la evaluación técnica, los beneficios, los costos, la evaluación económica, la sostenibilidad, el plan de implementación y la recomendación al directorio.

US$ 69.835	US$ 281.383	1,54	2,02 años
CAPEX (inversión)	OPEX anual a plena adopción	relación B/C	payback descontado

Tabla 3. *Indicadores clave de la evaluación*

Indicador	Meta o resultado	Lectura
Latencia de inferencia	Meta < 250 ms [CASO] · diseño p95 175 ms	Incidente resuelto con D1–D6; 75 ms de holgura
Concurrencia	1.500 llamadas simultáneas [CASO]	36 GPU y 12 nodos CPU en el pico, con autoescalado
Precisión causal	Error de ATE ≤ 0,05 [CASO]	Puerta de calidad del pipeline antes de publicar un modelo
VAN después de impuestos (tasa 12,34%)	**US$ 366.751**	**El proyecto crea valor en el escenario base**
TIR / payback simple / B/C	91,9% / 1,82 años / 1,54	La inversión se recupera durante el año 2
Valor para el cliente	Ahorro de US$ 7,37 millones al año	US$ 13,2 de ahorro por cada US$ 1 de recargo
Escenario pesimista	VAN −US$ 215.937 · B/C 0,71	El valor depende del precio y de la adopción

Fuente: secciones 3 a 5 de la Parte II; Anexo A.

Recomendación: GO CONDICIONADO

Se recomienda al directorio en Londres aprobar la integración por fases, sujeta a cuatro condiciones verificables: **(C1)** error de ATE ≤ 0,05 con datos reales; **(C2)** latencia p95 < 250 ms con 1.500 llamadas y al menos 19 streams por GPU; **(C3)** evaluación de impacto (DPIA) aprobada y análisis exclusivo de la voz del cliente; **(C4)** piloto que confirme un recargo ≥ 13,1% y una adopción ≥ 52% de la rampa (sección 8).

Nota metodológica. Por instrucción de la cátedra, los costos de infraestructura se estimaron con precios públicos de Amazon Web Services (AWS) en Londres (eu-west-2) para el servicio equivalente a cada componente Azure del caso (Anexo B). Los montos están en dólares estadounidenses (US$). Cada dato lleva una etiqueta de origen: [CASO] enunciado, [AWS] precio público, [MERCADO] fuente externa citada y [SUP] supuesto del equipo sometido a sensibilidad (Anexo A).

Parte I

Parte I. Arquitectura C4 y pipeline MLOps

Diseño de integración de Vox-Causal AI en la plataforma Azure de Alloxentric (región UK South, AKS).

La solución se describe con el **modelo C4** de Simon Brown (Brown, 2026), que representa un sistema en niveles de zoom. Por indicación del profesor, se presenta primero el **Nivel 2 (contenedores)**, que muestra las tecnologías y protocolos de integración; luego el Nivel 1 (contexto) y el Nivel 3 (componentes del servicio de inferencia). La arquitectura sigue tres principios: **(1)** separar el camino crítico, de modo que todo lo que debe responder en menos de 250 ms corra en un servicio síncrono y liviano, y lo lento (Azure OpenAI, auditoría) vaya por colas; **(2)** aislar el entrenamiento (por lotes en Azure ML) de la inferencia en tiempo real; y **(3)** seguridad y observabilidad por diseño (TLS 1.3, SAS de delegación de usuario, OpenTelemetry).

I.1 Diagrama de Arquitectura C4 – Nivel 2

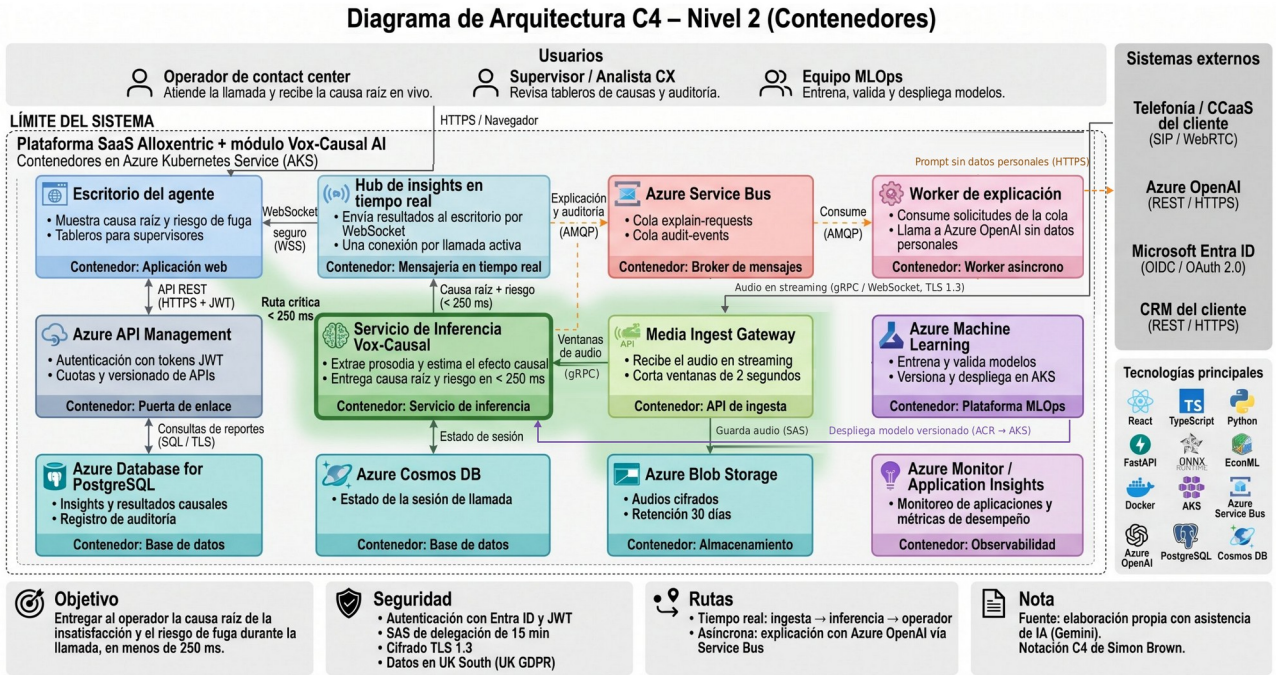


Figura 1. *Diagrama de Arquitectura C4 – Nivel 2 (contenedores, tecnologías y protocolos).* Elaborado por el Grupo 2 con asistencia de IA (Gemini, Google); revisado por el equipo.

El flujo crítico es **CCaaS → Media Ingest Gateway → Servicio de Inferencia → Web PubSub → escritorio del agente**. Las explicaciones en lenguaje natural siguen la ruta Servicio de Inferencia → Service Bus → Worker → Azure OpenAI, que nunca bloquea al operador. La Tabla 4 detalla cada contenedor.

Tabla 4. *Contenedores, tecnologías y protocolos*

Contenedor	Tecnología	Responsabilidad	Protocolo de entrada / salida
Escritorio del agente	React + TypeScript	Mostrar causa raíz, riesgo de fuga y guion sugerido	WSS (recibe insights) · HTTPS/REST (consultas)
Azure API Management	Gateway gestionado	Autenticación JWT (Entra ID), cuotas y versionado	HTTPS/REST + JWT
Media Ingest Gateway	Python FastAPI · Docker en AKS	Recibir audio, crear ventanas de 2 s, copiar a Blob y enrutar	gRPC/WebSocket sobre TLS 1.3 desde el CCaaS · gRPC hacia inferencia
Servicio de Inferencia	FastAPI · ONNX Runtime GPU · EconML	Prosodia e inferencia causal en línea (p95 < 250 ms)	gRPC (HTTP/2) · publica por Web PubSub

Contenedor	Tecnología	Responsabilidad	Protocolo de entrada / salida
Azure Web PubSub	WebSocket gestionado (PaaS)	Empujar insights a miles de escritorios sin polling	WSS
Azure Service Bus	Colas y tópicos con DLQ	Desacoplar explicaciones y auditoría	AMQP 1.0
Worker de explicación	Python · Docker en AKS	Llamar a Azure OpenAI con prompts sin PII	AMQP (entrada) · HTTPS por Private Endpoint
Azure OpenAI	LLM gestionado	Redactar la explicación (no decide la causa)	HTTPS/REST
Azure Blob Storage	Objetos cifrados	Audio de llamadas, retención 30 días	HTTPS + SAS de delegación (15 min)
Azure Cosmos DB	NoSQL de baja latencia	Estado de sesión de cada llamada	HTTPS (SDK)
PostgreSQL Flexible	Relacional gestionado	Insights e historial de auditoría inmutable	TLS (protocolo PostgreSQL)
Azure Machine Learning	Pipelines + Model Registry	Entrenar, validar y versionar modelos	HTTPS (SDK)
Azure Monitor / App Insights	OpenTelemetry	Latencia p95, errores, drift y alertas	OTLP/HTTPS

Fuente: elaboración propia del Grupo 2 a partir del caso PIA y de la documentación de Microsoft Learn.

I.2 Diagrama de Arquitectura C4 – Nivel 1

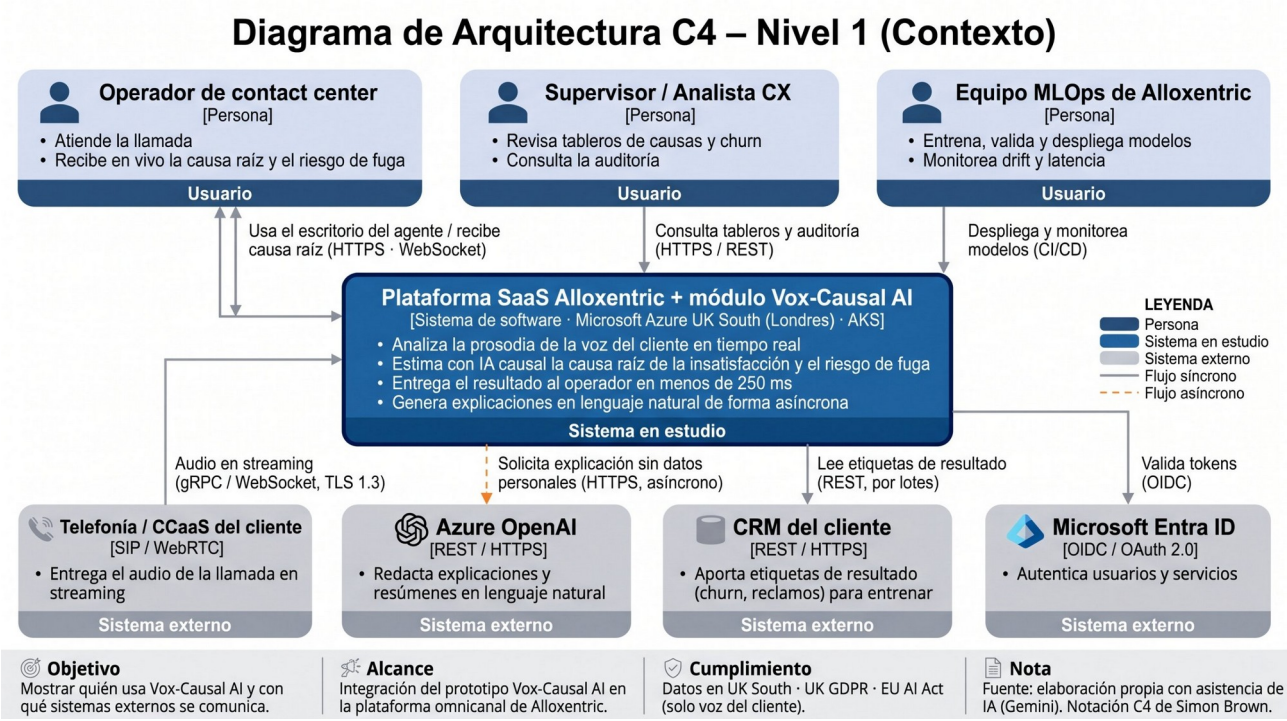


Figura 2. *Diagrama de Arquitectura C4 – Nivel 1 (contexto del sistema).* Elaborado por el Grupo 2 con asistencia de IA (Gemini, Google); revisado por el equipo.

Actores: el operador del contact center (recibe la causa raíz y el riesgo de fuga), el supervisor o analista de experiencia de cliente (CX) y el equipo MLOps. **Sistemas externos:** la telefonía en la nube del cliente (CCaaS), el CRM, Azure OpenAI (solo redacta explicaciones) y Microsoft Entra ID (identidad).

I.3 Diagrama de Arquitectura C4 – Nivel 3

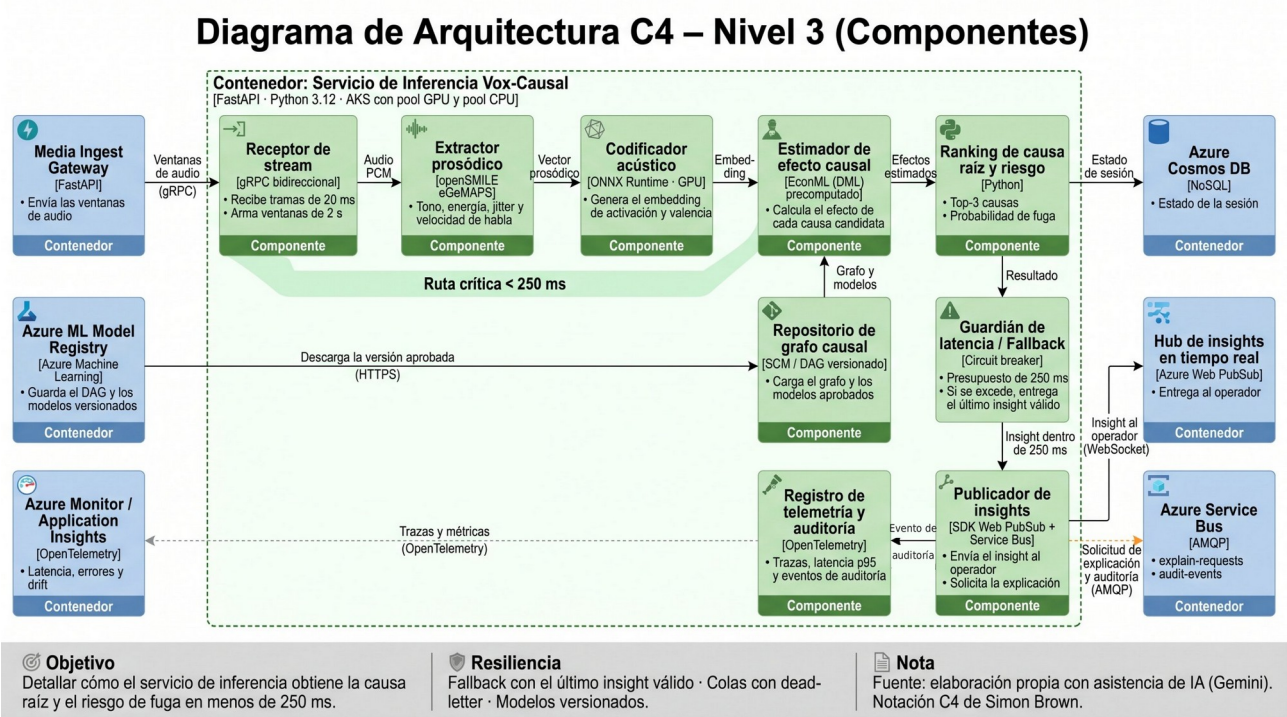
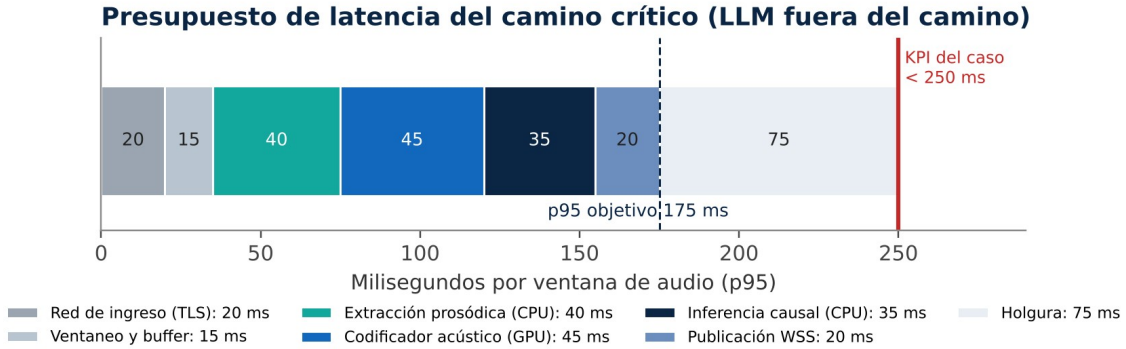


Figura 3. *Diagrama de Arquitectura C4 – Nivel 3 (componentes del Servicio de Inferencia).* Elaborado por el Grupo 2 con asistencia de IA (Gemini, Google); revisado por el equipo.

El **receptor de stream** agrupa tramas de 20 ms en ventanas de 2 s; el **extractor prosódico** calcula el conjunto eGeMAPS con openSMILE (Eyben et al., 2016); el **codificador acústico** (ONNX en GPU) produce un vector de rasgos; el **estimador de efecto causal** evalúa modelos EconML DML precalculados sobre el DAG del repositorio de grafos; el **ranking** entrega las tres causas más probables y la probabilidad de fuga; el **guardián de latencia** activa un fallback si se agota el presupuesto, y el **registro de telemetría** guarda cada decisión para auditoría.

Presupuesto de latencia. La referencia es la conversación humana: según la Recomendación ITU-T G.114, un retardo en un sentido menor a 150 ms es transparente para la mayoría de las aplicaciones de voz (ITU-T, 2003). El camino crítico suma **175 ms en p95**, con 75 ms de holgura bajo la meta de 250 ms del caso: red 20, ventaneo 15, prosodia en CPU 40, codificador en GPU 45, estimación causal 35 y entrega por WSS 20 ms.



Fuente: asignación de presupuesto del equipo por componente; a validar con prueba de carga de 1.500 llamadas concurrentes.
Elaborado por el Grupo 2 (Sección 411) con asistencia de IA: Claude Opus (Anthropic).

Figura 4. *Presupuesto de latencia del camino crítico por ventana de audio (ms, p95).* Elaborado por el Grupo 2 con asistencia de IA (Claude, Anthropic); revisado por el equipo.

I.4 Pipeline MLOps

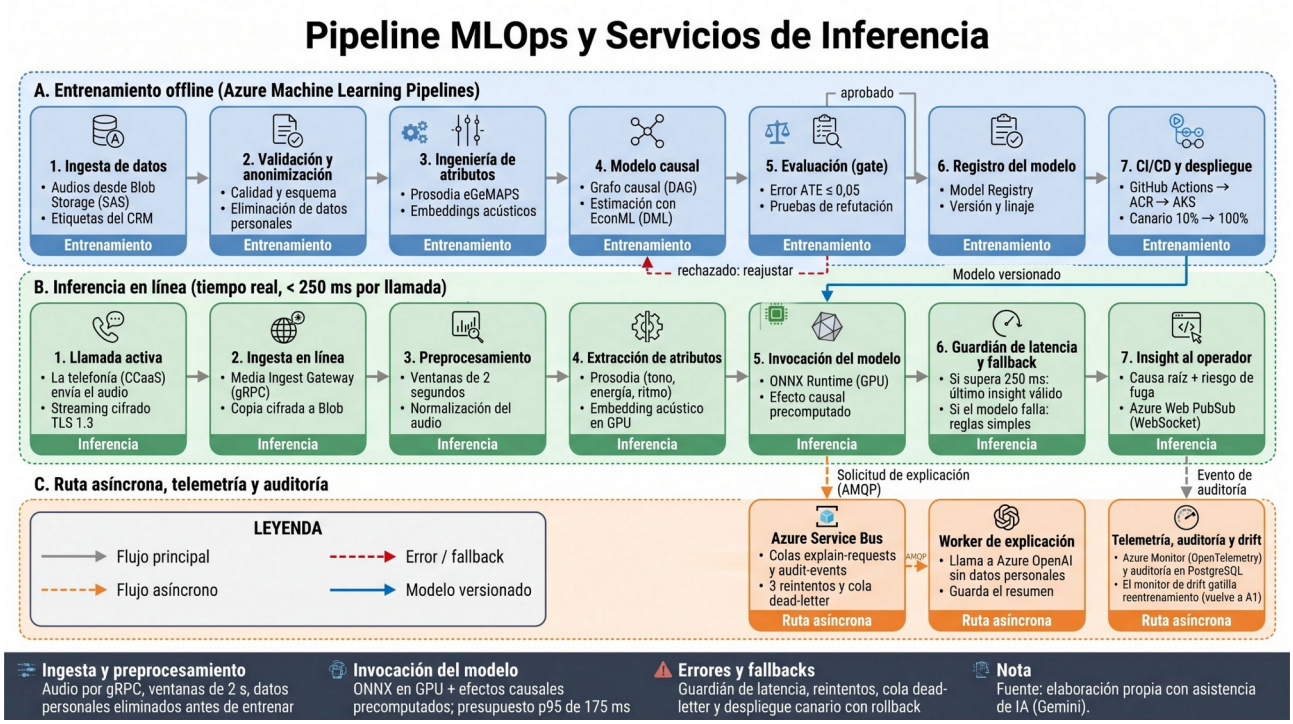


Figura 5. *Pipeline MLOps de Vox-Causal AI: entrenamiento, inferencia en línea y ruta asíncrona.* Elaborado por el Grupo 2 con asistencia de IA (Gemini, Google); revisado por el equipo.

El pipeline tiene tres carriles. **A – Entrenamiento por lotes** en Azure ML: ingesta, validación y anonimización, ingeniería de atributos, modelo causal, evaluación con puerta de calidad (error de ATE ≤ 0,05), registro y despliegue canario. **B – Inferencia en línea** por llamada: llamada, ingesta, preprocesamiento, extracción de atributos, invocación, guardián de latencia e insight al operador. **C – Ruta asíncrona**: Service Bus, worker de explicación y telemetría, auditoría y detección de drift, que gatilla un nuevo entrenamiento. Los carriles A y B solo se conectan a través del modelo aprobado en el registro.

Tabla 5. *Elementos del pipeline exigidos por la pauta*

Elemento	Cómo se implementa	Servicio / tecnología	Control
Ingesta	Audio por gRPC/WebSocket en ventanas de 2 s (línea); audios y etiquetas del CRM (lotes)	Media Ingest Gateway; Blob Storage con SAS de 15 min	Esquema y conteo de ventanas
Preprocesamiento	Normalización a 16 kHz, detección de voz, separación del canal del cliente, seudonimización	FastAPI; Azure ML jobs; Presidio (PII)	0 PII en datos de entrenamiento
Invocación del modelo	Rasgos eGeMAPS + codificador ONNX en GPU + efectos EconML precalculados	Servicio de Inferencia en AKS (gRPC)	p95 < 250 ms por ventana
Errores y fallbacks	Timeout → último insight válido marcado «provisional»; reintentos 3× con backoff; DLQ; rollback canario	Guardián de latencia; Service Bus; AKS	Tasa de fallback < 2%
Telemetría y auditoría	Trazas por call_id; registro inmutable de versión de modelo y DAG; drift por PSI	Azure Monitor/App Insights; PostgreSQL; Azure ML	Alerta si PSI > 0,2

Fuente: elaboración propia del Grupo 2; detalle de contratos y fallos en el Anexo C.

Parte II

Parte II. Informe ERV

Evaluación técnica y económica para el directorio de Alloxentric SpA en Londres.

1. Contexto y alcance

1.1 Alloxentric y su misión omnicanal

Alloxentric fue fundada en Chile en 2018 por Max Kreimerman y desarrolla **Xentric**, una plataforma omnicanal que integra voz, chat, correo y mensajería con analítica de experiencia de cliente (Alloxentric, 2026). La empresa reportó procesar del orden de **1 millón de contactos al día** (Digital Catapult, 2021); la analítica CX es su servicio de mayor éxito en Chile y México, y en junio de 2023 anunció su expansión al Reino Unido (The Fintech Times, 2023). El caso sitúa la operación en Londres, con la plataforma desplegada en Microsoft Azure.

Los modelos actuales del mercado son **correlacionales**: detectan sentimiento o tono, pero no explican *por qué* el cliente está insatisfecho ni qué acción reduciría su riesgo de fuga. Vox-Causal AI aborda ese vacío con un grafo causal (DAG) sobre causas operativas de la llamada (transferencias, esperas, errores de cobro), ajustado por confusores como el historial de contacto, más los rasgos prosódicos medidos en vivo.

Por qué causal. En un ejemplo verificable a mano (Anexo D), los clientes que ya habían llamado antes son transferidos más a menudo y además se fugan más por sí solos. El efecto real de una transferencia es +8 puntos porcentuales (pp), pero la comparación directa atribuye **15,1 pp**, con un error de ATE de **0,071 > 0,05**. Solo un método causal cumple la meta de precisión del caso.

1.2 Estado del arte

Tabla 6. *Soluciones comparables en producción*

Solución / caso	Qué hace	Resultado reportado	Brecha frente a Vox-Causal
Cogito en MetLife (EE. UU.)	Analiza tono y ritmo en vivo y sugiere ajustes al agente	+13% satisfacción; +3,5% resolución al primer contacto	Detecta cómo suena la llamada, no por qué
Microsoft Copilot for Service	Asistente de agentes con IA generativa	−12% de AHT (acceso anticipado, 2023)	Recomienda contenido; no atribuye causa
Google Agent Assist (TTEC, YouTube)	Sugerencias de conocimiento y resúmenes en vivo	TTEC −11% de AHT; YouTube −23%	Correlacional; no estima efectos
Five9 Agent Assist (TruConnect)	Transcripción y notas automáticas	−30 s de AHT en tres meses	Automatiza documentación; no diagnostica
Uber CausalML · Microsoft EconML	Librerías de ML causal (ATE/CATE)	Uso en producción para focalizar campañas	Procesamiento por lotes, no streaming de voz

Fuente: Best Practice AI (s. f.); CX Today (2023); Google Cloud (2024); Business Wire (2021); Uber Technologies (2026).

Las reducciones de AHT reportadas (11% a 23%) hacen plausible la reducción de 15% del TTR del caso. Ninguna solución revisada estima efectos causales en vivo: esa es la diferenciación que sostiene el recargo de 20%. Además, desde el 2 de febrero de 2025 el EU AI Act (art. 5.1.f) prohíbe el reconocimiento de emociones de trabajadores, por lo que el diseño analiza **solo la voz del cliente** (Lewis Silkin, 2025).

1.3 Alcance

Tabla 7. *Alcance de la evaluación*

Incluye	Excluye
Integración del prototipo en Azure (APIM, Service Bus, Blob con SAS, Azure OpenAI), AKS en UK South	Rediseño de la plataforma Xentric o de los canales de texto y video
800 HH de desarrollo [CASO], OPEX cloud y MLOps a 5 años	Costos comerciales y de venta del recargo

Incluye	Excluye
KPI del caso: < 250 ms, 1.500 llamadas, error ATE ≤ 0,05, TTR −15%, recargo 20%	Mercados fuera de Reino Unido y Unión Europea
Cumplimiento UK GDPR y EU AI Act (solo voz del cliente)	Análisis de la voz del operador

Fuente: caso PIA (Magna, 2026); elaboración propia.

2. Evaluación técnica

2.1 Infraestructura y compatibilidad

El prototipo (Python 3.12, FastAPI, DoWhy/EconML) es compatible con la plataforma existente; los ajustes se resumen en la Tabla 8. La capacidad pico se dimensionó con **50 streams por GPU** [SUP] y **150 por nodo CPU**, con 20% de holgura: **36 GPU (NVIDIA L4) y 12 nodos CPU** para 1.500 llamadas simultáneas, con un mínimo de 2 nodos por tipo en dos zonas de disponibilidad.

Tabla 8. *Compatibilidad del prototipo con los servicios Azure de Alloxentric*

Servicio existente	Uso en Vox-Causal AI	Compat.	Ajuste requerido
Azure API Management	Publicar APIs de consulta de insights	Alta	Políticas JWT y cuotas para el nuevo producto
Azure Service Bus	Explicaciones asíncronas y auditoría	Alta	Colas explain-requests y audit-events con DLQ
Blob Storage + SAS	Audio de llamadas	Alta	SAS de delegación de usuario de 15 min, solo HTTPS
Azure OpenAI	Explicación en lenguaje natural	Media	Fuera del camino crítico; filtrar PII antes del prompt
Python 3.12 + FastAPI	Servicios del prototipo	Alta	Contenerizar (Docker) y agregar endpoints gRPC
DoWhy / EconML	Motor causal	Media	Precalcular efectos offline; en línea solo evaluar

Fuente: elaboración propia; Microsoft Learn (2026a, 2026b).

2.2 Incidente de latencia y seguridad

Incidente. El caso exige que la inferencia sobre el flujo prosódico responda en menos de 250 ms, que el prototipo se integre con la arquitectura existente (donde los audios se leen desde Blob Storage mediante SAS URLs) y que los datos de voz de clientes del Reino Unido cumplan UK GDPR. Conectado tal como funcionaba en el sandbox, el prototipo **no cumplía ni la meta de latencia ni los requisitos de seguridad**.

Causa raíz. El prototipo encadenaba en una sola solicitud componentes incompatibles con la meta: (1) la respuesta de Azure OpenAI crece con el número de tokens generados (Microsoft Learn, 2026b); (2) la estimación causal con DoWhy/EconML reajustaba modelos sobre todo el conjunto de datos, una operación por lotes; y (3) el acceso a los audios usaba SAS firmadas con la clave de la cuenta y de larga duración. Una SAS no cifra, es un token de autorización; el cifrado en tránsito lo aporta TLS (Microsoft Learn, 2026a).

Tabla 9. *Decisiones arquitectónicas frente al incidente*

#	Decisión	Por qué	Alternativa descartada
D1	Separar el camino crítico (síncrono) de la ruta asíncrona por Service Bus	Nada lento en la ruta en vivo; la latencia del LLM depende de los tokens	Una sola API que infiere y explica
D2	Efectos causales precalculados offline; en línea solo se evalúan	Evaluar ≈ 35 ms frente a reentrenar (minutos)	DoWhy/EconML completo en línea
D3	Codificador ONNX en GPU y transporte gRPC/WebSocket	Menor cómputo y serialización (45 ms por ventana)	PyTorch en CPU con REST/JSON
D4	SAS de delegación de usuario (Entra ID), solo HTTPS, 15 min, mínimo privilegio; TLS 1.3; UK South	Seguridad de los audios y UK GDPR	SAS con clave de cuenta y larga duración
D5	Aislar batch y tiempo real: node pools, subredes e identidades separados	El entrenamiento no compite con la API ni expone datos	Mismo clúster y colas compartidas
D6	Analizar solo el canal del cliente, seudonimizar y no enviar PII al LLM	UK GDPR y EU AI Act art. 5.1.f	Analizar ambas voces

Fuente: elaboración propia del Grupo 2; Microsoft Learn (2026a, 2026b); Lewis Silkin (2025).

Resultado y verificación. Con D1–D6 el camino crítico baja a **175 ms en p95** (Parte I, sección I.3). Se verifica con: (1) prueba de carga de una semana con 1.500 llamadas concurrentes, incluida en el CAPEX; (2) pruebas de seguridad (rechazo de HTTP y de TLS < 1.2, SAS que expira a los 15 minutos, escaneo de PII en los prompts); y (3) prueba de aislamiento: reentrenar durante la carga sin que el p95 varíe más de 5%. **Riesgo residual:** si cada GPU procesa menos streams que los 50 supuestos, el costo sube; el proyecto sigue siendo rentable sobre 19 streams por GPU (sección 5).

2.3 Métricas de calidad

Las métricas se alinean con el modelo de calidad de producto ISO/IEC 25010 (ISO, 2023). Para medirlas antes de la decisión, el equipo implementó un **prototipo del núcleo** (src/voxcausal en el repositorio, 161 líneas de código y 28 pruebas pytest) con los componentes del Nivel 3 que pueden probarse sin Azure: estimador causal, guardián de latencia, filtro de PII, ventaneo y política de acceso a audio. Las métricas que dependen de la infraestructura se medirán en la prueba de carga de la fase 1.

Tabla 10. *Métricas de calidad según ISO/IEC 25010: meta y valor medido*

Característica ISO 25010	Métrica	Meta	Valor medido	Estado
Adecuación funcional	Error de ATE (efecto real 8 pp, 200.000 llamadas sintéticas)	≤ 0,05 [CASO]	Sin ajuste: 0,071 Con ajuste backdoor: 0,0009	Cumple con ajuste; falta validar con datos reales (C1)
Eficiencia de desempeño	Latencia p95 con 1.500 llamadas	< 250 ms [CASO]	175 ms (presupuesto por tramo, verificado por prueba unitaria)	Cumple (estimado); se mide en prueba de carga
Fiabilidad	Respuestas en fallback / disponibilidad	< 2% / 99,9%	Guardián probado: fallback por lentitud y por error del modelo	Por medir en prueba de carga
Seguridad	PII en prompts; política de acceso a audio	0 casos; SAS ≤ 15 min, TLS ≥ 1.2, UK South	4 de 4 tipos de PII filtrados; 7 de 7 violaciones de política detectadas	Cumple
Mantenibilidad	Cobertura de pruebas (líneas y ramas)	≥ 80%	100% (152 sentencias, 34 ramas)	Cumple
Mantenibilidad	Deuda técnica (método SQALE)	≤ 4 h por incremento; ratio ≤ 5% (rating A)	0,3–1,5 h; ratio 0,4–1,9% (rating A)	Cumple (estimado)
Compatibilidad	Contratos de API gRPC/REST	100% de pruebas de contrato	Sin API publicada aún	Por medir en fase 1

Fuente: ISO/IEC 25010:2023; metas del caso PIA; mediciones del Grupo 2 sobre el prototipo (pytest-cov, ruff, pylint, radon), corte 04-nov-2026.

Cómo se estimó la deuda técnica. No se contó con un servidor SonarQube, por lo que se aplicó su mismo método (SQALE): el análisis estático con ruff y pylint encontró **9 code smells** (imports deprecados, captura genérica de excepciones, valores por defecto mutables); a cada uno se le asignó entre 2 y 10 minutos de corrección, el rango de esas reglas en SonarQube, lo que da 18 a 90 minutos. El ratio de deuda es esa cifra dividida por el costo de desarrollo (161 líneas × 30 min). Lo respaldan una complejidad ciclomática promedio de 2,25 (A), un índice de mantenibilidad A en todos los módulos y una nota pylint de 9,73/10. Como la deuda absoluta crece con el tamaño del código, la meta de 4 h se aplica **por incremento** y se complementa con el ratio ≤ 5% para el sistema completo.

2.4 Modularidad

Cada contenedor se despliega y escala por separado en AKS: el ingreso de audio, la inferencia y los workers pueden versionarse sin detener a los demás. El motor causal está detrás de un contrato gRPC estable, de modo que un nuevo DAG o modelo se publica por el registro de Azure ML sin cambiar el código del servicio. Las explicaciones y la auditoría se comunican solo por mensajes (Service Bus), lo que evita acoplamiento temporal con el LLM.

3. Beneficios

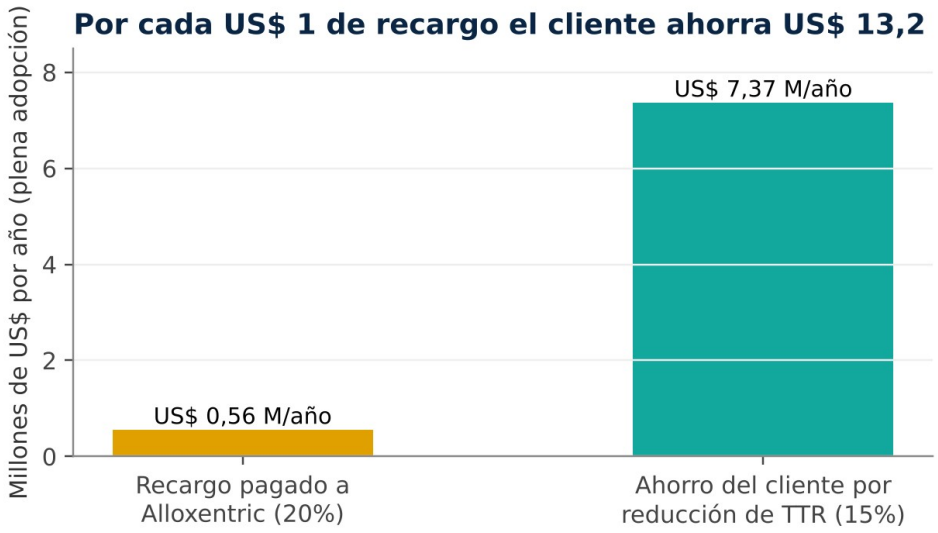
3.1 Reducción del TTR

Con un AHT de 6 min 10 s (Kayako, 2026) y un factor de carga de 31,8% [SUP], las 1.500 líneas pico equivalen a **80.100 horas de llamada por semana** (1.500 × 168 h × 31,8%), es decir **4,17 millones de horas al año** y unos **40,5 millones de llamadas**. Una reducción de 15% del TTR [CASO] libera **624.780 horas de agente**. Valoradas al costo de un agente UK (£23.500 anuales según Pertemps, 2026, más 30% de carga: **US$ 23,60/h**) y suponiendo que solo el 50% se convierte en ahorro de dotación [SUP], el ahorro de los clientes es de **US$ 7,37 millones al año**.

3.2 Recargo y resolución de casos

Ingreso para Alloxentric: recargo de 20% [CASO] sobre una suscripción base de US$ 65 por puesto al mes (Google US$ 50–60, Sentient US$ 65 y Observe.AI US$ 89) para **3.590 puestos**, derivados de la carga de llamadas con 30% de shrinkage y 85% de ocupación (Call Centre Helper): **US$ 560.027 al año** a plena adopción. El ahorro del cliente es **13,2 veces** el recargo (9,7 veces si la reducción fuera solo de 11%, como en TTEC). Ese ahorro no se suma como ingreso de Alloxentric, para no contarlo dos veces: es el argumento comercial del recargo.

Resolución al primer contacto (FCR). El promedio de la industria es 69% y cada punto de FCR reduce aproximadamente 1% el costo operacional y aumenta 1% la satisfacción (SQM Group, 2024). Si identificar la causa raíz eleva el FCR en 3 pp [SUP] (Cogito reportó +3,5%), el beneficio adicional para los clientes sería de **≈ US$ 2,9 millones al año**. Por prudencia, **no se incluye en el VAN**.



Fuente: caso PIA (TTR −15%, recargo 20%); salario agente UK (Pertemps); AHT 6:10 (Sprinklr); realización del ahorro 50% (supuesto).
Elaborado por el Grupo 2 (Sección 411) con asistencia de IA: Claude Opus (Anthropic).

Figura 6. *Ahorro anual del cliente frente al recargo pagado a Alloxentric, a plena adopción.* Elaborado por el Grupo 2 con asistencia de IA (Claude, Anthropic); revisado por el equipo.

3.3 Beneficios intangibles

- **Explicabilidad y auditoría:** cada insight registra el modelo, el DAG y el efecto estimado, lo que facilita responder a clientes y reguladores.
- **Cumplimiento por diseño:** solo voz del cliente, seudonimización y región UK South, condición para vender en la Unión Europea.
- **Diferenciación y reputación:** primera oferta causal en vivo del segmento (Tabla 6).
- **Activo de datos:** el grafo causal acumulado mejora con cada piloto y es difícil de copiar.

4. Costos

4.1 Horas-hombre y CAPEX

Las 800 HH del caso se valoran a **US$ 68,73/h**: salario de un ML Engineer en Reino Unido (£68.444, Glassdoor, 2026) más 30% de carga del empleador, 1.740 horas productivas al año y un tipo de cambio de 1,344 US$/£ (Pound Sterling Live, 2026).

Tabla 11. *Estructura de desglose del trabajo (EDT) en horas-hombre*

#	Paquete de trabajo	Semanas	HH	US$
1	Gestión, gobernanza y DPIA	S1–S10	60	4.124
2	Refactorización y contenerización del prototipo	S1–S4	150	10.310
3	Integración Azure (APIM, Service Bus, Blob SAS, Web PubSub)	S3–S7	150	10.310

#	Paquete de trabajo	Semanas	HH	US$
4	Pipeline MLOps y motor causal (Azure ML)	S2–S7	160	10.997
5	Seguridad y cumplimiento (SAS, TLS, UK GDPR)	S5–S8	90	6.186
6	Pruebas SQA y desempeño	S6–S10	120	8.248
7	Despliegue canario y transferencia	S9–S10	70	4.811
	Total	S1–S10	800	54.982

Fuente: 800 HH [CASO]; tarifa calculada por el equipo (Anexo A).

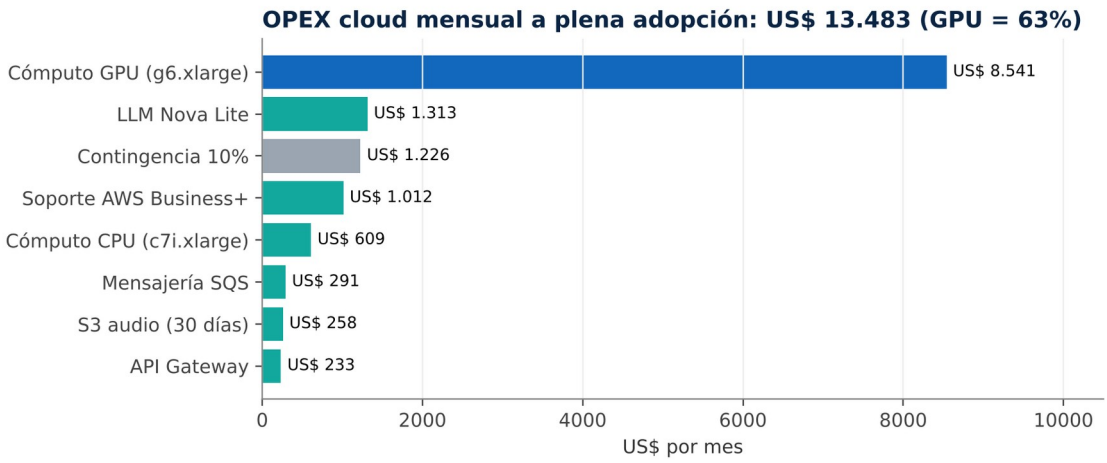
Tabla 12. *CAPEX*

Concepto	Cálculo	US$
Desarrollo e integración	800 HH × US$ 68,73	54.982
Contingencia	15% del desarrollo [SUP]	8.247
Prueba de carga a escala pico	168 h × (36 GPU + 12 CPU) on-demand [AWS]	6.606
Total CAPEX		69.835

Fuente: elaboración propia; precios AWS eu-west-2 (DoiT, 2026).

4.2 Cloud y mantenimiento (OPEX)

A plena adopción el OPEX cloud es **US$ 13.483 al mes**: GPU 8.541, CPU 609, soporte 1.012, LLM 1.313, almacenamiento 258, colas 291, API 233 y contingencia 1.226. El cómputo GPU representa el 63%. El mantenimiento del modelo requiere **1 FTE MLOps** (US$ 119.585 al año), que es el 42% del OPEX total. El costo por llamada es de **≈ US$ 0,004**.



Fuente: precios públicos AWS eu-west-2 (Londres) como referencia equivalente a Azure; volumen y capacidad según supuestos del Anexo A.
Elaborado por el Grupo 2 (Sección 411) con asistencia de IA: Claude Opus (Anthropic).

Figura 7. *Desglose del OPEX cloud mensual a plena adopción (US$).* Elaborado por el Grupo 2 con asistencia de IA (Claude, Anthropic); revisado por el equipo.

Tabla 13. *OPEX anual según adopción (US$)*

Concepto	Año 1	Año 2	Año 3	Año 4	Año 5
Adopción [SUP]	30%	60%	85%	100%	100%
Cloud	56.983	103.108	140.064	161.798	161.798
MLOps (1 FTE)	119.585	119.585	119.585	119.585	119.585
OPEX total	176.568	222.693	259.649	281.383	281.383

Fuente: modelo ERV del Grupo 2; precios AWS eu-west-2 (Anexo B).

5. Evaluación económica

Modelo anual a **5 años** sin valor terminal, después de impuestos (25%, UK corporation tax; Full Fact, 2026) con el CAPEX amortizado en 5 años (US$ 13.967 al año). **Tasa de descuento: 12,34%** = costo de capital del sector Software de Damodaran (enero 2026: 9,34%) más 3 pp de premio por riesgo de innovación [SUP].

Tabla 14. *Flujo de caja del proyecto, escenario base (US$)*

Concepto	Año 0	Año 1	Año 2	Año 3	Año 4	Año 5
Ingreso (recargo 20%)	—	168.008	336.016	476.023	560.027	560.027
OPEX	—	−176.568	−222.693	−259.649	−281.383	−281.383
EBITDA	—	−8.559	113.323	216.373	278.644	278.644
Impuesto (25%)	—	5.632	−24.839	−50.602	−66.169	−66.169
CAPEX	−69.835	—	—	—	—	—
Flujo de caja libre	**−69.835**	**−2.928**	**88.484**	**165.772**	**212.475**	**212.475**
Factor de descuento	1,0000	0,8902	0,7924	0,7053	0,6279	0,5589
FCL descontado acumulado	−69.835	−72.441	−2.329	114.596	248.000	366.751

Fuente: modelo ERV del Grupo 2; impuesto = 25% × (EBITDA − amortización).

Tabla 15. *Indicadores financieros del escenario base*

Indicador	Antes de impuestos	Después de impuestos
VAN (12,34%)	US$ 495.637	US$ 366.751
TIR	106,4%	91,9%
Payback simple	1,69 años	1,82 años
Payback descontado	1,86 años	2,02 años
Relación B/C = VP ingresos / VP costos	—	1,54 (1.416.173 / 920.536)

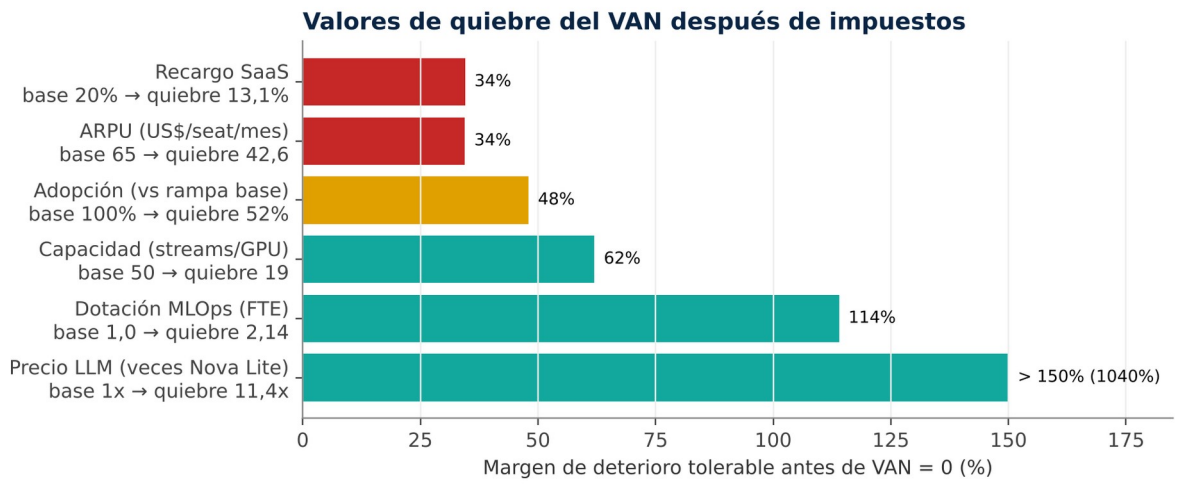
Fuente: modelo ERV del Grupo 2.

La inversión es pequeña frente al ingreso recurrente, por eso la TIR es alta y la decisión se apoya en el VAN, la relación B/C y la sensibilidad. Desde la perspectiva económica, que suma el ahorro de los clientes, el VAN sería de **US$ 17,7 millones** con una relación B/C de 20,25.

Tabla 16. *Indicadores por escenario (después de impuestos)*

Indicador	Pesimista	Base	Optimista
Supuestos	ARPU US$ 50 · adopción 15→80% · 25 streams/GPU	ARPU US$ 65 · adopción 30→100% · 50 streams/GPU · 1 FTE	ARPU US$ 89 · 100 streams/GPU · 0,5 FTE
VAN	−US$ 215.937	US$ 366.751	US$ 1.037.247
TIR	No se alcanza	91,9%	238%
Payback	> 5 años	1,82 años	0,65 años
B/C	0,71	1,54	3,53

Fuente: modelo ERV del Grupo 2.



Fuente: análisis de sensibilidad univariado del equipo sobre el modelo ERV; rojo = margen < 40% (riesgo crítico).
Elaborado por el Grupo 2 (Sección 411) con asistencia de IA: Claude Opus (Anthropic).

Figura 8. *Valores de quiebre: deterioro tolerable de cada variable antes de que el VAN sea cero.* Elaborado por el Grupo 2 con asistencia de IA (Claude, Anthropic); revisado por el equipo.

Valores de quiebre: recargo 13,1% (vs. 20%), ARPU US$ 42,6, adopción al 52% de la rampa, 19 streams por GPU, 2,14 FTE MLOps y un precio del LLM 11,4 veces mayor. La tasa de descuento casi no mueve el resultado: entre 9,34% y 15% el VAN va de US$ 412.935 a US$ 330.644.

6. Viabilidad y sostenibilidad

6.1 Escalabilidad

El escalamiento es horizontal: KEDA agrega pods según la profundidad de colas y los streams activos, y AKS agrega nodos. Como el costo cloud crece casi linealmente con las llamadas y el ingreso por puesto también, el margen se mantiene y el VAN crece con la escala.

Tabla 17. *Escalabilidad de la solución*

Concurrencia	GPU / CPU	Llamadas al mes	Cloud al mes (US$)	VAN (US$)
1.500 (caso)	**36 / 12**	**3,38 M**	**13.483**	**366.751**
3.000	72 / 24	6,75 M	26.404	1.130.610
4.500	108 / 36	10,13 M	39.299	1.893.628

Fuente: modelo ERV del Grupo 2, mismo perfil de demanda y 1 FTE MLOps.

6.2 Plan de mantenimiento

Tabla 18. *Plan de mantenimiento según ISO/IEC/IEEE 14764*

Tipo	Actividad	Frecuencia	Responsable
Correctivo	Atención de incidentes con SLA de 4 h [SUP]; rollback al modelo anterior del registro	Según evento	MLOps de guardia
Adaptativo	Actualización de librerías, imágenes Docker y versiones de AKS/Azure ML	Trimestral	Equipo de plataforma
Perfectivo	Reentrenamiento con datos nuevos y revisión experta del DAG	Mensual [SUP] o si PSI > 0,2	MLOps + analista CX
Preventivo	Pruebas de carga, revisión de costos cloud y de deuda técnica	Semestral	MLOps + arquitectura

Fuente: ISO/IEC/IEEE 14764:2022; supuestos del equipo (Anexo A).

7. Plan de implementación y riesgos

7.1 Fases

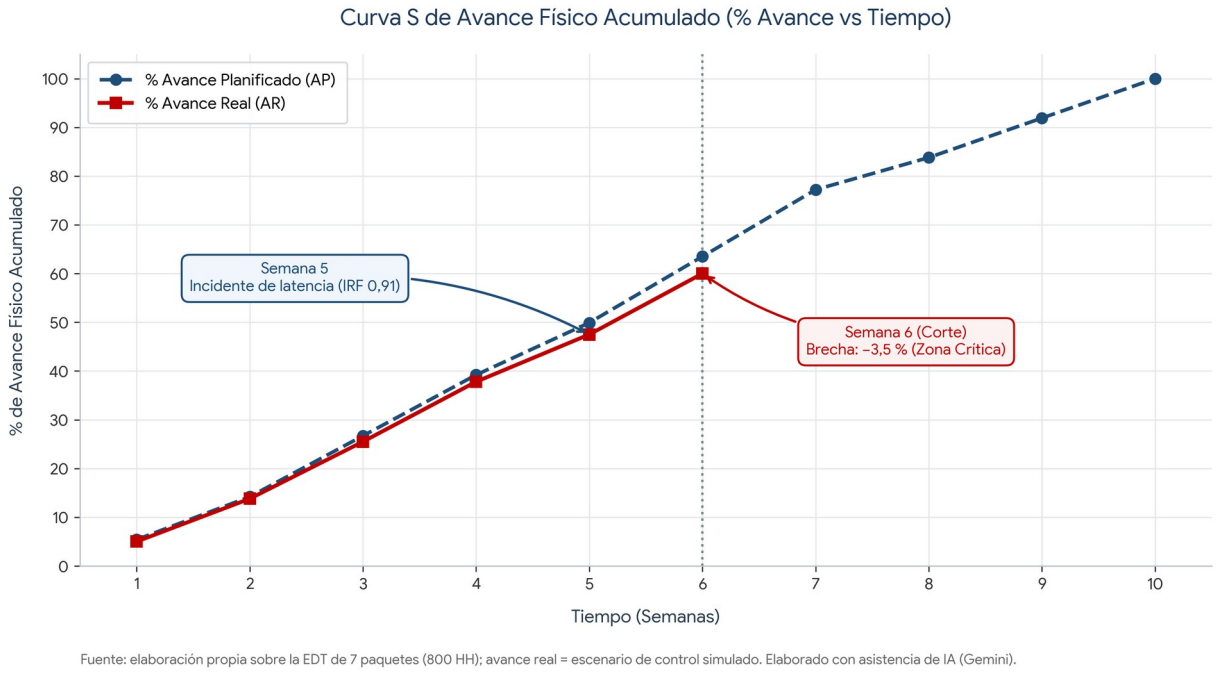
Tabla 19. *Hoja de ruta*

Fase	Plazo	Entregables	Criterio de salida
1 · Integración	Semanas 1–10	Servicios en AKS, Service Bus, SAS de delegación, CI/CD, prueba de carga	C1 y C2 cumplidas; cobertura ≥ 80%
2 · Piloto	Meses 3–5	2–3 clientes UK; DPIA; corpus etiquetado	C3 y C4 cumplidas
3 · Escalamiento	Meses 6–12	Lanzamiento UK/UE; monitoreo de drift	Adopción 30% el año 1

Fuente: elaboración propia del Grupo 2.

7.2 Control de avance físico

El avance se controla con la **curva S de avance físico** (avance programado AP frente a avance real AR, en % acumulado) y el **cuadrante de desempeño** (Δ% = AR − AP frente al índice de ritmo IRF = ΔAR semanal / ΔAP semanal). Los valores de avance real corresponden a un escenario de control simulado para el ejercicio académico, porque el proyecto aún no se ejecuta. Los índices de valor ganado (SPI y CPI) están en el Anexo E.



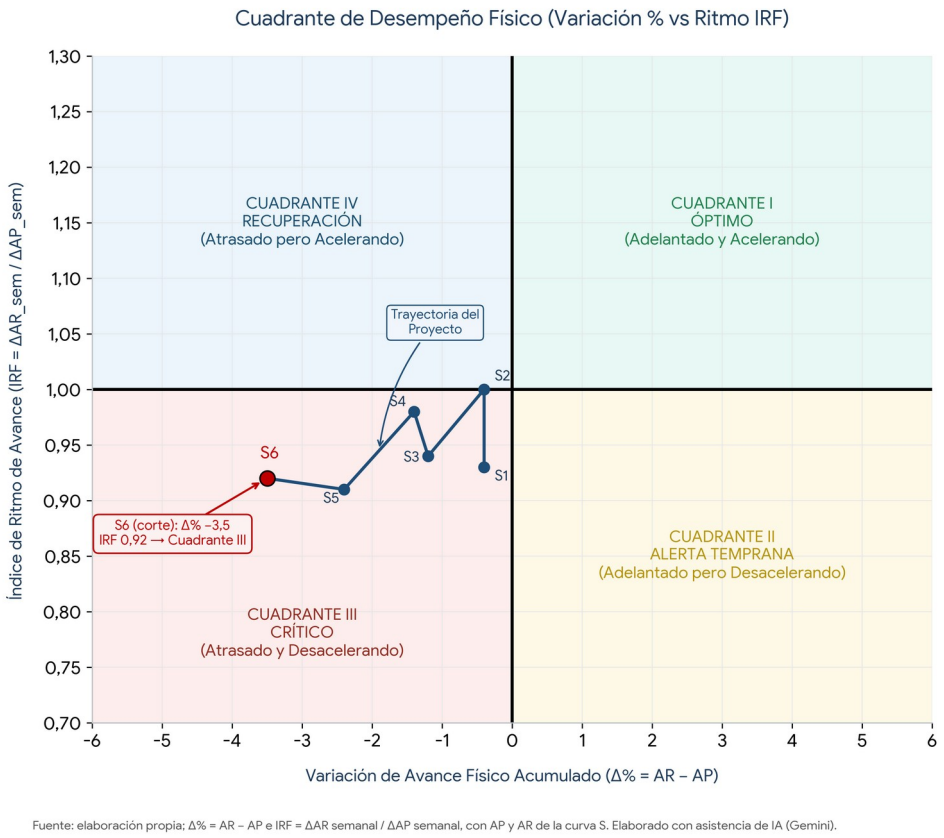
Fuente: elaboración propia sobre la EDT de 7 paquetes (800 HH); avance real = escenario de control simulado. Elaborado con asistencia de IA (Gemini).

Figura 9. *Curva S de avance físico: avance programado (AP) frente a avance real (AR), al corte de la semana 6.* Elaborado por el Grupo 2 con asistencia de IA (Gemini, Google); revisado por el equipo.

Tabla 20. *Avance físico al corte de la semana 6*

Semana	S1	S2	S3	S4	S5	S6
AP acumulado (%)	5,4	14,2	26,7	39,2	49,9	63,5
AR acumulado (%)	5,0	13,8	25,5	37,8	47,5	60,0
Δ% = AR − AP	−0,4	−0,4	−1,2	−1,4	−2,4	−3,5
IRF	0,93	1,00	0,94	0,98	0,91	0,92

Fuente: línea base del Grupo 2 (AP: S7–S10 = 77,2 / 83,8 / 91,9 / 100); AR simulado.



Fuente: elaboración propia; Δ% = AR – AP e IRF = ΔAR semanal / ΔAP semanal, con AP y AR de la curva S. Elaborado con asistencia de IA (Gemini).

Figura 10. *Cuadrante de desempeño físico (Δ% vs. IRF) con la trayectoria semanal.* Elaborado por el Grupo 2 con asistencia de IA (Gemini, Google); revisado por el equipo.

Lectura: al corte, el proyecto está en el **Cuadrante III – Crítico** (Δ% −3,5; IRF 0,92): atrasado y avanzando más lento que lo programado. El atraso se concentra en la integración Azure y en seguridad, por el retrabajo que provocó el incidente de latencia y seguridad (sección 2.2), visible en la semana 5 (IRF 0,91). **Acciones:** congelar el alcance de los paquetes 3 y 5 en los controles ya definidos, reutilizar plantillas de infraestructura como código y aprobar el uso de la reserva de contingencia (120 HH) para el retrabajo del incidente, con seguimiento semanal.

7.3 Matriz de riesgos

Los riesgos se evalúan según ISO 31000 (ISO, 2018) con nivel = probabilidad × impacto en escalas de 1 a 5.

Tabla 21. *Matriz de riesgos*

#	Riesgo	P	I	Nivel	Mitigación
R1	**Model drift: cambian las causas o la voz de los clientes y el modelo pierde precisión**	**4**	**4**	**16**	**Monitoreo PSI, reentrenamiento mensual, puerta ATE ≤ 0,05**
R2	**Latencia cloud > 250 ms en el pico**	**3**	**5**	**15**	**Prueba de carga, guardián de latencia, ONNX/GPU, holgura 20%**
R3	Incumplimiento GDPR (UK GDPR / EU AI Act)	2	5	10	DPIA, SAS 15 min, TLS 1.3, solo voz del cliente, sin PII al LLM
R4	Confusores no modelados sesgan el efecto causal	3	4	12	Revisión experta del DAG y refutadores DoWhy
R5	El mercado no acepta el recargo o la adopción es lenta	3	4	12	Piloto pagado; argumento de ahorro 13:1
R6	Capacidad GPU menor a la supuesta o falta de cupo	3	3	9	Medir en prueba de carga; reserva de cuota; quiebre 19 streams
R7	Alza del precio del LLM	2	2	4	Modelo de bajo costo; quiebre 11,4×
R8	Rotación del personal MLOps	2	3	6	Documentación, runbooks y pipeline reproducible

Fuente: elaboración propia del Grupo 2 según ISO 31000:2018.

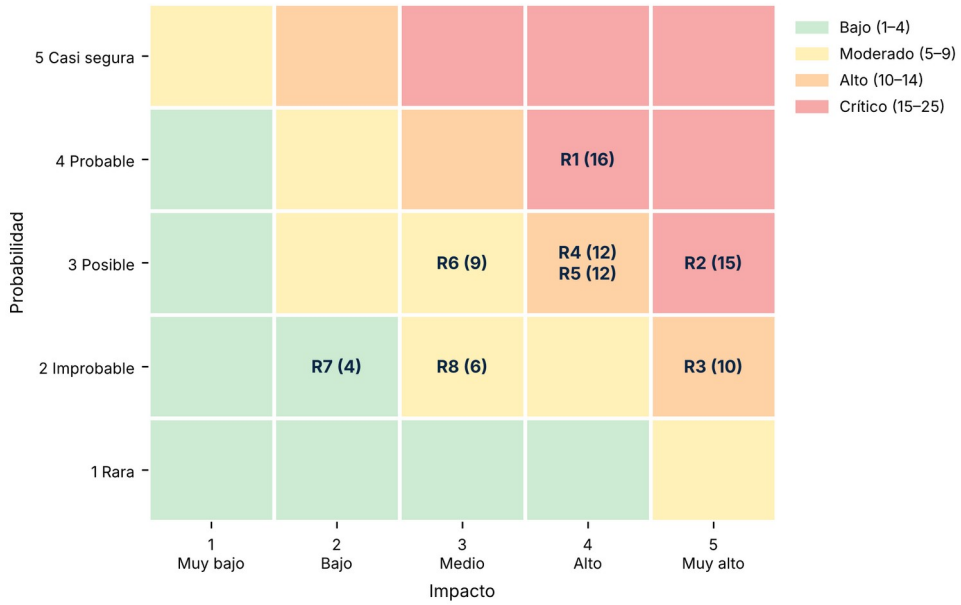


Figura 11. *Mapa de calor de riesgos (probabilidad × impacto).* Elaborado por el Grupo 2 con asistencia de IA (Claude, Anthropic); revisado por el equipo.

8. Conclusiones y recomendación ejecutiva

Al directorio de Alloxentric SpA en Londres:

- **Técnicamente viable.** La arquitectura cumple la meta de latencia con holgura (175 ms p95 vs. 250 ms), escala horizontalmente y se integra con los servicios Azure existentes con ajustes menores.
- **Económicamente atractivo en el escenario base.** VAN de US$ 366.751, TIR de 91,9%, payback descontado de 2,02 años y B/C de 1,54, con una inversión de US$ 69.835.
- **Valor claro para el cliente.** Ahorro de US$ 7,37 millones al año, 13,2 veces el recargo, sin contar la mejora de FCR.
- **Riesgo concentrado en el mercado.** El escenario pesimista destruye valor; las variables críticas son el recargo, el ARPU y la adopción.

Dictamen: GO CONDICIONADO, con avance por fases

C1 – Precisión: error de ATE ≤ 0,05 con datos reales del piloto.

C2 – Desempeño: latencia p95 < 250 ms con 1.500 llamadas concurrentes y ≥ 19 streams por GPU.

C3 – Cumplimiento: DPIA aprobada y análisis exclusivo de la voz del cliente.

C4 – Mercado: recargo aceptado ≥ 13,1% y adopción ≥ 52% de la rampa al cierre del piloto.

Si alguna condición no se cumple al cierre de la fase correspondiente, el dictamen pasa a **NO-GO de escalamiento**.

Referencias

Alloxentric. (2026). Xentric: plataforma omnicanal. https://www.alloxentric.com

Amazon Web Services. (2026). AWS Support plan pricing. https://aws.amazon.com/premiumsupport/pricing

Amazon Web Services. (2025). Effective cost optimization strategies for Amazon Bedrock. https://aws.amazon.com/blogs/machine-learning/effective-cost-optimization-strategies-for-amazon-bedrock

Best Practice AI. (s. f.). MetLife: Cogito real-time voice AI in call centres. https://bestpractice.ai/ai-use-cases/case-studies/financial-services/metlife

Brown, S. (2026). The C4 model for visualising software architecture. https://c4model.com

Business Wire. (2021). TruConnect leverages AI to drive call handling improvements with Five9 Agent Assist. https://www.businesswire.com/news/home/20210428005385/en

Call Centre Helper, citado en Lorikeet. (2026). WFM metrics: adherence, shrinkage and occupancy. https://www.lorikeetcx.ai/articles/wfm-metrics-adherence-shrinkage-occupancy-2026

CX Today. (2023). Copilot cuts average handling time by 12 percent, claims Microsoft. https://www.cxtoday.com/wfo/copilot-cuts-average-handling-time-by-12-percent-claims-microsoft/

Damodaran, A. (2026, enero). Cost of capital by sector (US). NYU Stern. https://pages.stern.nyu.edu/~adamodar/New_Home_Page/datafile/wacc.html

Digital Catapult. (2021). Alloxentric. https://www.digicatapult.org.uk

DoiT. (2026). AWS EC2 g6.xlarge y c7i.xlarge: precios on-demand eu-west-2. https://www.doit.com/compute/spot/eu-west-2/g6.xlarge

Eyben, F., Scherer, K. R., Schuller, B. W., et al. (2016). The Geneva Minimalistic Acoustic Parameter Set (GeMAPS) for voice research and affective computing. IEEE Transactions on Affective Computing, 7(2), 190–202.

Full Fact. (2026). Corporation tax cap at 25%. https://fullfact.org/government-tracker/corporation-tax-cap/

Glassdoor. (2026). Machine Learning Engineer salaries in United Kingdom. https://www.glassdoor.co.uk/Career/machine-learning-engineer-career_KO0,25.htm

Google Cloud. (2024). Companies achieve stronger results with Customer Engagement Suite. https://cloud.google.com/blog/products/ai-machine-learning/customer-engagement-suite-stronger-results-and-new-ai-features

Google Cloud. (2026). Conversational Insights pricing. https://cloud.google.com/contact-center/insights/pricing

International Organization for Standardization. (2018). ISO 31000:2018 Risk management – Guidelines. ISO.

International Organization for Standardization. (2022). ISO/IEC/IEEE 14764:2022 Software engineering – Software life cycle processes – Maintenance. ISO.

International Organization for Standardization. (2023). ISO/IEC 25010:2023 Systems and software quality models. ISO.

ITU-T. (2003). Recommendation G.114: One-way transmission time. International Telecommunication Union.

Kayako. (2026). Average handle time industry standards by sector. https://kayako.com/blog/average-handle-time-industry-standard/

Lewis Silkin. (2025). Understanding the EU AI Act's prohibited practices: workplace and advertising. https://www.lewissilkin.com/insights/2025/02/17/understanding-the-eu-ai-acts-prohibited-practices-key-workplace-and-advertising-102k011

Magna, O. (2026). Taller de actividades prácticas y caso de estudio PIA: arquitectura C4/MLOps e Informe ERV para Alloxentric SpA [Material de cátedra]. GPI 2026-II, Universidad Tecnológica Metropolitana.

Microsoft Learn. (2026a). Grant limited access to Azure Storage resources using shared access signatures (SAS). https://learn.microsoft.com/azure/storage/common/storage-sas-overview

Microsoft Learn. (2026b). Azure OpenAI: performance and latency. https://learn.microsoft.com/azure/ai-foundry/openai/how-to/latency

Microsoft Research / PyWhy. (2026). EconML: Python package for heterogeneous treatment effects. https://pypi.org/project/econml/

Pertemps. (2026). Contact centre agent jobs and salary. https://www.pertemps.co.uk/jobs/contact-centre-agent-jobs/

Pound Sterling Live. (2026). U.S. Dollar–British Pound history 2026. https://www.poundsterlinglive.com/history/USD-GBP-2026

Project Management Institute. (2021). A guide to the project management body of knowledge (PMBOK guide) (7.ª ed.). PMI.

Sharma, A. y Kiciman, E. (2020). DoWhy: An end-to-end library for causal inference. arXiv:2011.04216.

SQM Group. (2024). First call resolution operating strategies. https://www.sqmgroup.com/resources/library/blog/fcr-operating-strategies

The Fintech Times. (2023). Alloxentric expands to the UK. https://thefintechtimes.com

Uber Technologies. (2026). CausalML: uplift modeling and causal inference with machine learning. https://github.com/uber/causalml

Herramientas de IA utilizadas: Anthropic. (2026). Claude [modelo de lenguaje]; Google. (2026). Gemini [modelo de lenguaje y generación de imágenes]. Usadas como asistencia en redacción, cálculo y diagramas; todo el contenido fue revisado por el equipo.

Anexo A. Supuestos y fuentes

Tabla 22. *Convención de origen de cada dato*

Etiqueta	Significado	Ejemplo
[CASO]	Dato del enunciado del caso PIA	800 HH, 1.500 llamadas, recargo 20%, TTR −15%
[AWS]	Precio público de AWS en Londres (eu-west-2), usado como referencia por instrucción de la cátedra	GPU g6.xlarge US$ 1,0216/h
[MERCADO]	Dato publicado por una fuente externa citada	WACC software 9,34% (Damodaran)
[SUP]	Supuesto del equipo, justificado y sometido a sensibilidad	50 streams por GPU

Fuente: elaboración propia del Grupo 2.

Tabla 23. *Registro de supuestos*

Parámetro	Valor	Origen	Justificación / fuente
Concurrencia pico	1.500 llamadas	[CASO]	KPI de throughput
Reducción TTR / recargo	15% / 20%	[CASO]	Beneficios comerciales del caso
Horas de desarrollo	800 HH	[CASO]	CAPEX del caso
Salario ML Engineer UK	£68.444/año	[MERCADO]	Glassdoor, 2026
Carga del empleador	30%	[SUP]	National Insurance (15%), pensión y equipamiento
Horas productivas	1.740 h/año	[SUP]	37,5 h × 52 semanas menos vacaciones y feriados
Tipo de cambio	1,344 US$/£	[MERCADO]	Promedio 2026, Pound Sterling Live
Factor de carga	31,8%	[SUP]	Perfil horario típico de contact center UK
AHT	6 min 10 s	[MERCADO]	Sprinklr vía Kayako, 2026
Streams por GPU / CPU	50 / 150	[SUP]	A validar en prueba de carga; quiebre 19
GPU g6.xlarge / CPU c7i.xlarge	US$ 1,0216/h / US$ 0,2121/h	[AWS]	DoiT y Holori, eu-west-2
LLM (Nova Lite como referencia)	US$ 0,06 / 0,24 por millón de tokens + 20%	[AWS] + [SUP]	Recargo regional supuesto
Soporte AWS	Business Support+ escalonado	[AWS]	Tabla oficial de AWS
Contingencia CAPEX / OPEX	15% / 10%	[SUP]	Error de estimación / servicios no modelados
MLOps	1 FTE	[SUP]	Quiebre 2,14 FTE
Shrinkage / ocupación	30% / 85%	[MERCADO]	Call Centre Helper
ARPU base	US$ 65/puesto/mes	[MERCADO]	Google, Sentient, Observe.AI
Salario agente UK	£23.500/año	[MERCADO]	Pertemps, 2026
Realización del ahorro TTR	50%	[SUP]	No todas las horas reducen dotación
Mejora de FCR	+3 pp (no incluida en el VAN)	[SUP]	Cogito reportó +3,5%; SQM: 1 pp ≈ 1% de costo
Reentrenamiento	Mensual o si PSI > 0,2	[SUP]	Plan de mantenimiento perfectivo
SLA de incidentes	4 h	[SUP]	Mantenimiento correctivo
Adopción	30/60/85/100/100%	[SUP]	Rampa comercial de 4 años
Tasa de descuento	12,34%	[MERCADO] + [SUP]	Damodaran 9,34% + 3 pp
Impuesto	25%	[MERCADO]	UK corporation tax

Fuente: registro del Grupo 2.

Anexo B. Equivalencia Azure ↔ AWS usada para costear

Tabla 24. *Servicio del caso (Azure) y equivalente de referencia (AWS)*

Componente del caso (Azure)	Equivalente AWS para el precio	Unidad de cobro
Instancias GPU/CPU en AKS	EC2 g6.xlarge (NVIDIA L4) y c7i.xlarge	Hora de instancia
Azure OpenAI	Amazon Bedrock – Nova Lite	Millón de tokens
Blob Storage + SAS	Amazon S3 Standard + URLs prefirmadas	GB-mes y solicitudes
Azure Service Bus	Amazon SQS	Millón de solicitudes
Azure API Management	Amazon API Gateway (REST)	Millón de llamadas
Soporte Microsoft Unified	AWS Business Support+	% del gasto mensual

Fuente: instrucción de la cátedra; elaboración propia.

La arquitectura se mantiene íntegramente en Azure, como exige el caso. Los precios de AWS solo sirven como referencia verificable; la diferencia con las tarifas de Azure queda cubierta por la contingencia y la sensibilidad.

Anexo C. Contratos de servicio, fallos y evidencia del repositorio

Tabla 25. *Interfaces expuestas*

Endpoint	Protocolo	Entrada → salida	SLO
InferenceStream.Analyze	gRPC bidireccional	call_id + ventana PCM 16 kHz (2 s) → top-3 causas, efecto, p(fuga), versión	p95 < 250 ms; 99,9%
Cola explain-requests	AMQP 1.0	call_id, causas, rasgos sin PII → texto explicativo	p95 < 5 s
GET /v1/calls/{id}/insights	HTTPS/REST vía APIM + JWT	call_id → historial y explicación	p95 < 300 ms
GET /healthz, /readyz	HTTP	— → estado del pod y del modelo	Usado por AKS

Fuente: elaboración propia del Grupo 2.

Tabla 26. *Estrategia ante fallos*

Fallo	Detección	Respuesta
Inferencia excede 250 ms	Guardián de latencia	Último insight válido como «provisional»; evento registrado
Azure OpenAI no disponible (429)	Código HTTP / timeout	Reintento 3× con backoff; luego DLQ; el insight causal se mantiene
Mensaje no procesable	Excepción de deserialización	Dead-letter queue y alerta
Caída de pod o nodo GPU	Sondas de AKS	Reprogramación; mínimo 2 nodos por pool en 2 zonas
Modelo nuevo degrada métricas	Canario (10% durante 30 min)	Rollback automático a la versión anterior
Drift de datos	PSI > 0,2	Alerta y nuevo ciclo de entrenamiento

Fuente: elaboración propia del Grupo 2.

Tabla 27. *Estructura del repositorio github.com/GiovanniGabrielli33/gpi-411-grupo2-voxcausal*

Carpeta	Contenido
/README.md	Descripción del caso, integrantes y uso de IA
/docs/erv	Informe ERV (Word y PDF) y presentación
/docs/arquitectura	Diagramas C4 N1–N3 y pipeline MLOps en alta resolución
/docs/gestion	Curva S y cuadrante de desempeño físico
/src/voxcausal	Prototipo del núcleo: causal.py (ajuste backdoor), guardian.py (D2), pii.py, latency.py, security.py (D4)
/tests	28 pruebas pytest; cobertura 100% de líneas y ramas
/pyproject.toml	Dependencias y configuración de pytest-cov y ruff

Fuente: elaboración propia del Grupo 2.

Flujo de ramas. Cada entrega se trabaja en una rama feature/* y se integra a main por pull request revisado por otro integrante: PR #1 (feature/erv, informe) y PR #2 (feature/prototipo, código y pruebas). Las métricas de la sección 2.3 se reproducen con: pip install -e ".[dev]" y luego pytest. Pipelines de Azure ML, infraestructura como código y CI/CD (GitHub Actions con SonarCloud) se agregan en la fase 1 si el dictamen se confirma.

Anexo D. Cálculo del ejemplo de confusión

Tabla 28. *Ejemplo ilustrativo de sesgo por confusión (fuga a 90 días)*

Segmento	Peso	% transferido	Fuga si transferido	Fuga si no	Efecto real
Con llamada previa	40%	60%	35%	27%	+8 pp
Primer contacto	60%	25%	15%	7%	+8 pp

Fuente: ejemplo construido por el Grupo 2.

Transferidos: 0,40 × 0,60 = 0,24 y 0,60 × 0,25 = 0,15 (total 0,39). Fuga de transferidos = (0,24 × 35% + 0,15 × 15%) / 0,39 = **27,3%**. No transferidos: 0,16 y 0,45 (total 0,61). Fuga = (0,16 × 27% + 0,45 × 7%) / 0,61 = **12,2%**. La diferencia ingenua es **15,1 pp**, frente a un efecto real de 8 pp: error de ATE = 0,151 − 0,080 = **0,071 > 0,05**. Ajustar por el confusor (criterio backdoor: promediar el efecto dentro de cada segmento) recupera los 8 pp.

Verificación en código. La función simulate de src/voxcausal/causal.py genera 200.000 llamadas con estas mismas probabilidades. La diferencia ingenua resulta 0,150 (error 0,070, igual al 0,071 teórico salvo por el muestreo) y el ajuste backdoor 0,0809 (error **0,0009**); en cinco semillas distintas el error ajustado se mantiene bajo 0,01.

Anexo E. Valor ganado (SPI y CPI)

Tabla 29. *EDT y valor ganado al corte de la semana 6 (horas)*

#	Paquete	BAC	PV	EV	AC	SPI	CPI
1	Gestión, gobernanza y DPIA	60	36	36	40	1,00	0,90
2	Refactorización y contenerización	150	150	150	158	1,00	0,95
3	Integración Azure	150	120	96	118	0,80	0,81
4	Pipeline MLOps y motor causal	160	133	140	142	1,05	0,99
5	Seguridad y cumplimiento	90	45	40	48	0,89	0,83
6	Pruebas SQA y desempeño	120	24	18	20	0,75	0,90
7	Despliegue canario	70	0	0	0	—	—
	Total	800	508	480	526	0,945	0,913

Fuente: línea base de 800 HH [CASO]; EV y AC simulados; PMI (2021).

Tabla 30. *Indicadores de valor ganado al corte*

Indicador	Valor	Interpretación
SV = EV − PV	−28 h	Atraso concentrado en la integración Azure (paquete 3)
CV = EV − AC	−46 h	Sobrecosto por el retrabajo del incidente (paquetes 3 y 5)
SPI / CPI	0,945 / 0,913	Atrasado y sobre presupuesto; ambos ≥ 0,90
EAC = BAC / CPI	877 h (US$ 60.256)	Desvío final estimado de 77 h (9,6%)
Reserva de contingencia (15%)	120 h	Cubre el desvío (uso estimado 64%)
TCPI = (BAC − EV) / (BAC − AC)	1,168	Eficiencia exigente; se gestiona con la reserva

Fuente: fórmulas PMI (2021) aplicadas a la tabla anterior.

Los índices de valor ganado son coherentes con el cuadrante de desempeño físico de la sección 7.2: ambos ubican al proyecto atrasado al corte de la semana 6, con recuperación prevista mediante la reserva de contingencia.