UNIVERSIDAD TECNOLÓGICA METROPOLITANA
UTEM del Estado de Chile

Vox-Causal AI · Informe ERV

Caso de Estudio PIA · GPI 2026-II

Alloxentric

Integrantes Grupo 02

Cristóbal Muñoz Muñoz - Investigador

Giovanni Gabrielli Bilbao - Líder de equipo

Martin Andrés Vera - Desarrollador

Ailyn Strajilevich Vega - Documentador

Académico: Dr. Óscar Magna Veloso · Sección 411 · PIA

29 de octubre de 2026



UNIVERSIDAD TECNOLÓGICA METROPOLITANA
del Estado de Chile
UTEM

Contenidos

01 Gestión del Proyecto: contexto y control EVM

02 Arquitectura C4, Pipeline MLOps e incidente

03 Calidad SQA: repositorio y métricas

04 Evaluación ERV y dictamen ejecutivo



UNIVERSIDAD TECNOLÓGICA METROPOLITANA
UTEM del Estado de Chile

Contexto y problema

Alloxentric SpA (Londres) procesa millones de llamadas en Azure, pero sus modelos son correlacionales: detectan el tono, no la causa. Vox-Causal AI combina prosodia en vivo con Modelos Causales Estructurales (SCM/DAG) para entregar al operador la causa raíz y el riesgo de fuga durante la llamada.

Problema	Sin causa raíz, el operador ataca el síntoma: la llamada se alarga y el riesgo de fuga no se gestiona.
Causal vs. correlacional	Ejemplo: la correlación atribuye 15,1 pp de fuga a las transferencias; el efecto real es 8 pp (confusor: llamada previa). Error ATE 0,071 > 0,05: solo un método causal cumple el KPI.
Decisión pedida	¿Financiar e integrar el prototipo en la plataforma SaaS? KPIs: < 250 ms, 1.500 llamadas concurrentes y error ATE ≤ 0,05. Beneficios: TTR −15% y recargo SaaS de 20%.

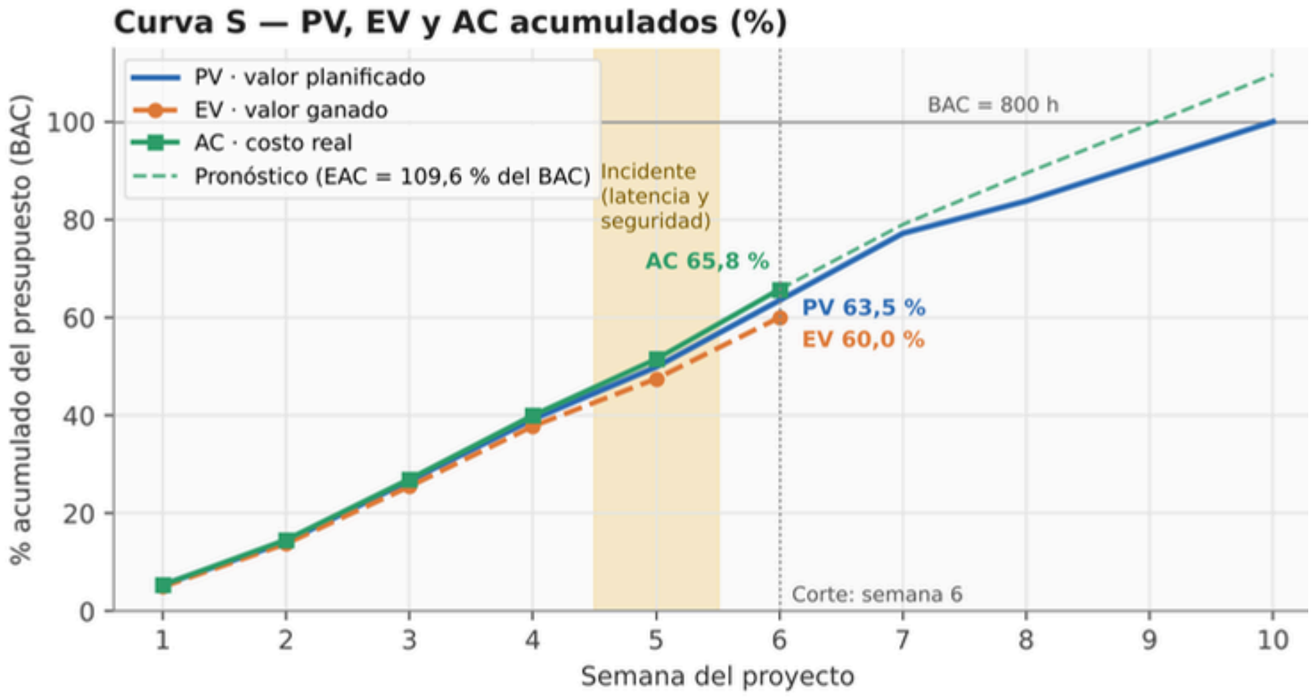
Problema y enfoque

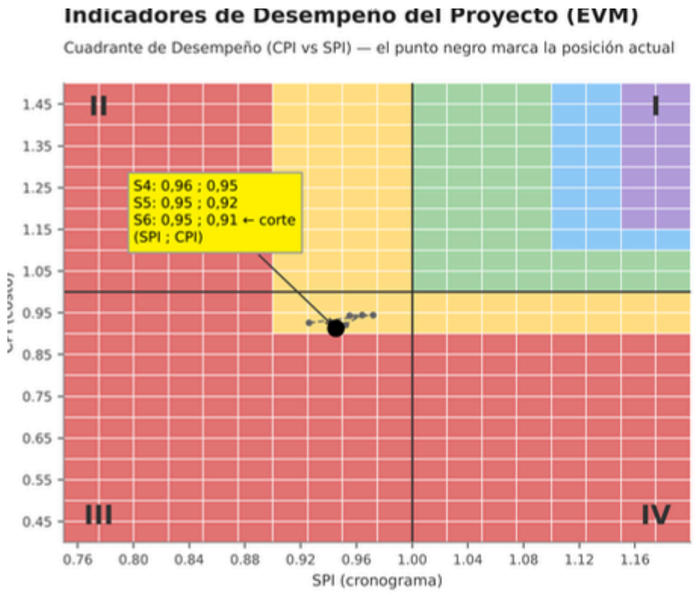
N°	Solución comparable	Resultado reportado	Enfoque	Brecha
1	Cogito en MetLife	+13% satisfacción	Tono de voz	Sin causa
2	Microsoft Copilot for Service	−12% AHT	IA generativa	Sin causa
★	Vox-Causal AI (propuesta)	TTR −15% (caso)	Causal en vivo	Diferenciador
3	Google Agent Assist (TTEC)	−11% AHT	Sugerencias	Correlacional
4	Five9 Agent Assist (TruConnect)	−30 s AHT	Transcripción	No diagnostica
5	CausalML (Uber) / EconML	Campañas focalizadas	Causal (lotes)	No en vivo

Estado del arte

Fuente: caso PIA; Best Practice AI, CX Today, Google Cloud, Business Wire, Uber.

Curva S y cuadrante de desempeño





Corte semana 6	
CPI (Costo)	0,91
SPI (Cronograma)	0,95
Clasificación	Marginal

Valores índices	Estado del proyecto
CPI y SPI ≥ 1,15	Excepcional
CPI y SPI ≥ 1,10	Muy bueno
CPI y SPI ≥ 1,00	Satisfactorio
CPI y SPI ≥ 0,90	Marginal
CPI y SPI < 0,90	No satisfactorio

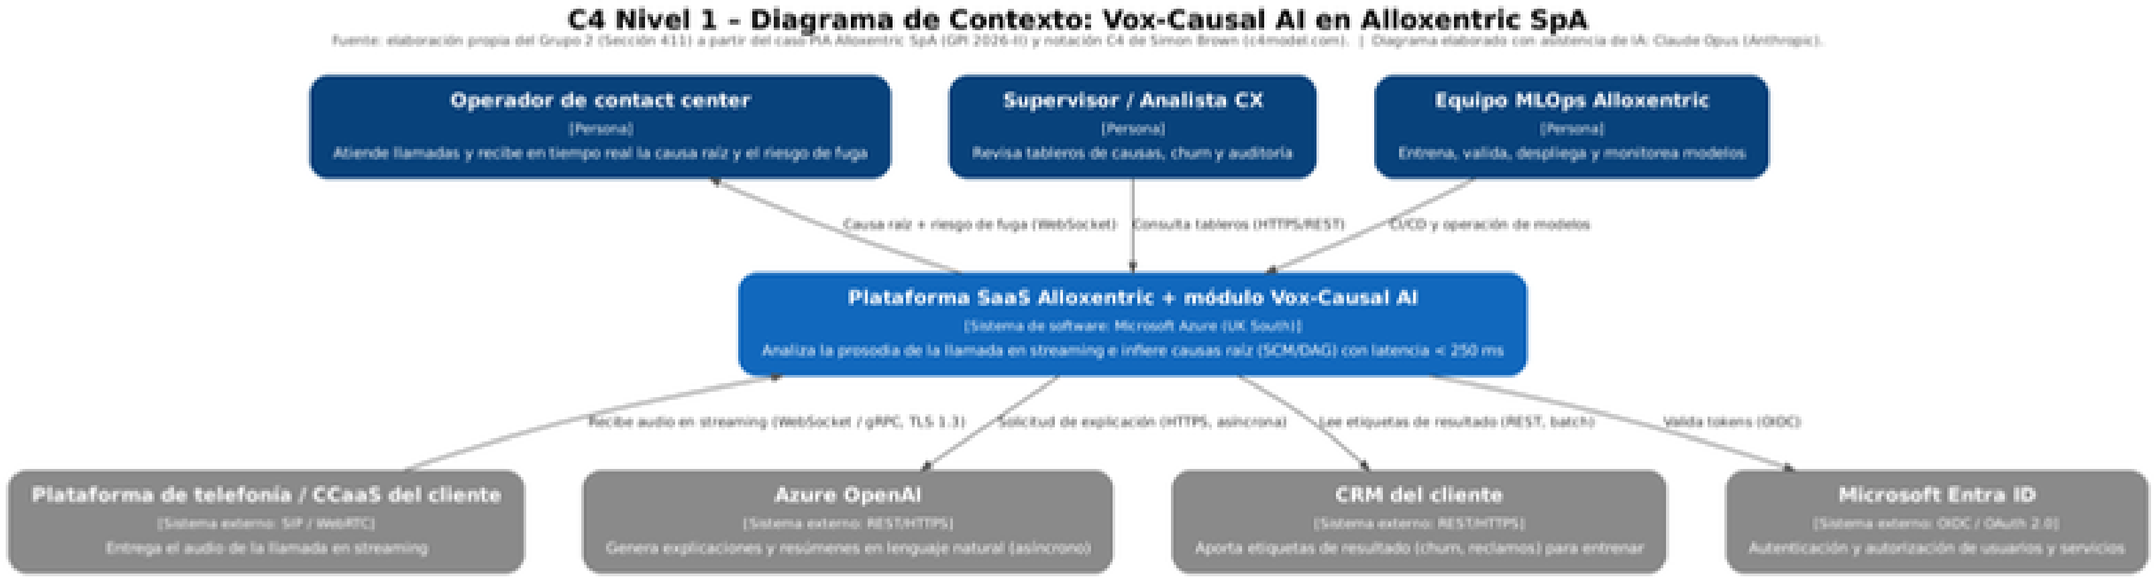
Cuadrante III: atrasado (SPI < 1) y sobre presupuesto (CPI < Trayectoria S1–S6 en gris; punto negro = corte.

ente: SPI = EV/PV y CPI = EV/AC (PMI, PMBOK) sobre la EDT del equipo; escenario de control simulado.
ıborado por el Grupo 2 (Sección 411) con asistencia de IA: Claude Opus (Anthropic).

uente: línea base de 7 paquetes sobre las 800 HH del caso; EV y AC = escenario de control simulado (no medición real).
laborado por el Grupo 2 (Sección 411) con asistencia de IA: Claude Opus (Anthropic).

Fuente: EDT de 7 paquetes sobre 800 HH; EV y AC simulados. Corte S6: SPI 0,95 · CPI 0,91 · EAC 877 h. Elaborado con IA (Claude Opus).

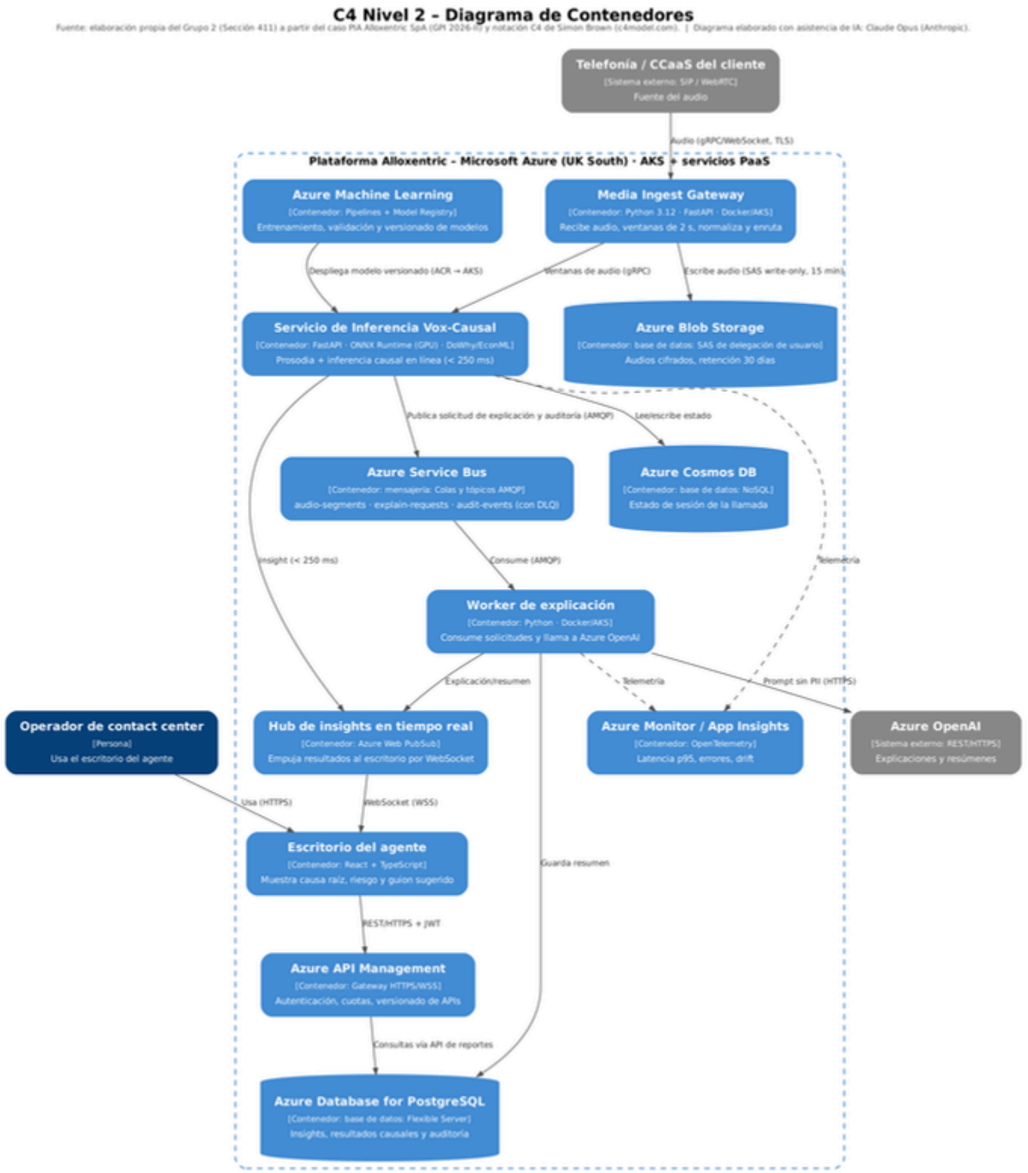
Arquitectura C4 · Nivel 1: Contexto



Vox-Causal AI funciona como módulo de la plataforma SaaS de Alloxentric (Azure, Londres). Usuarios: operador del contact center, supervisor/analista CX y equipo MLOps. Sistemas externos: telefonía/CCaaS, Azure OpenAI, CRM y Microsoft Entra ID.

Fuente: elaboración propia (modelo C4, S. Brown). Diagramas elaborados con IA (Claude Opus).

Arquitectura C4 · Nivel 2: Contenedores



Flujo de un insight

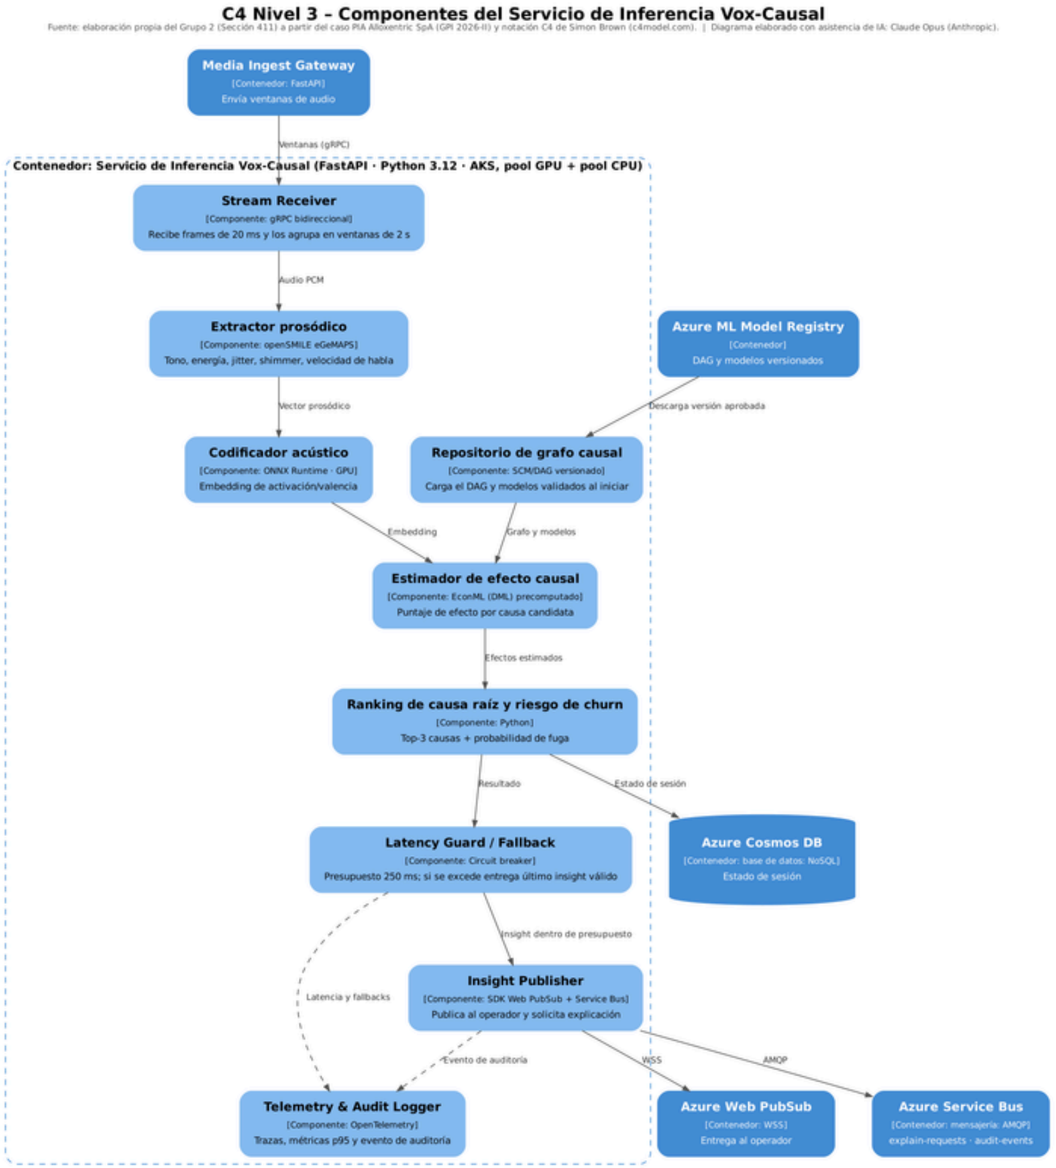
1. El audio entra por el Hub de insights (Event Hubs).
2. El servicio de inferencia (FastAPI + ONNX en GPU) calcula prosodia y efecto causal.
3. El insight llega al operador en < 250 ms (p95 estimado 175 ms).
4. Azure OpenAI redacta la explicación en forma asíncrona vía Service Bus.

Stack y seguridad

- gRPC interno entre servicios
- Blob Storage UK South con SAS de delegación de 15 min
- TLS 1.3 · UK GDPR · identidad con Entra ID
- Pools separados para batch y tiempo real

Fuente: elaboración propia (modelo C4, S. Brown). Diagramas elaborados con IA (Claude Opus).

Arquitectura C4 · Nivel 3: Componentes



Dentro del servicio de inferencia

- Extractor prosódico: tono, energía y ritmo por segmento de audio.
- Motor causal: aplica efectos precomputados (CausalML/EconML) en vez de calcularlos en línea.
- Ajuste de confusores: controla la llamada previa para mantener el error ATE ≤ 0,05.
- Fallback: si el modelo no responde a tiempo, entrega una regla simple (< 2% de los casos).
- Publicador de insights: envía el resultado al operador y la tarea al LLM asíncrono.

Fuente: elaboración propia (modelo C4, S. Brown). Diagramas elaborados con IA (Claude Opus).

Pipeline MLOps e incidente de latencia

Inferencia asíncrona · KPI del caso < 250 ms · seguridad de audios (UK GDPR)

Pipeline MLOps (3 carriles)

- A · Entrenamiento: Azure ML, re-estimación causal semanal (EconML)
- B · Despliegue: modelo ONNX en GPU, canary 10% y rollback
- C · Monitoreo: drift de prosodia, ATE y latencia p95

Incidente de latencia y seguridad

- Causa: LLM síncrono y cálculo causal en línea
- Resultado: p95 175 ms (KPI < 250 ms)
- Seguridad: SAS de delegación 15 min, TLS 1.3, UK South

Elemento	Prototipo (sandbox)	Arquitectura productiva
Azure OpenAI	Llamada síncrona	Asíncrono vía Service Bus (D1)
Motor causal	Cálculo en línea	Efectos precomputados + ONNX GPU/gRPC (D2, D3)
Audios	Clave de cuenta	SAS de delegación 15 min, solo voz del cliente (D4, D6)
Batch / tiempo real	Mismo clúster	Pools aislados (D5)

Verificación: prueba de carga con 1.500 llamadas; capacidad ≥ 19 streams por GPU. Fuente: elaboración propia con IA (Claude Opus).

UNIVERSIDAD TECNOLÓGICA METROPOLITANA
del Estado de Chile
UTEM

Evidencia del repositorio

Estructura del proyecto

Repositorio público del grupo con el Informe ERV, la presentación y los diagramas

gpi-411-grupo2-voxcausal/	Portada del proyecto y dictamen
├── **README.md**	
├── **docs/**	Informe ERV (Word/PDF) y presentación
│ ├── **erv/**	Gráficos financieros y de latencia
│ │ └── **figuras/**	C4 niveles 1-3 y pipeline MLOps
│ ├── **arquitectura/**	Curva S y cuadrante EVM
│ └── **gestion/**	Código (si el dictamen es GO)
├── **src/**	Pruebas (si el dictamen es GO)
└── **tests/**	

Repositorio

PLATAFORMA	**GitHub**
URL	**github.com/GiovanniGabrielli33/gpi-411-grupo2-voxcausal**

Estado del repositorio

Corte al 28-oct-2026

2
ramas (main, feature/erv)

1
PR integrado (#1)

Flujo de trabajo

El informe se trabajó en feature/erv y se integró a main con un PR revisado; el PDF y esta presentación quedan en docs/erv.

Detalle de estructura, flujo y uso de IA en README.md

Ramas, revisión y automatización

Hecho

Ramas

main = versión entregada; feature/erv = desarrollo del informe

Hecho

Pull request

PR #1 revisado por otro integrante antes de integrar a main

Futuro

CI/CD

Pendiente: se habilita con el código si el dictamen es GO

UNIVERSIDAD TECNOLÓGICA METROPOLITANA
del Estado de Chile
UTEM

Métricas de aceptación del caso

Métrica · meta	Valor	Detalle	Estado
Precisión causal (error ATE) ≤ 0,05	**0,071**	sin ajuste	Por validar
Latencia p95 < 250 ms	**175 ms**	estimado	Cumple
Cobertura de pruebas ≥ 80%	—	pendiente	Por medir
Deuda técnica (SonarQube) ≤ 4 h	—	pendiente	Por medir

La latencia cumple con holgura (175 vs 250 ms). La precisión causal es la condición crítica: sin controlar el confusor (llamada previa) el error es 0,071 > 0,05; con ajuste (EconML) debe validarse antes del GO.

Plan de validación

1.500 llamadas en prueba de carga y validación

3,38 M llamadas/mes en producción

36 + 12 nodos GPU + CPU dimensionados

Umbrales de operación

≤ 0,05 error ATE objetivo

< 2 % respuestas en fallback

≥ 19 streams por GPU (punto de quiebre)

Fuente: KPI del caso PIA; estimaciones propias del Informe ERV (secc. 4 y 6), elaboradas con IA (Claude Opus).

Evaluación financiera

Caso base (5 años, tasa 12,34%, impuesto UK 25%)

CAPEX US$ 69.835

OPEX pleno US$ 281.383/año: cloud AWS US$ 13.483/mes (63% GPU) + 1 FTE MLOps.

VAN US$ 366.751 · TIR 91,9%

Ingreso: 3.590 seats × ARPU US$ 65 × recargo 20% = US$ 560.027/año.

Payback 1,82 años · B/C 1,54

Después de impuestos. Antes de impuestos: VAN US$ 495.637 y TIR 106,4%.

Escenarios

Escenario	VAN (US$)	B/C	Supuesto que cambia
Pesimista	−215.937	0,71	Menor adopción y recargo, mayor costo GPU y MLOps
Base	366.751	1,54	Supuestos justificados del informe (AWS, Damodaran)
Optimista	1.037.247	3,53	TIR 238%, payback 0,65 años
Económico (cliente)	17,7 M	20,25	Incluye ahorro del cliente por menor tiempo de atención

Puntos de quiebre (VAN = 0)

Recargo / ARPU
13,1% · US$ 42,6

Adopción / MLOps
52% · 2,14 FTE · LLM 11,4×

Valor para el cliente

Ahorro US$ 7,37 M = 13,2× el recargo

Dictamen, impacto y hoja de ruta

1 Dictamen: GO condicionado

Condición	Umbral	Plazo
Validar precisión causal con ajuste de confusores	**ATE ≤ 0,05**	Sem. 1–10
Prueba de carga en preproducción	**p95 < 250 ms**	Sem. 8
Recargo comercial pactado	**≥ 13,1%**	Antes del piloto
Cumplimiento UK GDPR y EU AI Act	**Solo voz del cliente**	Sem. 6

2 Impacto y diferenciación

Impacto en el cliente

- Ahorro de US$ 7,37 M en 5 años: 13,2× el recargo
- Con −11% de AHT (Google/TTEC) sigue siendo 9,7×
- Nueva línea de ingresos de US$ 560 mil/año

Diferenciación

- Causal, no solo correlacional (CausalML/EconML)
- Explicable y auditable para supervisores
- Diseñado para UK GDPR y EU AI Act

3 Hoja de ruta

Semanas 1–10 · Integración

- Integrar en Azure UK South (800 HH)
- Aplicar decisiones D1–D6
- Validar ATE y latencia

Meses 3–5 · Piloto

- Piloto con un cliente del contact center
- Medir AHT y satisfacción reales
- Confirmar recargo y adopción

Meses 6–12 · Escalamiento

- Despliegue a los 3.590 seats
- Monitoreo MLOps continuo
- Revisión del VAN con datos reales

Fuente: Informe ERV del Grupo 2 (secciones 7 y 8); referencias de impacto: Google Cloud/TTEC y estudios del estado del arte.