UNIVERSIDAD TECNOLÓGICA METROPOLITANA
del Estado de Chile
UTEM

Vox-Causal AI · Informe ERV

Caso de Estudio PIA · GPI 2026-II

Alloxentric

Integrantes Grupo 02

Cristóbal Muñoz Muñoz

Giovanni Gabrielli Bilbao

Martin Andrés Vera

Ailyn Strajilevich Vega

Académico: Dr. Óscar Magna Veloso · Sección 411 · PIA



UNIVERSIDAD TECNOLÓGICA METROPOLITANA
UTEM del Estado de Chile

Contenidos

01 Contexto y arquitectura C4 (Parte I)

02 Pipeline MLOps e incidente de latencia

03 Evaluación técnica, beneficios y costos

04 Evaluación económica, riesgos y dictamen



UNIVERSIDAD TECNOLÓGICA METROPOLITANA
UTEM del Estado de Chile

1. Contexto y alcance

Alloxentric (Chile, 2018) opera la plataforma omnicanal Xentric con ~1 M de contactos/día (Digital Catapult, 2021) y se expandió a Reino Unido en 2023. Sus modelos de IA son correlacionales: detectan el tono, no la causa. Vox-Causal AI combina prosodia en vivo con Modelos Causales Estructurales (SCM) sobre un grafo causal (DAG).

Problema	Sin causa raíz, el operador ataca el síntoma: la llamada se alarga y el riesgo de fuga no se gestiona.
Causal vs. correlacional	Ejemplo: la correlación atribuye 15,1 pp (puntos porcentuales) de fuga a las transferencias; el efecto real es 8 pp (confusor: llamada previa). Error del efecto causal promedio (ATE) 0,071 > 0,05.
Decisión pedida	¿Financiar e integrar el prototipo? Indicadores (KPI): < 250 ms, 1.500 llamadas simultáneas y error ATE ≤ 0,05. Beneficios: tiempo de resolución (TTR) −15% y recargo SaaS de 20%.

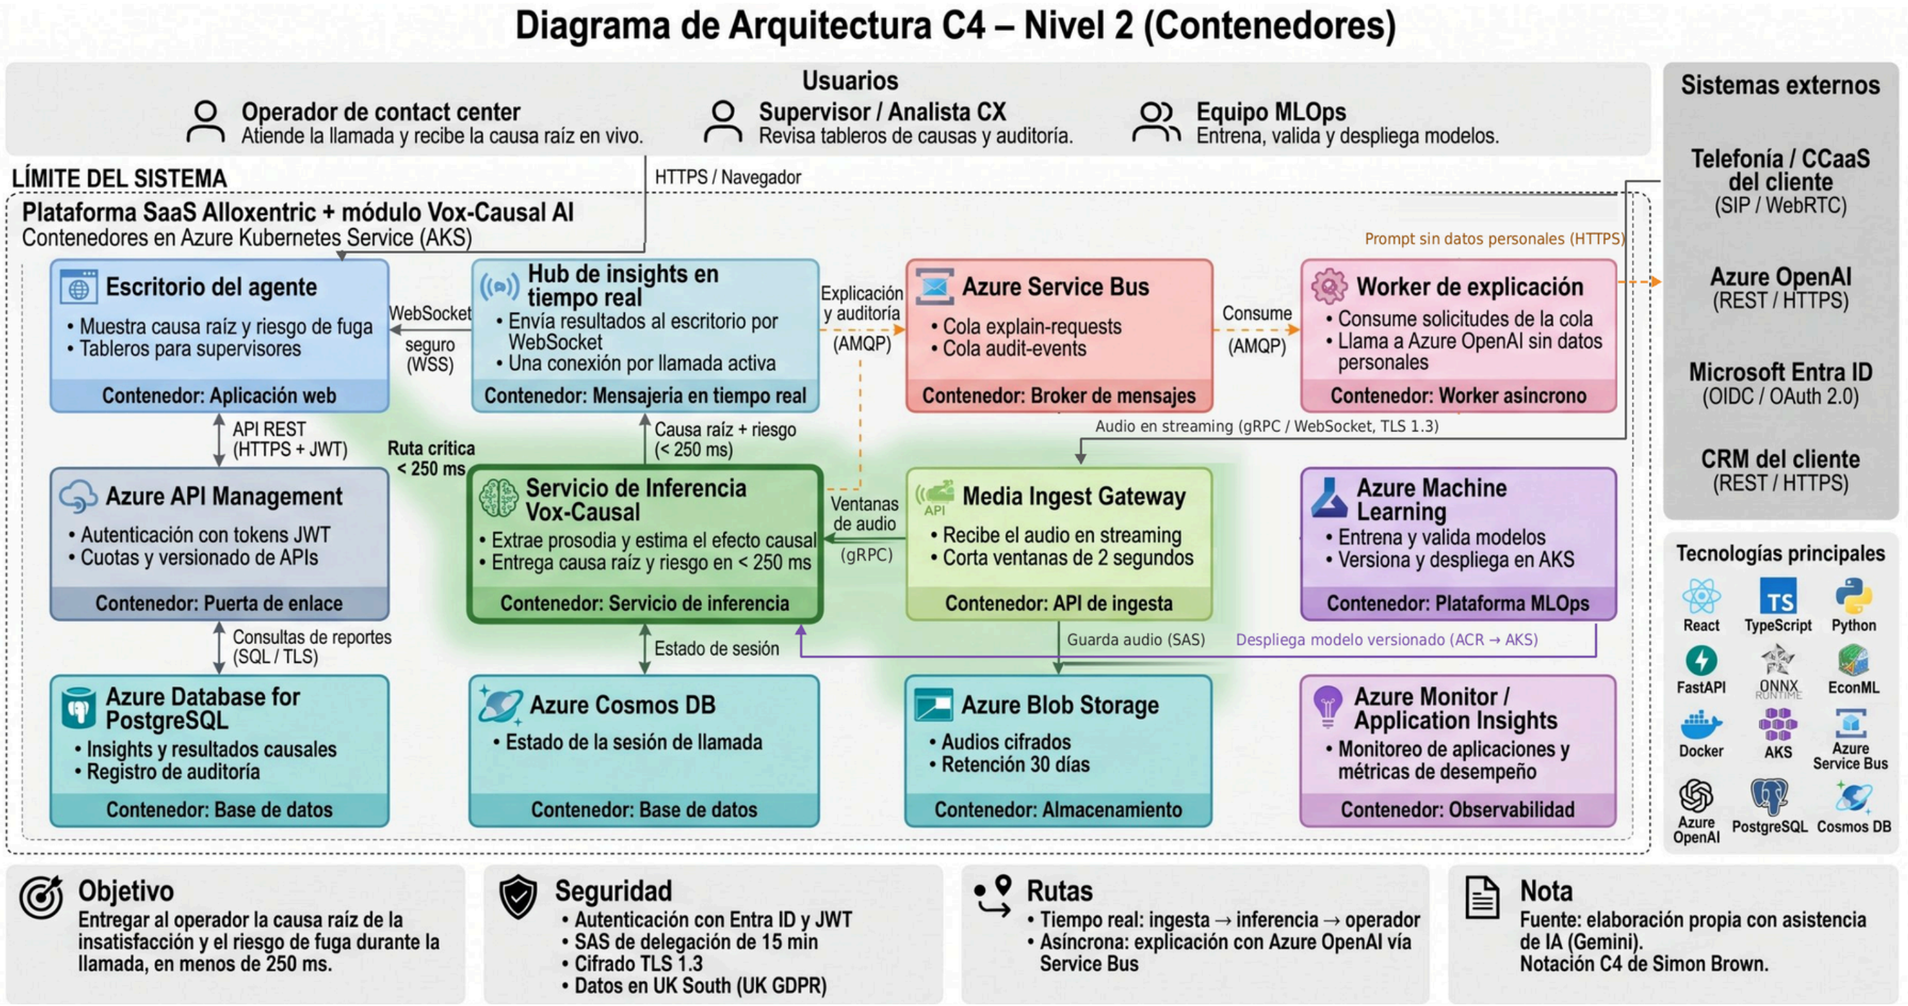
Problema y enfoque

N°	Solución comparable	Resultado reportado	Enfoque	Brecha
1	Cogito en MetLife	+13% satisfacción	Tono de voz	Sin causa
2	Microsoft Copilot for Service	−12% AHT	IA generativa	Sin causa
★	Vox-Causal AI (propuesta)	TTR −15% (caso)	Causal en vivo	Diferenciador
3	Google Agent Assist (TTEC)	−11% AHT	Sugerencias	Correlacional
4	Five9 Agent Assist (TruConnect)	−30 s AHT	Transcripción	No diagnostica
5	CausalML (Uber) / EconML	Campañas focalizadas	Causal (lotes)	No en vivo

Estado del arte

Fuente: caso PIA (Magna, 2026); Digital Catapult (2021); The Fintech Times (2023); Best Practice AI; CX Today (2023); Google Cloud (2024); Business Wire (2021); Uber (2026).

Diagrama de Arquitectura C4 – Nivel 2



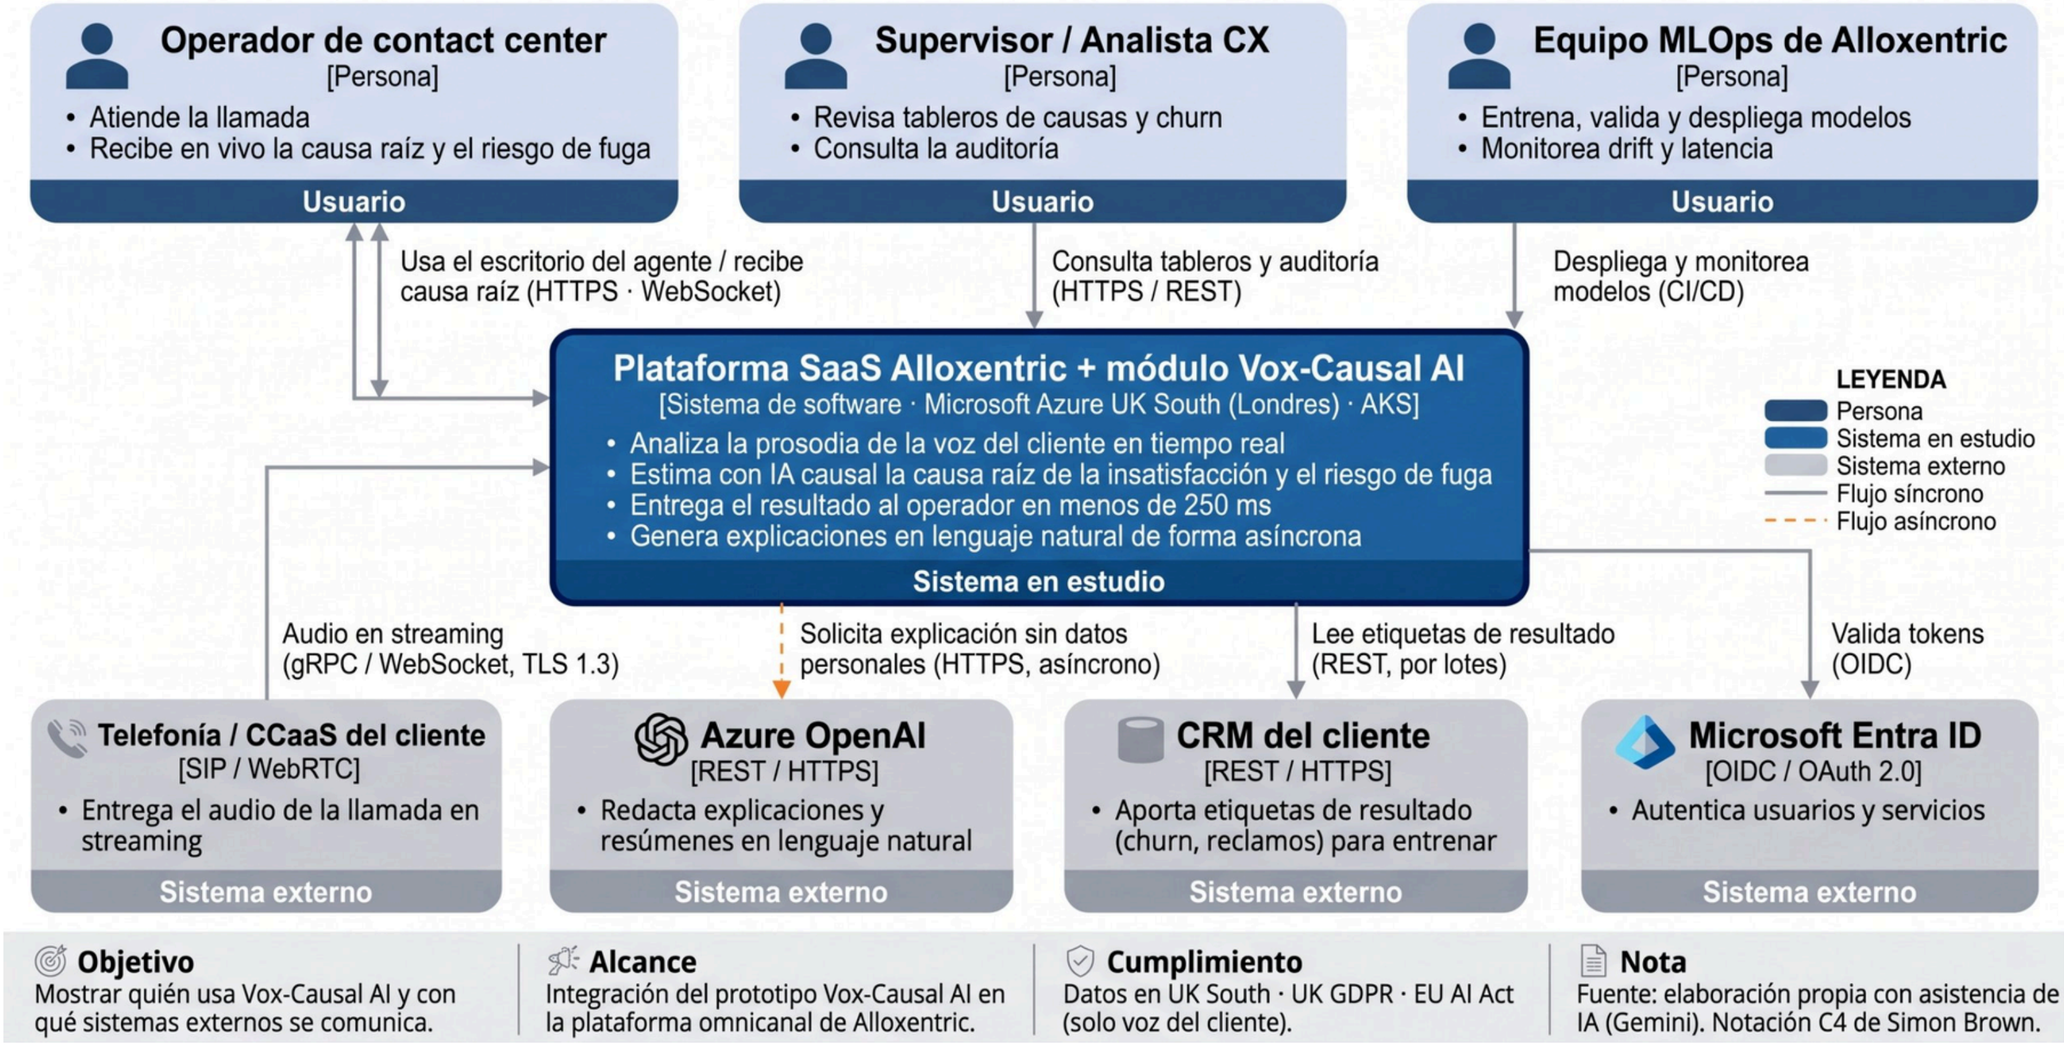
Flujo crítico (< 250 ms)
1. CCaaS → Media Ingest Gateway (FastAPI) por gRPC/WebSocket sobre TLS 1.3.
2. Servicio de Inferencia (FastAPI + ONNX en GPU + EconML) por gRPC.
3. Insight al escritorio React vía Azure Web PubSub (WSS). p95 diseñado: 175 ms.

Ruta asíncrona
4. Service Bus (AMQP, con cola de fallidos DLQ) → Worker → Azure OpenAI.

Datos y operación
• Blob Storage con SAS de 15 min
• Cosmos DB (sesión) · PostgreSQL (auditoría)
• Azure ML (modelos) · Azure Monitor (telemetría)
• APIM con JWT (Entra ID)

Fuente: elaboración propia del Grupo 2 (modelo C4, Brown, 2026; Microsoft Learn, 2026). Diagrama elaborado con asistencia de IA (Gemini); revisado por el equipo.

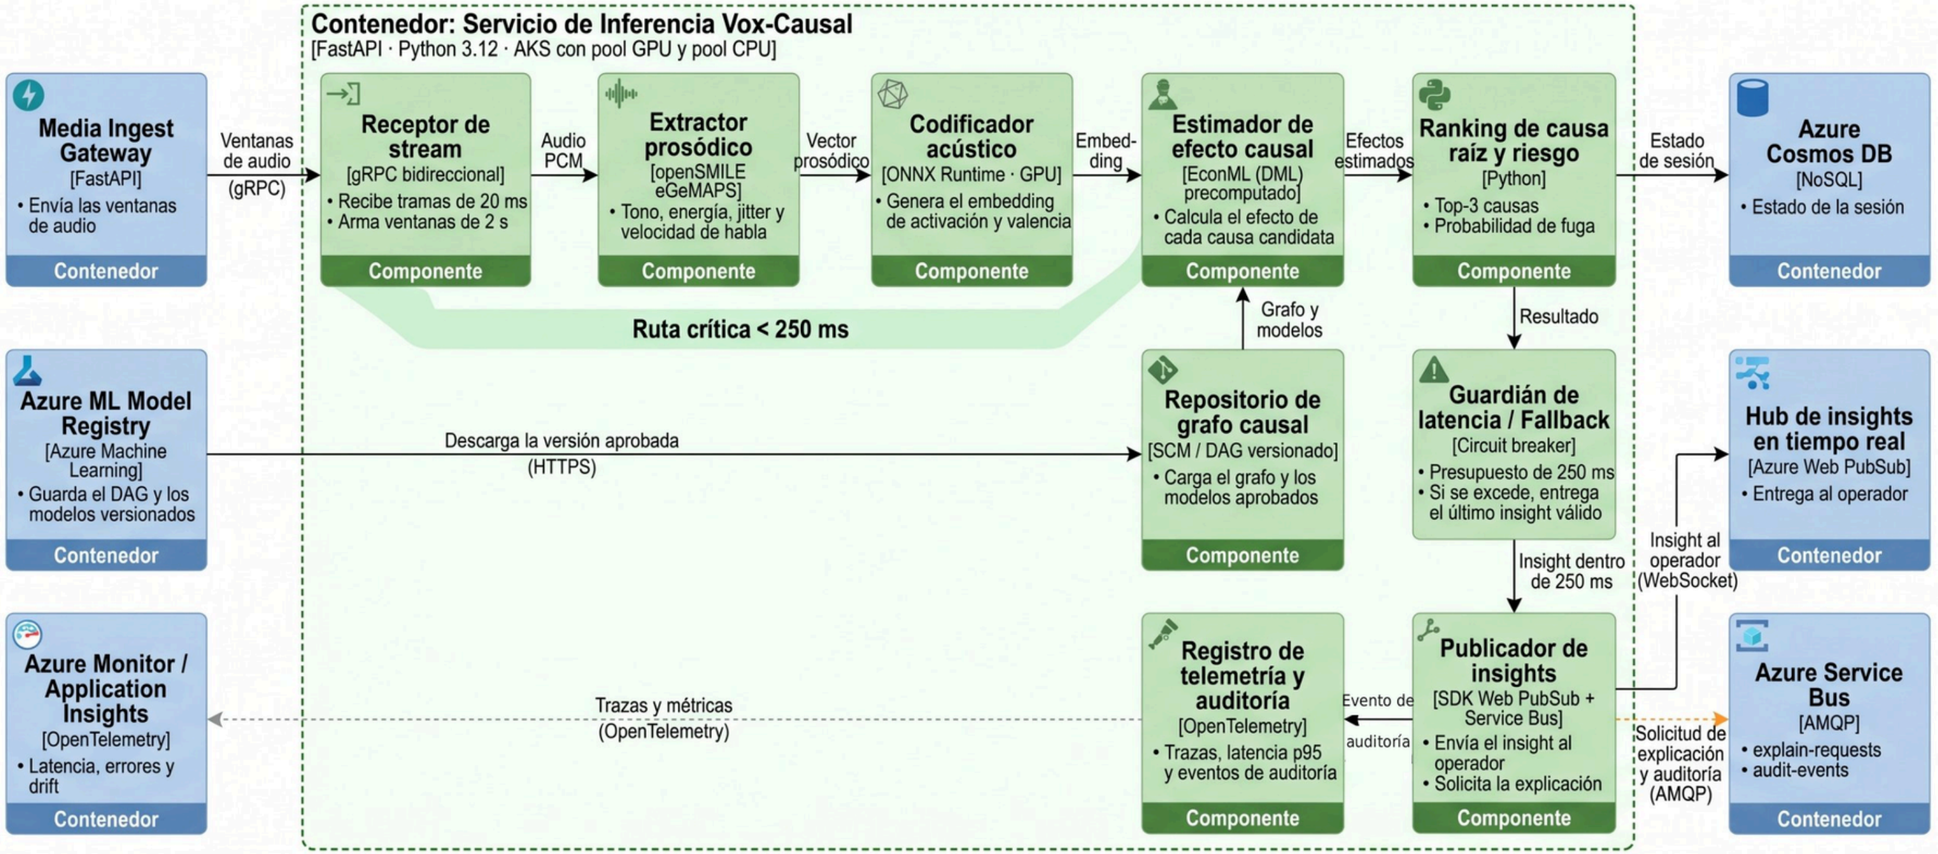
Diagrama de Arquitectura C4 – Nivel 1 (Contexto)



Vox-Causal AI funciona como módulo de la plataforma de Alloxentric (Azure UK South). Actores: operador del contact center, supervisor/analista de experiencia de cliente (CX) y equipo MLOps. Sistemas externos: telefonía en la nube (CCaaS), CRM, Azure OpenAI (solo redacta explicaciones) y Microsoft Entra ID (identidad).

Fuente: elaboración propia del Grupo 2 (modelo C4, Brown, 2026). Diagrama elaborado con asistencia de IA (Gemini); revisado por el equipo.

Diagrama de Arquitectura C4 – Nivel 3 (Componentes)



Objetivo
Detallar cómo el servicio de inferencia obtiene la causa raíz y el riesgo de fuga en menos de 250 ms.

Resiliencia
Fallback con el último insight válido · Colas con dead-letter · Modelos versionados.

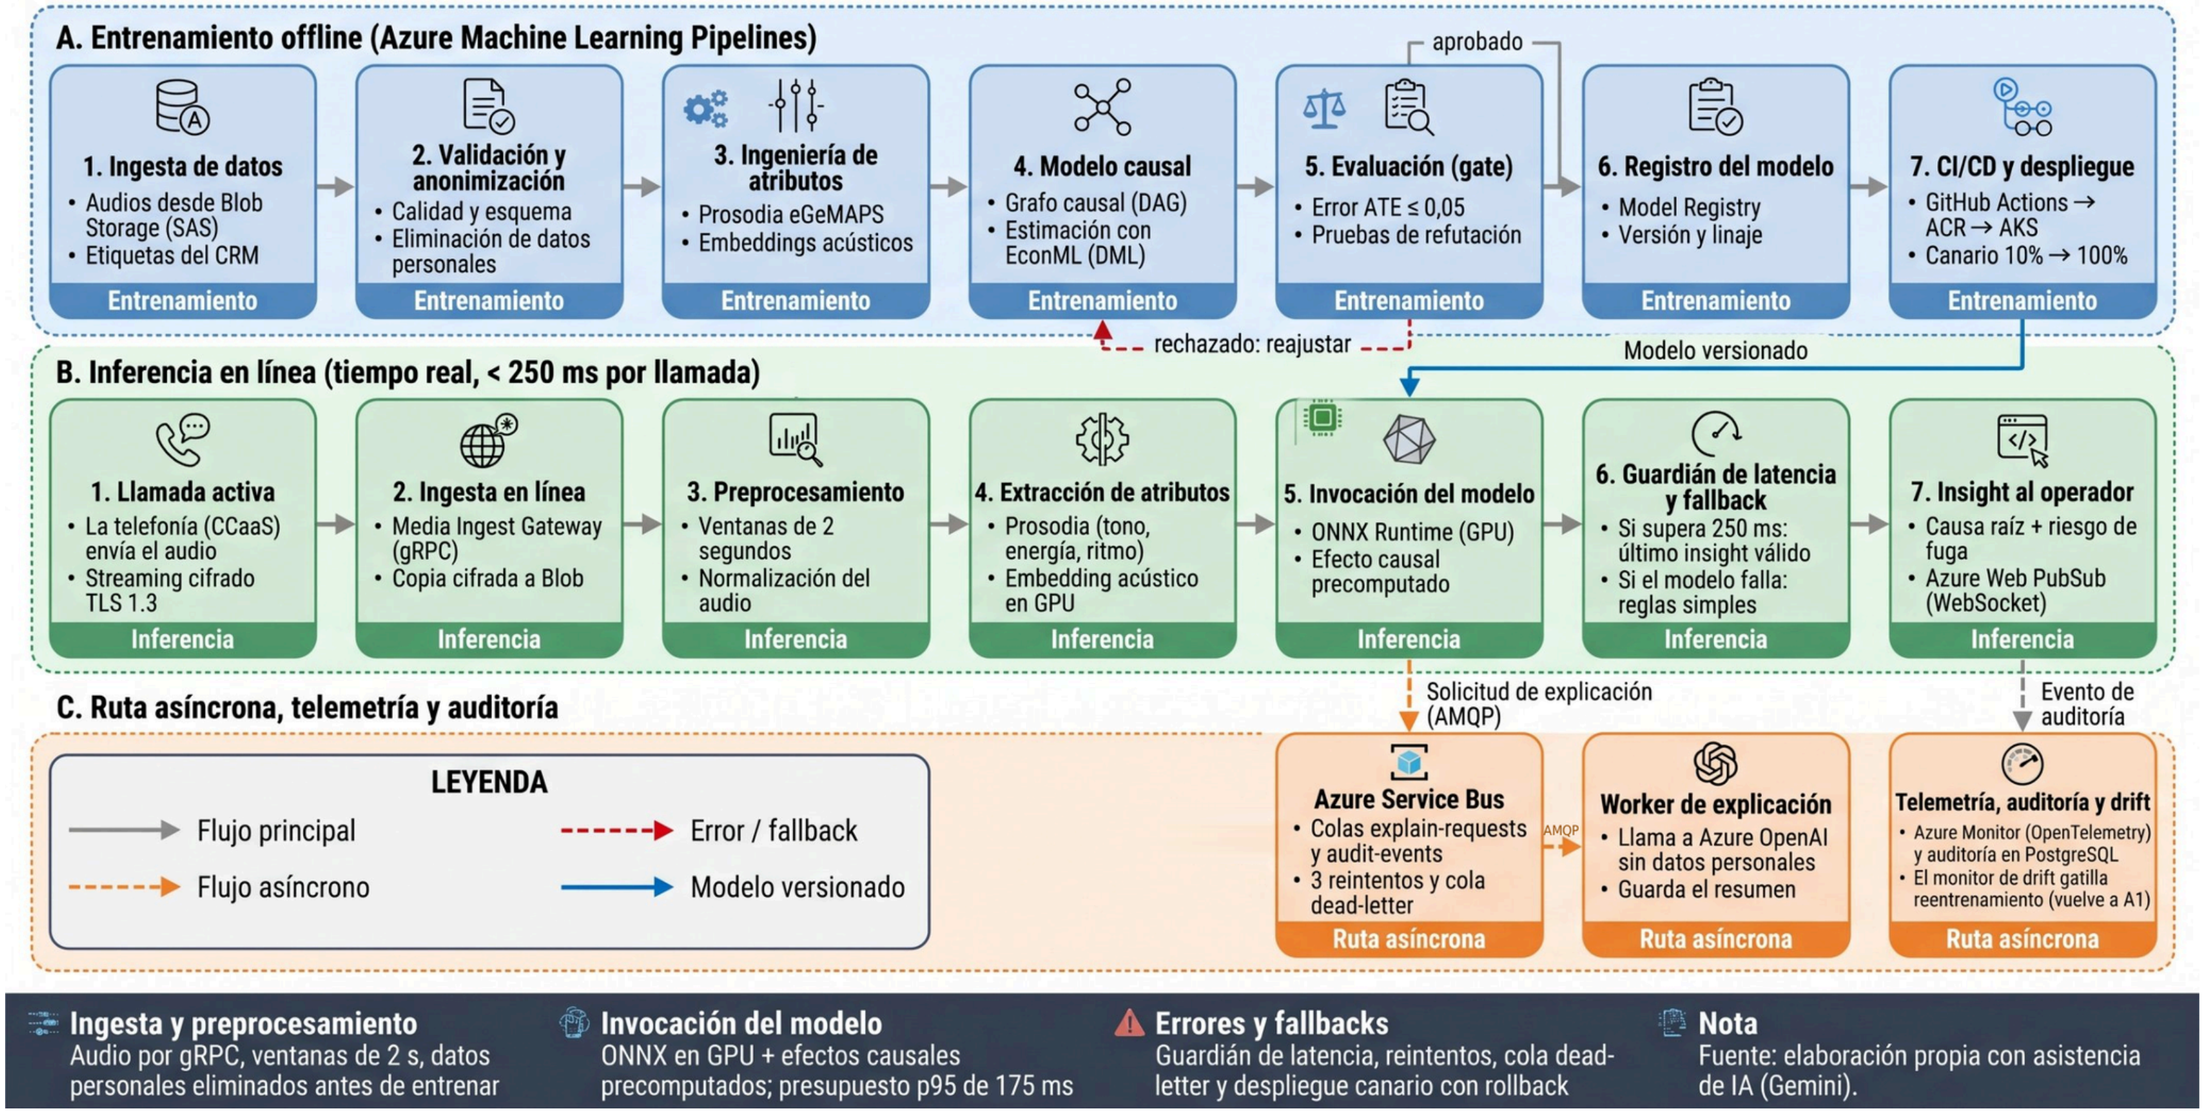
Nota
Fuente: elaboración propia con asistencia de IA (Gemini). Notación C4 de Simon Brown.

Dentro del Servicio de Inferencia
- Receptor de stream: ventanas de 2 s.
- Extractor prosódico: 88 rasgos eGeMAPS (openSMILE).
- Codificador acústico: ONNX en GPU.
- Estimador causal: modelos EconML precalculados sobre el grafo causal (DAG).
- Ranking: top-3 causas y probabilidad de fuga.
- Guardián de latencia: fallback si se agota el tiempo (< 2%).
- Publicador y registro de telemetría/auditoría.

Presupuesto p95 (ms)
Red 20 · Ventaneo 15 · Prosodia 40 · GPU 45 · Causal 35 · WSS 20 = 175 ms (holgura 75 ms)

Fuente: elaboración propia del Grupo 2 (modelo C4, Brown, 2026; ITU-T G.114, 2003). Diagrama elaborado con asistencia de IA (Gemini); revisado por el equipo.

Pipeline MLOps y Servicios de Inferencia



A · Entrenamiento por lotes (Azure ML): ingesta → anonimización → atributos → modelo causal → puerta ATE ≤ 0,05 → registro → canario. B · Inferencia en línea: llamada → ingesta → preprocesamiento → atributos → invocación → guardián → insight. C · Ruta asíncrona: Service Bus → worker → telemetría, auditoría y drift.

Fuente: elaboración propia del Grupo 2. Diagrama elaborado con asistencia de IA (Gemini); revisado por el equipo.

2. Incidente de latencia y seguridad

Prototipo del sandbox vs. arquitectura productiva · meta < 250 ms · UK GDPR

Qué falló en el sandbox

- Azure OpenAI se llamaba de forma síncrona: su latencia crece con los tokens
- El efecto causal se reestimaba en línea (operación por lotes)
- Audios con SAS de clave de cuenta y larga duración

Resultado con D1–D6

- Latencia p95: 175 ms (meta < 250 ms, holgura 75 ms)
- Seguridad: SAS de delegación 15 min, TLS 1.3, UK South
- Cumplimiento: solo voz del cliente (EU AI Act art. 5.1.f)

Elemento	Prototipo (sandbox)	Arquitectura productiva
Azure OpenAI	Llamada síncrona	Asíncrono vía Service Bus (D1)
Motor causal	Cálculo en línea	Efectos precomputados + ONNX GPU/gRPC (D2, D3)
Audios	Clave de cuenta	SAS de delegación 15 min, solo voz del cliente (D4, D6)
Batch / tiempo real	Mismo clúster	Pools aislados (D5)

Verificación: prueba de carga de 1 semana con 1.500 llamadas; SAS que expira a los 15 min; reentrenar durante la carga sin variar el p95 > 5%; ≥ 19 streams por GPU. Fuente: Microsoft Learn (2026); Lewis Silkin (2025); elaboración propia.

UNIVERSIDAD TECNOLÓGICA METROPOLITANA
del Estado de Chile
UTEM

2. Evaluación técnica: métricas de calidad

Métrica · meta	Valor	Detalle	Estado
Precisión causal (error ATE) ≤ 0,05 · sin ajuste: 0,071	**0,0009**	con ajuste	Cumple
Latencia p95 < 250 ms · eficiencia de desempeño	**175 ms**	estimado	Cumple
Cobertura de pruebas ≥ 80% · mantenibilidad	**100%**	28 tests	Cumple
Deuda técnica (SQALE) ≤ 4 h por incremento · mantenibilidad	**0,3–1,5 h**	rating A	Cumple (est.)

Medido sobre el prototipo del núcleo (src/voxcausal, 28 pruebas). Con ajuste backdoor el error de ATE baja de 0,071 a 0,0009; falta validarlo con datos reales del piloto (C1). La deuda es estimada con ruff y pylint (9 code smells).

Plan de validación

1.500 llamadas en prueba de carga y validación

3,38 M llamadas/mes en producción

36 + 12 nodos GPU + CPU dimensionados

Umbrales de operación

≤ 0,05 error ATE objetivo

< 2 % respuestas en fallback

≥ 19 streams por GPU (punto de quiebre)

Fuente: KPI del caso PIA (Magna, 2026); ISO/IEC 25010:2023; mediciones del Grupo 2 sobre el prototipo con pytest-cov, ruff y pylint, corte 04-nov-2026 (Informe ERV, sección 2.3).

3 y 6. Beneficios, escalabilidad y mantenimiento

3. Beneficios

TTR −15% [CASO]: libera 624.780 h de agente al año → US$ 7,37 M/año de ahorro para los clientes (50% realizable, US$ 23,60/h).

Recargo 20% [CASO]: 3.590 puestos × US$ 65 → US$ 560.027/año para Alloxentric. El ahorro es 13,2× el recargo.

Resolución al primer contacto (FCR) +3 pp [SUP]: ≈ US$ 2,9 M/año para los clientes; no se incluye en el VAN.

Intangibles: explicabilidad y auditoría, cumplimiento por diseño, diferenciación y grafo causal como activo de datos.

6. Escalabilidad

Escalamiento horizontal: KEDA agrega pods según colas y streams; AKS agrega nodos.

1.500 llamadas: 36 GPU / 12 CPU · 3,38 M llamadas/mes · US$ 13.483/mes · VAN US$ 366.751

3.000 llamadas: 72 / 24 · 6,75 M · US$ 26.404/mes · VAN US$ 1,13 M

4.500 llamadas: 108 / 36 · 10,13 M · US$ 39.299/mes · VAN US$ 1,89 M

Costo cloud ≈ US$ 0,004 por llamada: el margen se mantiene al crecer.

6. Plan de mantenimiento

Según ISO/IEC/IEEE 14764:

Correctivo: incidentes con SLA de 4 h [SUP] y rollback al modelo anterior.

Adaptativo (trimestral): librerías, imágenes Docker, AKS y Azure ML.

Perfectivo (mensual [SUP] o si PSI > 0,2): reentrenamiento y revisión experta del DAG.

Preventivo (semestral): pruebas de carga, costos cloud y deuda técnica.

Responsable: 1 FTE MLOps (quiebre 2,14 FTE).

Fuente: caso PIA [CASO]; Pertemps (2026); Kayako (2026); SQM Group (2024); ISO/IEC/IEEE 14764:2022; modelo ERV del Grupo 2. [SUP] = supuesto del equipo (Anexo A del informe).

4–5. Costos y evaluación económica

Caso base (5 años, tasa 12,34%, impuesto UK 25%)

CAPEX US$ 69.835

800 HH × US$ 68,73 + 15% contingencia + prueba de carga. OPEX pleno US$ 281.383/año: cloud US$ 13.483/mes + 1 FTE MLOps.

VAN US$ 366.751 · TIR 91,9%

Tasa 12,34% = Damodaran 9,34% + 3 pp. Ingreso: 3.590 puestos × US$ 65 × 20% = US$ 560.027/año.

Payback 1,82 años (desc. 2,02) · B/C 1,54

Después de impuestos. Antes de impuestos: VAN US$ 495.637 y TIR 106,4%.

Escenarios

Escenario	VAN (US$)	B/C	Supuesto que cambia
Pesimista	−215.937	0,71	ARPU US$ 50, adopción 15→80%, 25 streams/GPU
Base	366.751	1,54	ARPU US$ 65, adopción 30→100%, 50 streams/GPU, 1 FTE
Optimista	1.037.247	3,53	ARPU US$ 89, 100 streams/GPU, 0,5 FTE · TIR 238%
Económico (cliente)	17,7 M	20,25	Incluye el ahorro anual de los clientes

Puntos de quiebre (VAN = 0)

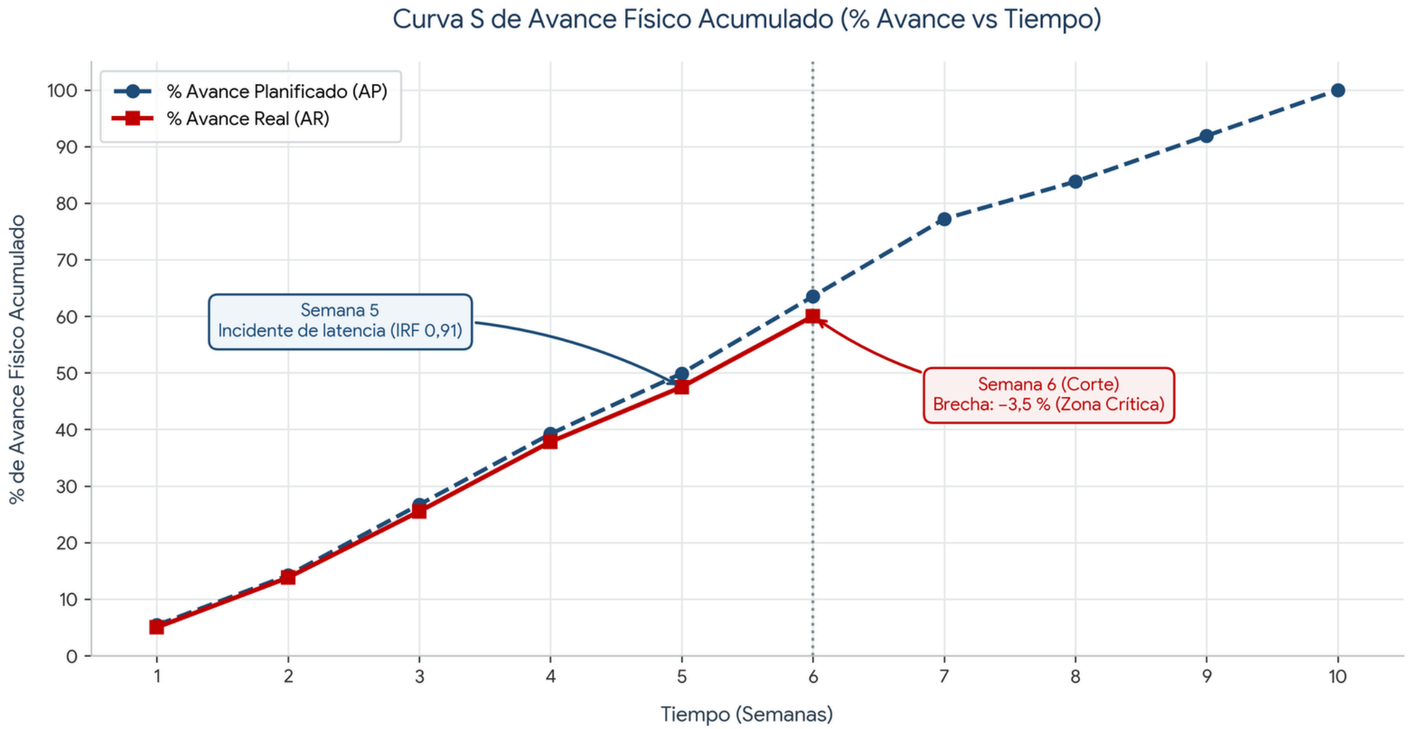
Recargo / ARPU
13,1% · US$ 42,6

Adopción / MLOps
52% · 2,14 FTE · LLM 11,4×

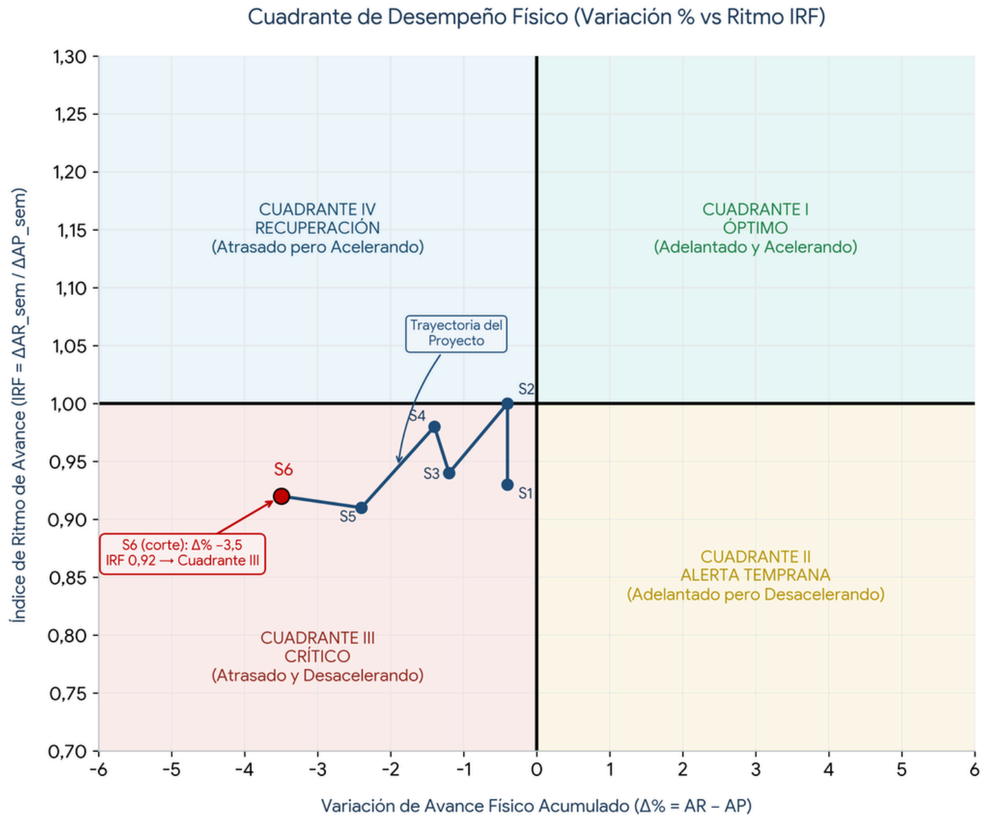
Valor para el cliente

Ahorro US$ 7,37 M al año = 13,2× el recargo

7. Control de avance físico: curva S y cuadrante



Fuente: elaboración propia sobre la EDT de 7 paquetes (800 HH); avance real = escenario de control simulado. Elaborado con asistencia de IA (Gemini).

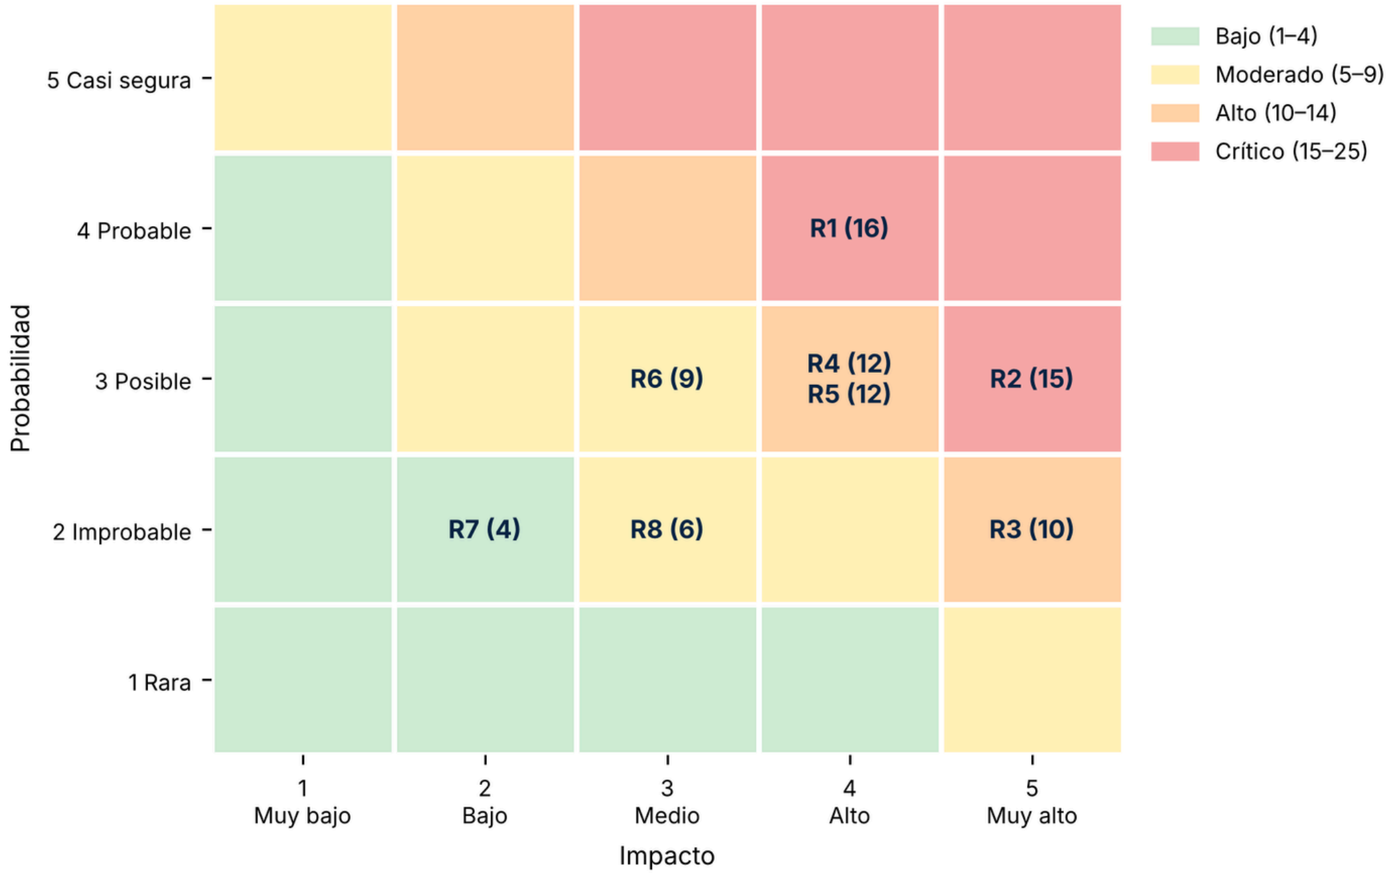


Fuente: elaboración propia; Δ% = AR − AP e IRF = ΔAR semanal / ΔAP semanal, con AP y AR de la curva S. Elaborado con asistencia de IA (Gemini).

Fuente: línea base sobre 800 HH (7 paquetes, 10 semanas); avance real (AR) simulado. Δ% = AR − AP; IRF = ΔAR semanal / ΔAP semanal. Corte S6: Δ% −3,5 · IRF 0,92 → Cuadrante III (Crítico). SPI/CPI en anexo. Gráficos elaborados con IA (Gemini).

7. Matriz de riesgos (ISO 31000)

R1 · Model drift (4×4 = 16, crítico): monitoreo PSI, reentrenamiento mensual, puerta ATE ≤ 0,05.
R2 · Latencia cloud > 250 ms (3×5 = 15, crítico): prueba de carga, guardián de latencia, ONNX/GPU, holgura 20%.
R3 · Incumplimiento GDPR (2×5 = 10, alto): DPIA, SAS 15 min, TLS 1.3, solo voz del cliente, sin PII al LLM.
R4 · Confusores no modelados (3×4 = 12): revisión experta del DAG y refutadores DoWhy.
R5 · Mercado no acepta recargo o adopción lenta (3×4 = 12): piloto pagado; ahorro 13:1.
R6 · Capacidad GPU (3×3 = 9): medir en prueba de carga; quiebre 19 streams.
R7 · Alza del precio del LLM (2×2 = 4): modelo de bajo costo; quiebre 11,4×.
R8 · Rotación MLOps (2×3 = 6): runbooks y pipeline reproducible.



Fuente: elaboración propia del Grupo 2 según ISO 31000:2018. Nivel = probabilidad × impacto (escala 1–5). Mapa de calor elaborado con asistencia de IA (Claude).

8. Recomendación al directorio y hoja de ruta

1 Dictamen: GO condicionado (C1–C4)

Condición	Umbral	Plazo
C1 · Precisión causal con datos reales	**ATE ≤ 0,05**	Sem. 1–10
C2 · Prueba de carga con 1.500 llamadas	**p95 < 250 ms · ≥ 19 streams/GPU**	Sem. 8–10
C3 · DPIA aprobada (UK GDPR / EU AI Act)	**Solo voz del cliente**	Sem. 6
C4 · Piloto comercial	**Recargo ≥ 13,1% · adopción ≥ 52%**	Meses 3–5

2 Impacto y diferenciación

Impacto en el cliente

- Ahorro de US$ 7,37 M al año: 13,2× el recargo
- Con −11% de AHT (Google/TTEC) sigue siendo 9,7×
- Nueva línea de ingresos de US$ 560 mil/año

Diferenciación

- Causal, no solo correlacional (CausalML/EconML)
- Explicable y auditable para supervisores
- Diseñado para UK GDPR y EU AI Act

3 Hoja de ruta

Semanas 1–10 · Integración

- Integrar en Azure UK South (800 HH)
- Aplicar decisiones D1–D6
- Validar C1 y C2

Meses 3–5 · Piloto

- Piloto con 2–3 clientes del Reino Unido
- Medir AHT, FCR y satisfacción reales
- Confirmar recargo y adopción (C4)

Meses 6–12 · Escalamiento

- Despliegue a los 3.590 puestos
- Reentrenamiento mensual y monitoreo de drift
- Revisión del VAN con datos reales

Fuente: Informe ERV del Grupo 2 (secciones 3, 5, 7 y 8); Google Cloud (2024) para el escenario de −11% de AHT.

Anexo A. Glosario de siglas

AHT · tiempo medio de atención de una llamada
AKS · Azure Kubernetes Service
AMQP · protocolo de mensajería de Service Bus
AP / AR · avance físico programado / real
APIM · Azure API Management
ATE · efecto causal promedio
B/C · relación beneficio/costo
CAPEX / OPEX · inversión / gasto operacional
CCaaS · telefonía de contact center en la nube
CPI / SPI · índices de costo y plazo (valor ganado)
CX · experiencia de cliente
DAG · grafo causal dirigido acíclico
DLQ · cola de mensajes fallidos
DPIA · evaluación de impacto (UK GDPR)
EDT · estructura de desglose del trabajo
eGeMAPS · 88 rasgos acústicos estándar (openSMILE)
FCR · resolución al primer contacto
FTE · jornada completa equivalente
GDPR · reglamento de protección de datos
gRPC · llamada remota sobre HTTP/2
HH · horas-hombre
IRF · índice de ritmo físico (ΔAR / ΔAP semanal)
KPI · indicador clave
LLM · modelo de lenguaje (Azure OpenAI)
ONNX · formato de modelo optimizado
p95 · percentil 95
PII · datos personales
PSI · indicador de drift de datos
SAS · URL de acceso temporal a Blob Storage
SCM · modelo causal estructural
SQALE · método de deuda técnica (SonarQube)
TIR / VAN · tasa interna de retorno / valor actual neto
TTR · tiempo de resolución del caso
WSS · WebSocket seguro (TLS)

Anexo B. Valor ganado (SPI y CPI) al corte de la semana 6

Paquete · BAC · PV · EV · AC · SPI · CPI (horas)

1 Gestión y DPIA · 60 · 36 · 36 · 40 · 1,00 · 0,90

2 Refactorización · 150 · 150 · 150 · 158 · 1,00 · 0,95

3 Integración Azure · 150 · 120 · 96 · 118 · 0,80 · 0,81

4 MLOps y motor causal · 160 · 133 · 140 · 142 · 1,05 · 0,99

5 Seguridad · 90 · 45 · 40 · 48 · 0,89 · 0,83

6 Pruebas SQA · 120 · 24 · 18 · 20 · 0,75 · 0,90

7 Despliegue · 70 · 0 · 0 · 0 · — · —

Total · 800 · 508 · 480 · 526 · 0,945 · 0,913

SV = EV − PV = −28 h (atraso en integración Azure)

CV = EV − AC = −46 h (retrabajo del incidente)

EAC = BAC / CPI = 877 h (US$ 60.256)

Desvío estimado 77 h (9,6%) → cubierto por la reserva de 120 h

TCPI = 1,168

Coherente con el cuadrante físico: Cuadrante III (crítico) en S6.

Fuente: línea base de 800 HH [CASO]; EV y AC simulados para el ejercicio académico; fórmulas PMI (PMBOK, 7.ª ed., 2021). PV = valor planificado; EV = valor ganado; AC = costo real; BAC = presupuesto total; EAC = estimación al término.

UNIVERSIDAD TECNOLÓGICA METROPOLITANA
del Estado de Chile
UTEM

Anexo C. Evidencia del repositorio

Estructura del proyecto

Repositorio público del grupo con el Informe ERV, la presentación, los diagramas y el prototipo

gpi-411-grupo2-voxcausal/	Portada del proyecto y dictamen
├── **README.md**	
├── **docs/**	Informe ERV corregido y presentación
│ ├── **erv/**	Gráficos financieros y de riesgos
│ │ └── **figuras/**	C4 niveles 1–3 y pipeline MLOps
│ ├── **arquitectura/**	(Gemini)
│ └── **gestion/**	Curva S y cuadrante de avance físico
├── **src/**	Prototipo del núcleo (5 módulos)
└── **tests/**	28 pruebas pytest, cobertura 100%

Repositorio

PLATAFORMA **GitHub**

URL **github.com/GiovanniGabrielli33/gpi-411-grupo2-voxcausal**

Estado del repositorio

Corte al 04-nov-2026

3
ramas: main, erv, prototipo

2
PR integrados (#1 y #2)

Flujo de trabajo

El informe (feature/erv) y el prototipo (feature/prototipo) se integraron a main con PR revisados; el PDF y esta presentación quedan en docs/erv.

Detalle de estructura, flujo y uso de IA en README.md

Ramas, revisión y automatización

Hecho
Ramas
main = versión entregada; feature/* = desarrollo

Hecho
Pull request
PR #1 y #2 revisados por otro integrante antes de integrar a main

Futuro
CI/CD
Pendiente: GitHub Actions y SonarCloud en la fase 1